TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN, ĐHQG-HCM
KHOA CÔNG NGHỆ THÔNG TIN



BÁO CÁO
Ứng dụng xử lý ảnh số và video số

CHỦ ĐỀ:
PHÂN ĐOẠN ẢNH VỚI DỮ LIỆU NHÃN HẠN CHẾ + TEXT PROMPT

Chung Tín Đạt - 23122024

Giảng Viên:
PGS. TS. Lý Quốc Ngọc

TP. Hồ Chí Minh, tháng 7/2026

Mục lục

1 Giới thiệu **4**

1.1 Bối cảnh chung 4

1.2 Động lực nghiên cứu 6

1.2.1 Ý nghĩa khoa học 6

1.2.2 Ý nghĩa thực tiễn 8

1.3 Đóng góp 9

1.4 Phát biểu bài toán 10

2 Các công trình nghiên cứu liên quan **16**

2.1 Phân đoạn ảnh y khoa truyền thống 16

2.2 Học bán giám sát trong phân đoạn ảnh y khoa 17

2.3 Phân đoạn ảnh theo tham chiếu ngôn ngữ 18

2.4 Phân đoạn ảnh y khoa có tham chiếu văn bản 19

2.5 Phân đoạn linh hoạt theo prompt và thế giới mở 20

2.6 Học biểu diễn đa phương thức ảnh–văn bản trong y khoa 21

2.7 Tổng kết 22

3 Phương pháp **23**

3.1 Dữ liệu 23

3.1.1 Mô tả các bộ dữ liệu 23

3.1.2 Quy trình xây dựng chú thích văn bản 24

3.1.3 Cấu trúc chú thích 24

3.1.4 Phân chia dữ liệu 24

3.2 Kiến trúc mô hình 25

3.2.1 Nhánh CNN U-shape 27

3.2.2 Nhánh ViT U-shape 28

3.2.3 Mô-đun Patch Embedding 29

3.2.4 Bộ mã hóa văn bản 30

3.2.5 Mô-đun Reconstruct 31

3.2.6 Mô-đun PLAM 32
3.3 Hàm mất mát 34
3.3.1 Hàm mất mát có giám sát 34
3.3.2 Language Vision Loss 35
3.4 Cơ chế sinh nhãn giả 36
3.5 Các pipeline huấn luyện và sử dụng mô hình 38

4 Cài đặt **42**
4.1 Độ đo đánh giá 42
4.2 Môi trường thử nghiệm 43
4.3 Chú thích mã nguồn 44
4.4 Cài đặt thực tế 45
4.5 Kết quả thử nghiệm 47

5 Kết luận **52**
5.1 Tổng kết 52
5.2 Hạn chế 53
5.3 Hướng phát triển 53

Danh sách hình vẽ

1.1 Pipeline chung của mô hình phân đoạn dựa trên ảnh và text prompt 15

3.1 Ví dụ ảnh đầu vào và mặt nạ phân đoạn trong các bộ dữ liệu. . 25
3.2 Kiến trúc mô hình LViT. 26
3.3 Minh họa quá trình làm phẳng và xử lý đặc trưng trong LViT. . 26
3.4 Nhánh CNN U-shape và công thức cập nhật đặc trưng. 27
3.5 Nhánh ViT U-shape và quá trình tích hợp đặc trưng ảnh-văn bản. 28
3.6 Bộ mã hóa văn bản dựa trên BERT. 31
3.7 Mô-đun PLAM trong kiến trúc LViT. 33
3.8 Pipeline huấn luyện mô hình 38
3.9 Pipeline sử dụng mô hình 38
3.10 Pipeline tính toán hàm mất mát và xây dựng nhãn giả chi tiết . 39

4.1 Minh họa kiến trúc LViT trong cài đặt. 46
4.2 Phép nối dữ liệu theo chiều kênh. 46
4.3 So sánh trực quan dự đoán trên QaTa-COV19, thứ tự từ trái sang phải là ảnh gốc, ground truth, mask supervised và mask semi-supervised. 47
4.4 So sánh trực quan dự đoán trên MosMedData+, thứ tự trong mỗi nhóm là ảnh gốc, ground truth, mask supervised và mask semi-supervised. 48

Chương 1

Giới thiệu

1.1 Bối cảnh chung

Trong thập kỷ qua, các mạng học sâu ứng dụng trong lĩnh vực Thị giác Máy tính đã đạt được nhiều thành tựu quan trọng trong các tác vụ như phân loại ảnh, phát hiện đối tượng và phân đoạn ảnh. Các kiến trúc như mạng nơ-ron tích chập (Convolutional Neural Networks – CNNs) và Vision Transformer đã giúp mô hình học được các đặc trưng trực quan phức tạp từ dữ liệu hình ảnh, từ đó cải thiện đáng kể độ chính xác so với các phương pháp xử lý ảnh truyền thống. Tuy nhiên, phần lớn các mô hình này vẫn hoạt động trong bối cảnh *Closed-vocabulary*, nghĩa là chúng chỉ có thể nhận diện hoặc phân đoạn các lớp đối tượng đã được định nghĩa sẵn trong tập dữ liệu huấn luyện.

Cách tiếp cận *Closed-vocabulary* tạo ra một giới hạn lớn về khả năng tổng quát hóa. Khi mô hình được triển khai trên các miền dữ liệu mới, các lớp đối tượng mới, hoặc các điều kiện thu nhận ảnh khác biệt so với dữ liệu huấn luyện, hiệu suất thường suy giảm đáng kể. Nguyên nhân là mô hình học mối quan hệ chặt chẽ giữa hình ảnh và tập nhãn cố định, nhưng không có cơ chế linh hoạt để hiểu các khái niệm mới ngoài tập nhãn đó. Điều này đặc biệt bất lợi trong các bài toán thực tế, nơi dữ liệu luôn đa dạng, phân bố thay đổi theo thời gian, và yêu cầu nhận diện có thể thay đổi tùy theo ngữ cảnh sử dụng.

Sự xuất hiện của các mô hình nền tảng (Foundation Models) như CLIP và SAM đã thúc đẩy sự chuyển dịch từ các hệ thống phân đoạn khép kín sang các hệ thống có khả năng tương tác và mở rộng hơn. CLIP cho thấy hiệu quả của việc học biểu diễn chung giữa hình ảnh và ngôn ngữ tự nhiên, trong khi SAM chứng minh khả năng phân đoạn linh hoạt thông qua các dạng prompt trực quan như điểm, hộp bao hoặc mặt nạ gợi ý. Những mô hình này mở ra hướng tiếp cận *Open-vocabulary Segmentation*, trong đó mô hình không chỉ phụ thuộc vào tập nhãn cố định, mà có thể sử dụng thông tin mô tả bổ sung để xác định

vùng cần phân đoạn.

Trong bối cảnh này, prompt đóng vai trò như một kênh giao tiếp giữa người dùng và mô hình. Prompt có thể tồn tại dưới nhiều dạng khác nhau, chẳng hạn như điểm ảnh, hộp bao, mặt nạ thô hoặc mô tả bằng ngôn ngữ tự nhiên. Đối với phân đoạn dựa trên văn bản, câu nhắc văn bản giúp người dùng mô tả trực tiếp đối tượng, cơ quan hoặc vùng tổn thương cần quan tâm. Nhờ đó, mô hình có khả năng khai thác thêm thông tin ngữ nghĩa thay vì chỉ dựa trên tín hiệu thị giác thuần túy.

Tuy nhiên, đối với nhiều lĩnh vực chuyên biệt, đặc biệt là trong y khoa, việc ứng dụng các mô hình học sâu vẫn bị giới hạn bởi sự thiếu hụt các tập dữ liệu được dán nhãn chất lượng cao [1]. Dữ liệu y khoa thường có chi phí thu thập và gán nhãn rất lớn, bởi quá trình chú thích cần được thực hiện hoặc kiểm chứng bởi bác sĩ và chuyên gia có kinh nghiệm. Ngoài ra, ranh giới của các cấu trúc giải phẫu hoặc tổn thương bệnh lý thường không rõ ràng, có sự khác biệt giữa các chuyên gia, và phụ thuộc mạnh vào từng phương thức hình ảnh như CT, MRI, siêu âm hoặc nội soi.

Chính vì vậy, bên cạnh dữ liệu hình ảnh, các mô hình hiện đại có xu hướng phát triển các cơ chế học dựa trên câu nhắc (*Prompting*) nhằm tận dụng tri thức đa phương thức. Thay vì yêu cầu một lượng lớn nhãn pixel chính xác cho mọi bệnh lý và mọi cơ quan, mô hình có thể khai thác thông tin bổ sung từ văn bản lâm sàng, báo cáo chẩn đoán hoặc mô tả chuyên môn. Cách tiếp cận này giúp thu hẹp khoảng cách giữa dữ liệu hình ảnh và tri thức y khoa, đồng thời hỗ trợ mô hình tập trung vào vùng có ý nghĩa lâm sàng.

Một số mô hình tiêu biểu cho xu hướng này gồm:

- **MedSAM:** Kế thừa khả năng phân đoạn linh hoạt của SAM và sử dụng *câu nhắc trực quan* như điểm hoặc hộp bao để hướng dẫn mô hình tập trung vào vùng giải phẫu hoặc tổn thương cần phân đoạn.

- **LViT:** Tích hợp *câu nhắc văn bản* vào quá trình học biểu diễn, giúp đưa kiến thức bệnh lý và thông tin mô tả lâm sàng vào mô hình phân đoạn, từ đó cải thiện hiệu suất trong điều kiện dữ liệu nhãn còn hạn chế.

Sự hiệu quả của các kiến trúc kết hợp Prompting bắt nguồn từ khả năng thiết lập một không gian biểu diễn chung giữa thị giác và ngôn ngữ thông qua

cơ chế căn chỉnh đa phương thức. Trong không gian này, đặc trưng hình ảnh không còn được xử lý một cách độc lập, mà được điều hướng bởi các khái niệm ngữ nghĩa được cung cấp từ prompt. Nhờ đó, mô hình có thể hình thành một bộ lọc ngữ nghĩa mạnh mẽ, giúp giảm ảnh hưởng của các vùng nhiễu, loại bỏ các cấu trúc không liên quan và tập trung vào những đặc điểm phù hợp với mô tả đầu vào.

Đối với ảnh y khoa, vai trò của ngôn ngữ càng trở nên quan trọng vì nhiều tổn thương không thể được xác định chỉ bằng tên lớp đơn giản. Thay vì chỉ biết đây là "khối u", văn bản có thể cung cấp thêm các đặc điểm hình thái chuyên sâu như *"bờ không đều", "mật độ thấp", "thâm nhiễm xung quanh"* hoặc vị trí tương quan với các cấu trúc giải phẫu lân cận. Những mô tả này giúp mô hình hiểu rõ hơn ngữ cảnh bệnh lý, từ đó đưa ra mặt nạ phân đoạn hợp lý hơn về mặt y khoa.

Do đó, phân đoạn ảnh dựa trên prompt, đặc biệt là prompt văn bản, là một hướng nghiên cứu có ý nghĩa trong việc xây dựng các hệ thống phân đoạn linh hoạt, có khả năng thích ứng với dữ liệu mới và phù hợp hơn với quy trình làm việc thực tế của chuyên gia. Đây cũng là nền tảng quan trọng để phát triển các mô hình hỗ trợ chẩn đoán có tính tương tác, tận dụng đồng thời thông tin thị giác và tri thức chuyên ngành được biểu diễn bằng ngôn ngữ tự nhiên.

1.2 Động lực nghiên cứu

1.2.1 Ý nghĩa khoa học

Sự phát triển của trí tuệ nhân tạo và thị giác máy tính trong nhiều lĩnh vực đã chứng minh vai trò quan trọng của phân đoạn ảnh tự động. Khác với bài toán phân loại ảnh chỉ đưa ra nhãn tổng quát cho toàn bộ ảnh, phân đoạn ảnh yêu cầu mô hình xác định chính xác vùng không gian tương ứng với từng đối tượng hoặc từng cấu trúc quan tâm. Vì vậy, phân đoạn ảnh đóng vai trò nền tảng trong nhiều hệ thống phân tích hình ảnh chuyên sâu, đặc biệt là các hệ thống cần định lượng hình dạng, kích thước, vị trí hoặc mức độ lan rộng của đối tượng như hệ thống xe tự hành, hệ thống giám sát nông nghiệp, hệ thống chỉnh sửa ảnh/video, hệ thống kiểm tra chất lượng sản phẩm, hệ thống phân tích ảnh y tế,...

Tuy nhiên, hiệu quả của các mô hình phân đoạn học sâu phụ thuộc rất lớn vào chất lượng và quy mô của dữ liệu được gán nhãn ở mức pixel. Việc tạo ra các nhãn chuẩn này không chỉ tiêu tốn nhiều chi phí và thời gian, mà còn đòi hỏi sự tham gia trực tiếp của các chuyên gia có kiến thức chuyên môn. Trong y khoa, yêu cầu này càng trở nên nghiêm ngặt hơn vì ranh giới của cơ quan, mô bệnh hoặc tổn thương thường khó xác định, dễ bị ảnh hưởng bởi nhiễu ảnh, độ tương phản thấp và sự khác biệt giữa các thiết bị chụp. Do đó, việc xây dựng các bộ dữ liệu lớn, đa dạng và được chú thích chính xác vẫn là một thách thức lớn.

Về mặt khoa học, hạn chế về dữ liệu nhãn đặt ra nhu cầu nghiên cứu các phương pháp có khả năng học hiệu quả hơn từ ít dữ liệu hơn, đồng thời tận dụng được các nguồn tri thức bổ sung ngoài nhãn pixel truyền thống. Các mô hình dựa trên prompt, đặc biệt là prompt văn bản, cung cấp một hướng tiếp cận tiềm năng cho vấn đề này. Thay vì chỉ học từ cặp ảnh-mặt nạ, mô hình có thể khai thác thêm mô tả ngôn ngữ về đặc điểm hình thái, vị trí giải phẫu hoặc ngữ cảnh bệnh lý của vùng cần phân đoạn.

Động lực chính của nghiên cứu này xuất phát từ việc khai thác nguồn tri thức lâm sàng dồi dào tồn tại dưới dạng ngôn ngữ tự nhiên. Trong thực tế, hình ảnh y khoa hiếm khi được sử dụng một cách độc lập, chúng thường đi kèm với báo cáo chẩn đoán, ghi chú lâm sàng hoặc nhận định của bác sĩ. Những văn bản này chứa đựng các mô tả tinh vi về đặc điểm hình thái và vị trí tổn thương mà nhãn pixel đơn thuần khó có thể truyền tải đầy đủ. Ví dụ, cùng là một vùng bất thường, mô tả bằng ngôn ngữ có thể bổ sung thông tin về mức độ lan rộng, bờ tổn thương, mật độ, cấu trúc lân cận hoặc dấu hiệu xâm lấn.

Việc phát triển các kiến trúc hướng văn bản vì thế không chỉ là một cải tiến kỹ thuật, mà còn là một nỗ lực nhằm đưa tri thức chuyên ngành vào quá trình học biểu diễn của mô hình. Khi mô hình có khả năng liên kết đặc trưng thị giác với mô tả ngôn ngữ, nó có thể hình thành biểu diễn giàu ngữ nghĩa hơn, giảm phụ thuộc vào tập nhãn cố định và cải thiện khả năng tổng quát hóa sang các bệnh lý, cơ quan hoặc miền dữ liệu mới. Đây là một hướng nghiên cứu quan trọng để thu hẹp khoảng cách giữa học máy thuần dữ liệu và tri thức chuyên gia trong các bài toán phân đoạn y khoa.

1.2.2 Ý nghĩa thực tiễn

Về mặt thực tiễn, nghiên cứu này được thúc đẩy bởi nhu cầu xây dựng một hệ thống AI có tính tương tác, linh hoạt và phù hợp hơn với quy trình làm việc của chuyên gia. Trong nhiều ứng dụng lâm sàng, người dùng không chỉ cần một mô hình đưa ra kết quả cố định, mà còn cần khả năng điều chỉnh vùng quan tâm theo mục tiêu phân tích cụ thể. Sự hỗ trợ của prompt văn bản cho phép chuyên gia mô tả trực tiếp đối tượng cần phân đoạn bằng ngôn ngữ tự nhiên, từ đó tạo ra một cơ chế giao tiếp trực quan hơn giữa người và máy.

Cách tiếp cận này giúp giảm tính chất "hộp đen" của mô hình phân đoạn. Thay vì chỉ nhận ảnh đầu vào và trả về một mặt nạ duy nhất, hệ thống có thể thay đổi kết quả dựa trên câu lệnh mô tả của người dùng. Ví dụ, chuyên gia có thể yêu cầu mô hình tập trung vào một loại tổn thương cụ thể, một vùng giải phẫu nhất định hoặc một đặc điểm bệnh lý quan trọng. Điều này tạo nên một vòng lặp, trong đó bác sĩ hoặc nhà nghiên cứu có thể định hướng mô hình, kiểm tra kết quả và điều chỉnh prompt để đạt được mặt nạ phù hợp hơn với mục tiêu sử dụng.

Bên cạnh đó, phân đoạn dựa trên văn bản có tiềm năng hỗ trợ giải quyết bài toán thiếu hụt dữ liệu nhãn trong thực tế. Đối với các bệnh lý hiếm, các cơ quan ít được nghiên cứu hoặc các thiết bị hình ảnh mới, việc thu thập đủ dữ liệu có nhãn để huấn luyện lại mô hình từ đầu thường không khả thi. Nếu mô hình có thể tận dụng mô tả văn bản để thích nghi với đối tượng mới, quá trình triển khai sẽ trở nên nhanh hơn, ít tốn kém hơn và linh hoạt hơn so với các phương pháp phân đoạn truyền thống.

Ngoài y khoa, hướng tiếp cận này cũng có ý nghĩa đối với các lĩnh vực cần phân đoạn theo ngữ cảnh, chẳng hạn như ảnh viễn thám, kiểm tra công nghiệp hoặc phân tích ảnh khoa học. Trong các lĩnh vực này, đối tượng quan tâm có thể thay đổi tùy theo nhiệm vụ, trong khi việc xây dựng bộ nhãn đầy đủ cho mọi trường hợp là rất khó khăn. Prompt văn bản giúp mô hình tiếp nhận yêu cầu ở mức ngữ nghĩa, từ đó mở rộng khả năng ứng dụng mà không cần thiết kế lại toàn bộ hệ thống.

Do đó, nghiên cứu về phân đoạn ảnh dựa trên text prompt có ý nghĩa thực tiễn trong việc phát triển các công cụ hỗ trợ ra quyết định, tăng khả năng cá nhân hóa phân tích và cải thiện hiệu quả tương tác giữa chuyên gia và hệ thống

AI. Nếu được thiết kế phù hợp, mô hình không chỉ đóng vai trò là một bộ phân đoạn tự động, mà còn có thể trở thành một trợ lý thông minh hỗ trợ chuyên gia trong quá trình quan sát, định vị và phân tích các vùng quan trọng trên ảnh.

1.3 Đóng góp

Mục tiêu của báo cáo này là tìm hiểu, phân tích và tái hiện mô hình LViT được đề xuất trong công trình gốc cho bài toán phân đoạn ảnh y khoa có điều kiện theo câu nhắc văn bản. Thay vì chỉ trình bày lại mô hình ở mức tổng quan, báo cáo tập trung làm rõ cách các thành phần thị giác và ngôn ngữ được kết hợp trong kiến trúc, cách dữ liệu được xử lý qua từng nhánh, cũng như vai trò của các hàm mất mát trong quá trình huấn luyện.

Các đóng góp chính của báo cáo có thể được tóm tắt như sau:

- **Hệ thống hóa cơ sở lý thuyết của bài toán phân đoạn dựa trên câu nhắc văn bản:** Báo cáo trình bày bối cảnh của phân đoạn ảnh y khoa, hạn chế của các mô hình phân đoạn khép kín và động lực sử dụng thông tin ngôn ngữ như một tín hiệu điều kiện cho mô hình. Từ đó, báo cáo làm rõ vì sao việc kết hợp ảnh và văn bản có ý nghĩa trong các bài toán y khoa, nơi mô tả lâm sàng và vị trí tổn thương đóng vai trò quan trọng.

- **Phân tích chi tiết kiến trúc LViT:** Báo cáo giải thích các thành phần chính của mô hình, bao gồm nhánh CNN U-shape, nhánh ViT U-shape, bộ mã hóa văn bản, Patch Embedding, Reconstruct, PLAM và cơ chế kết hợp đặc trưng ảnh-văn bản. Phần phân tích không chỉ mô tả vai trò riêng của từng mô-đun, mà còn làm rõ cách các mô-đun phối hợp để vừa giữ thông tin cục bộ, vừa khai thác ngữ cảnh toàn cục và tín hiệu ngôn ngữ.

- **Làm rõ quy trình huấn luyện và suy luận của mô hình:** Báo cáo trình bày các pipeline huấn luyện ngoại tuyến, suy luận sau huấn luyện và tính toán hàm mất mát. Trong đó, các thành phần như Dice loss, Cross-Entropy, Language-Vision Loss và cơ chế sinh nhãn giả EPI được

giải thích nhằm làm rõ cách LViT học từ dữ liệu có nhãn, dữ liệu không nhãn và câu nhắc văn bản.

- **Tái hiện và điều chỉnh cài đặt trong môi trường thực nghiệm hiện tại:** Báo cáo mô tả quá trình chuẩn bị dữ liệu, thiết lập môi trường Kaggle, cấu hình siêu tham số và các điều chỉnh kỹ thuật cần thiết để mã nguồn có thể chạy với phiên bản thư viện mới. Các thay đổi này giúp tái lập luồng xử lý chính của LViT trong điều kiện tài nguyên và dữ liệu hiện có.

- **Đánh giá mô hình trên các tập dữ liệu y khoa tương ứng:** Báo cáo hướng đến việc thử nghiệm mô hình trên các bộ dữ liệu QaTa-COV19-v2 và MosMedData+, sử dụng các độ đo Dice score và mIoU để đánh giá chất lượng mặt nạ phân đoạn. Việc đánh giá này giúp kiểm tra khả năng tái hiện mô hình và cung cấp cơ sở so sánh với các kết quả được báo cáo trong công trình gốc.

Thông qua các nội dung trên, báo cáo không chỉ đóng vai trò là một bản tái hiện thực nghiệm của LViT, mà còn cung cấp một phân tích có hệ thống về cách mô hình phân đoạn ảnh y khoa có thể tận dụng thông tin ngôn ngữ để định hướng quá trình dự đoán mặt nạ.

1.4 Phát biểu bài toán

Phân đoạn ảnh là bài toán xác định và gán nhãn cho từng pixel trong ảnh sao cho các pixel thuộc cùng một đối tượng hoặc cùng một vùng ngữ nghĩa được nhóm lại với nhau, đồng thời được tách biệt khỏi các vùng không liên quan. Khác với phân loại ảnh, nơi mô hình chỉ cần dự đoán một nhãn cho toàn bộ ảnh, phân đoạn ảnh yêu cầu kết quả ở mức không gian chi tiết hơn, tức là mỗi vị trí pixel đều cần được xác định thuộc về nền, đối tượng quan tâm hoặc một lớp cụ thể nào đó.

Có thể hiểu một cách trực quan, phân đoạn ảnh là quá trình học một tiêu chí phân biệt giữa các vùng ảnh. Tiêu chí này có thể được biểu diễn thông qua việc làm giảm một *khoảng cách được định nghĩa trước* giữa các pixel có cùng ý nghĩa ngữ nghĩa, đồng thời làm tăng *khoảng cách* giữa các pixel thuộc các đối

tượng hoặc vùng khác nhau. Trong các mô hình học sâu, tiêu chí này thường không được thiết kế thủ công, mà được học thông qua các biểu diễn đặc trưng nhiều tầng của ảnh.

Trong phạm vi phân đoạn ảnh với câu nhắc văn bản, khác với phân đoạn ảnh truyền thống, mô hình không chỉ nhận ảnh đầu vào mà còn nhận thêm một mô tả bằng ngôn ngữ tự nhiên. Câu nhắc văn bản đóng vai trò chỉ định đối tượng, cơ quan, tổn thương hoặc vùng ngữ nghĩa mà người dùng muốn mô hình phân đoạn. Do đó, cùng một ảnh đầu vào có thể cho ra các mặt nạ khác nhau nếu câu nhắc văn bản thay đổi.

Với các mô hình phân đoạn kết hợp câu nhắc văn bản, có thể định nghĩa bài toán như sau:

- **Đầu vào:**

  Một ảnh kích thước $H \times W$ được xem như một hàm số ánh xạ từ miền tọa độ pixel sang không gian giá trị cường độ hoặc màu sắc:

  $$I : \Omega \to \mathbb{R}^C$$

  trong đó:

  $$\Omega = \{(x, y) \mid 1 \leq x \leq H, 1 \leq y \leq W\}, \quad C \in \mathbb{N}^*$$

  Mỗi điểm $(x, y) \in \Omega$ tương ứng với một vị trí pixel trong ảnh.

  Câu nhắc văn bản được biểu diễn dưới dạng một chuỗi các token:

  $$T = \{w_1, w_2, \cdots, w_L\}$$

  trong đó L là độ dài của câu nhắc sau khi được tách token. Nội dung của T mô tả vùng mục tiêu cần phân đoạn, ví dụ như tên cơ quan, loại tổn thương, đặc điểm hình thái hoặc vị trí giải phẫu.

- **Đầu ra:**

  Đầu ra trung gian của mô hình thường là một bản đồ xác suất $\mathbf{P}$ có cùng kích thước không gian với ảnh đầu vào $H \times W$. Tại mỗi vị trí pixel, giá

trị xác suất thể hiện mức độ tin cậy của mô hình rằng pixel đó thuộc về vùng mục tiêu được mô tả bởi câu nhắc văn bản.

- Đối với phân đoạn nhị phân, mỗi pixel được gán một giá trị thực trong đoạn $[0, 1]$, thể hiện xác suất pixel thuộc về foreground (tiền cảnh) hoặc background (hậu cảnh) đối với vùng mục tiêu.
- Đối với phân đoạn đa lớp, mỗi pixel được gán một vector xác suất kích thước $n \times 1$, trong đó mỗi phần tử nằm trong đoạn $[0, 1]$ và tổng các phần tử bằng 1. Phần tử thứ i thể hiện xác suất pixel thuộc về lớp thứ i, với $i = 1, 2, \ldots, n$.

Từ bản đồ xác suất, mặt nạ phân đoạn cuối cùng M được suy ra bằng cách áp dụng một quy tắc quyết định. Với phân đoạn nhị phân, cho một ngưỡng α cho trước, mặt nạ M là một ma trận gồm các giá trị 0 và 1, trong đó 1 biểu thị pixel thuộc vùng mục tiêu và 0 biểu thị pixel không thuộc vùng mục tiêu:

$$M(x, y) = \begin{cases} 1 & \text{nếu } P(x, y) > \alpha \\ 0 & \text{nếu ngược lại} \end{cases}$$

Có thể diễn giải tương đương rằng:

$$M(x, y) = \begin{cases} 1 & \text{nếu } (x, y) \in \text{vùng mục tiêu được chỉ định bởi } T \\ 0 & \text{nếu ngược lại} \end{cases}$$

Với phân đoạn đa lớp, mặt nạ phân đoạn M chứa các giá trị i, $i = 1, 2, \ldots, n$, tương ứng với lớp có xác suất lớn nhất tại từng pixel:

$$M(x, y) = \arg\max_i \mathbf{P}(x, y) = \arg\max_i \{P_1(x, y), P_2(x, y), \ldots, P_n(x, y)\}$$

Từ các định nghĩa trên, bài toán phân đoạn dựa trên văn bản có thể được phát biểu là tìm kiếm một ánh xạ F sao cho:

$$F : (I, T) \to M$$

Trong đó, I cung cấp thông tin thị giác, T cung cấp điều kiện ngữ nghĩa, và M là mặt nạ phân đoạn phù hợp với nội dung được mô tả trong câu nhắc. Mục tiêu của mô hình là học được ánh xạ này sao cho mặt nạ sinh ra vừa chính xác về mặt hình học, vừa nhất quán với ý nghĩa ngôn ngữ của prompt.

Quy trình tổng quát của các mô hình phân đoạn dựa trên câu nhắc văn bản thường gồm bốn thành phần chính: một bộ mã hóa ảnh, một bộ mã hóa văn bản, một cơ chế đưa đặc trưng về không gian biểu diễn chung và một bộ giải mã mặt nạ. Các thành phần này phối hợp với nhau để kết hợp thông tin thị giác và thông tin ngôn ngữ trước khi tạo ra mặt nạ phân đoạn cuối cùng.

1. **Trích xuất đặc trưng thị giác (E_v):** Bộ mã hóa ảnh biến đổi ảnh đầu vào thành một tensor đặc trưng trong không gian d chiều. Tensor này lưu giữ thông tin về cấu trúc không gian, biên, hình dạng và ngữ cảnh của các vùng trong ảnh.

   $$f_v = E_v(I) \in \mathbb{R}^{h \times w \times d}$$

   Trong đó h và w là kích thước không gian của bản đồ đặc trưng sau khi ảnh đi qua bộ mã hóa.

2. **Trích xuất đặc trưng ngôn ngữ (E_l):** Bộ mã hóa văn bản biến đổi chuỗi token T thành các vector đặc trưng ngôn ngữ. Các vector này biểu diễn ý nghĩa của câu nhắc, bao gồm tên đối tượng, thuộc tính mô tả và các ràng buộc ngữ cảnh.

   $$f_l = E_l(T) \in \mathbb{R}^{L \times d'}$$

   Trong đó d' là số chiều của không gian đặc trưng ngôn ngữ.

3. **Đưa các đặc trưng về không gian nhúng chung D:** Do đặc trưng ảnh và đặc trưng văn bản thường nằm trong hai không gian khác nhau, cần có các phép chiếu học được để đưa chúng về cùng một không gian biểu diễn. Việc này giúp mô hình so khớp và tương tác giữa hai phương thức một cách hiệu quả hơn.

   - Ảnh:

   $$z_v = f_v \cdot \boldsymbol{W_v} + b_v, \quad \boldsymbol{W_v} \in \mathbb{R}^{d \times D}, b_v \in \mathbb{R}^D, \quad z_v \in \mathbb{R}^{(h \times w) \times D}$$

- Văn bản:

$$z_l = f_l \cdot \boldsymbol{W_l} + b_l, \quad \boldsymbol{W_l} \in \mathbb{R}^{d' \times D}, b_l \in \mathbb{R}^D, \quad z_l \in \mathbb{R}^{L \times D}$$

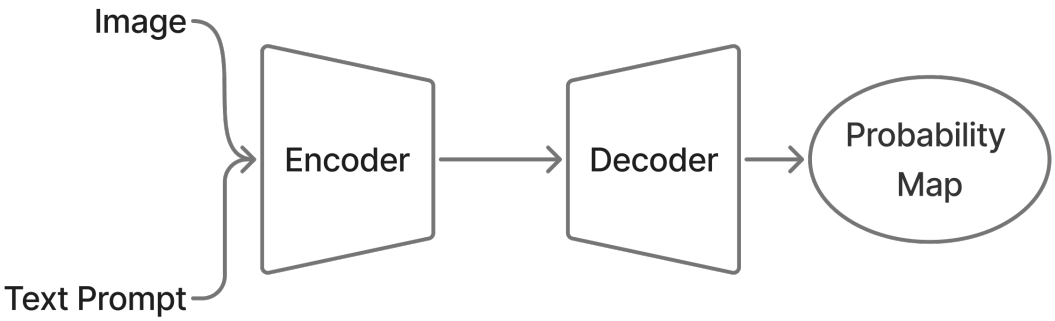
4. **Tương tác đa phương thức và giải mã mặt nạ (ϕ, P):** Sau khi được đưa về cùng không gian nhúng, đặc trưng hình ảnh và đặc trưng văn bản được kết hợp thông qua một hàm tương tác ϕ. Hàm này có thể được hiện thực bằng nhiều cơ chế khác nhau, chẳng hạn như attention, cross-attention, tích vô hướng tương đồng hoặc các khối hợp nhất đặc trưng. Mục tiêu của bước này là làm giàu đặc trưng thị giác bằng thông tin ngữ nghĩa từ câu nhắc văn bản.

$$f_u = \phi(z_v, z_l), \quad f_u \in \mathbb{R}^{(h \times w) \times D}$$

Từ đặc trưng hợp nhất f_u, bộ giải mã tạo ra bản đồ xác suất $P(f_u)$. Với bài toán nhị phân, mặt nạ cuối cùng được xác định bằng ngưỡng α:

$$M = \begin{cases} 1 & \text{nếu } P(f_u) > \alpha \\ 0 & \text{nếu ngược lại} \end{cases}$$

Như vậy, khác với mô hình phân đoạn truyền thống chỉ học ánh xạ từ ảnh sang mặt nạ, mô hình phân đoạn dựa trên văn bản học ánh xạ có điều kiện từ cặp ảnh–văn bản sang mặt nạ. Điều này giúp mô hình linh hoạt hơn, vì vùng cần phân đoạn không còn bị cố định bởi một tập lớp huấn luyện duy nhất mà có thể được điều khiển thông qua câu nhắc của người dùng.



Hình 1.1: Pipeline chung của mô hình phân đoạn dựa trên ảnh và text prompt

Chương 2

Các công trình nghiên cứu liên quan

2.1 Phân đoạn ảnh y khoa truyền thống

Phân đoạn ảnh y khoa là một bài toán quan trọng trong phân tích ảnh y tế, với mục tiêu xác định chính xác vùng cơ quan, tổn thương hoặc bất thường bệnh lý trên ảnh. Trong các hệ thống hỗ trợ chẩn đoán, kết quả phân đoạn có thể giúp bác sĩ định lượng kích thước tổn thương, theo dõi tiến triển bệnh và lập kế hoạch điều trị. Vì vậy, yêu cầu đối với mô hình phân đoạn ảnh y khoa không chỉ là dự đoán đúng vùng quan tâm, mà còn cần giữ được ranh giới không gian ở mức chi tiết.

Các mô hình học sâu ban đầu cho phân đoạn ảnh y khoa chủ yếu dựa trên mạng nơ-ron tích chập (Convolutional Neural Networks – CNNs). Những kiến trúc như FCN, U-Net và UNet++ đã trở thành nền tảng phổ biến nhờ khả năng trích xuất đặc trưng cục bộ và khôi phục bản đồ phân đoạn ở độ phân giải cao [1]. Đặc biệt, kiến trúc dạng encoder–decoder với các kết nối tắt giúp mô hình vừa học được đặc trưng ngữ nghĩa sâu, vừa giữ lại thông tin không gian từ các tầng nông.

Tuy nhiên, các phương pháp dựa trên CNN vẫn tồn tại một số hạn chế. Thứ nhất, phạm vi tiếp nhận cục bộ của phép tích chập khiến mô hình khó nắm bắt đầy đủ quan hệ toàn cục trong ảnh, nhất là khi vùng tổn thương có hình dạng phức tạp hoặc xuất hiện rải rác. Thứ hai, hiệu quả của mô hình phụ thuộc mạnh vào số lượng và chất lượng mặt nạ gán nhãn. Trong y khoa, việc tạo nhãn pixel-level thường tốn nhiều thời gian, cần chuyên gia có kinh nghiệm và dễ có sai khác giữa các người gán nhãn [1]. Do đó, dù các mô hình CNN đạt hiệu quả tốt trong nhiều thiết lập có giám sát, khả năng mở rộng sang dữ liệu mới hoặc môi trường lâm sàng thực tế vẫn bị giới hạn.

Sự xuất hiện của Vision Transformer mở ra hướng tiếp cận mới cho phân đoạn ảnh nhờ khả năng mô hình hóa quan hệ dài hạn giữa các vùng ảnh. Transformer có thể xem ảnh như một chuỗi token và học sự phụ thuộc toàn cục thông qua cơ chế self-attention. Tuy vậy, trong ảnh y khoa, chỉ sử dụng Transformer thuần túy có thể làm mất một phần chi tiết cục bộ quan trọng ở biên tổn thương. Vì vậy, nhiều nghiên cứu gần đây có xu hướng kết hợp CNN và Transformer để tận dụng đồng thời khả năng giữ chi tiết cục bộ của CNN và khả năng mô hình hóa ngữ cảnh toàn cục của Transformer.

2.2 Học bán giám sát trong phân đoạn ảnh y khoa

Một trong những thách thức lớn nhất của phân đoạn ảnh y khoa là sự khan hiếm dữ liệu có nhãn. Khác với ảnh tự nhiên, nơi dữ liệu chú thích có thể được thu thập ở quy mô lớn, dữ liệu y khoa thường bị giới hạn bởi quyền riêng tư, chi phí thu thập và yêu cầu chuyên môn khi gán nhãn. Điều này thúc đẩy các phương pháp học bán giám sát, trong đó mô hình học từ một phần nhỏ dữ liệu có nhãn và một lượng lớn dữ liệu không nhãn.

Các phương pháp bán giám sát thường khai thác ý tưởng rằng dữ liệu không nhãn vẫn chứa thông tin về phân bố ảnh. Một số hướng tiếp cận phổ biến gồm tạo nhãn giả, ràng buộc tính nhất quán giữa các dự đoán, hoặc sử dụng nhiều mô hình/nhánh dự đoán để kiểm tra lẫn nhau. Trong bối cảnh được tổng hợp bởi LViT, các phương pháp như DTC, PLCT và MC-Net+ được xem là những đại diện cho xu hướng tận dụng dữ liệu không nhãn nhằm giảm phụ thuộc vào mặt nạ thủ công [1].

Tuy nhiên, học bán giám sát trong ảnh y khoa cũng có rủi ro riêng. Nếu nhãn giả có chất lượng thấp, mô hình có thể học lại các dự đoán sai và làm suy giảm hiệu quả tổng quát hóa. Vấn đề này đặc biệt nghiêm trọng khi vùng tổn thương nhỏ, ranh giới mờ hoặc dữ liệu có sự khác biệt lớn giữa các ca bệnh. Do đó, một quy trình bán giám sát hiệu quả cần kiểm soát chất lượng nhãn giả và cập nhật nhãn giả một cách ổn định trong quá trình huấn luyện.

Trong công trình LViT, Li và cộng sự đề xuất cơ chế Exponential Pseudo label Iteration (EPI) nhằm cải thiện chất lượng nhãn giả trong thiết lập bán giám sát [1]. Thay vì sử dụng trực tiếp nhãn giả từ một bước dự đoán đơn lẻ, EPI cập nhật nhãn giả theo hướng lặp lại và làm ổn định quá trình học. Cơ

chế này giúp giảm tác động của các dự đoán nhiễu, đồng thời hỗ trợ mô hình khai thác dữ liệu không nhãn hiệu quả hơn. Đây là một thành phần quan trọng để LViT đạt kết quả cạnh tranh ngay cả khi chỉ sử dụng một phần dữ liệu có nhãn.

2.3 Phân đoạn ảnh theo tham chiếu ngôn ngữ

Phân đoạn ảnh theo tham chiếu ngôn ngữ (Referring Image Segmentation – RIS) là bài toán phân đoạn đối tượng hoặc vùng ảnh được mô tả bởi một câu văn bản tự nhiên. Khác với phân đoạn ngữ nghĩa truyền thống, trong đó các lớp cần phân đoạn được định nghĩa cố định, RIS cho phép người dùng chỉ định vùng quan tâm bằng ngôn ngữ. Do đó, cùng một ảnh có thể tạo ra các mặt nạ khác nhau tùy thuộc vào nội dung câu mô tả.

Trên ảnh tự nhiên, nhiều phương pháp RIS ban đầu thường trích xuất đặc trưng ảnh và đặc trưng văn bản bằng hai bộ mã hóa riêng biệt, sau đó dung hợp chúng ở giai đoạn giải mã. Cách tiếp cận này có ưu điểm là dễ thiết kế theo kiến trúc modular, nhưng việc dung hợp muộn có thể làm hạn chế mức độ tương tác sâu giữa token văn bản và đặc trưng thị giác. LAVT được đề xuất để giải quyết hạn chế này bằng cách đưa cơ chế tương tác ngôn ngữ–thị giác vào sớm trong bộ mã hóa Vision Transformer [2]. Cụ thể, mô hình sử dụng Pixel-Word Attention Module (PWAM) để cho phép đặc trưng ảnh tương tác với đặc trưng từ ngay trong quá trình mã hóa, từ đó tạo ra biểu diễn đa phương thức giàu ngữ cảnh hơn.

Ý tưởng của LAVT cho thấy tầm quan trọng của việc dung hợp sớm giữa ảnh và văn bản. Khi đặc trưng thị giác được điều hướng bởi câu mô tả ngay từ các tầng mã hóa, mô hình có thể tập trung tốt hơn vào đối tượng được nhắc đến, thay vì phải dựa vào bộ giải mã để kết hợp hai nguồn thông tin ở giai đoạn muộn. Đây là một hướng tiếp cận có ảnh hưởng đến các mô hình phân đoạn có điều kiện theo ngôn ngữ sau này, trong đó bao gồm cả các mô hình ứng dụng cho ảnh y khoa.

2.4 Phân đoạn ảnh y khoa có tham chiếu văn bản

Khi chuyển từ ảnh tự nhiên sang ảnh y khoa, bài toán phân đoạn theo tham chiếu ngôn ngữ trở nên khó hơn. Ảnh y khoa thường có độ tương phản thấp, ranh giới tổn thương không rõ, cấu trúc giải phẫu phức tạp và sự khác biệt lớn giữa các phương thức ảnh như X-ray, CT hoặc MRI. Ngoài ra, mô tả văn bản trong y khoa không chỉ gọi tên đối tượng, mà còn có thể chứa thông tin về vị trí, mức độ, phạm vi và đặc điểm bệnh lý.

LViT là một trong những công trình tiêu biểu đưa thông tin văn bản vào phân đoạn ảnh y khoa [1]. Mô hình được thiết kế theo hướng kết hợp kiến trúc CNN và Transformer, đồng thời sử dụng văn bản như một nguồn tín hiệu bổ sung để định hướng quá trình phân đoạn. Trong LViT, thông tin ảnh được xử lý qua các nhánh thị giác nhằm giữ đặc trưng không gian, trong khi thông tin văn bản được mã hóa và đưa vào quá trình học biểu diễn. Pixel-Level Attention Module (PLAM) giúp mô hình bảo toàn đặc trưng cục bộ, còn Language-Vision loss hỗ trợ khai thác thông tin văn bản trong thiết lập có dữ liệu không nhãn.

Điểm đáng chú ý của LViT là mô hình không chỉ sử dụng văn bản trong giai đoạn suy luận, mà còn đưa văn bản vào quá trình huấn luyện để cải thiện chất lượng biểu diễn. Với ảnh y khoa, chú thích văn bản có thể cung cấp tín hiệu ngữ nghĩa quan trọng về vùng bệnh lý, đặc biệt khi mặt nạ phân đoạn không đầy đủ hoặc số lượng nhãn bị giới hạn. Vì vậy, LViT có thể được xem là cầu nối giữa phân đoạn ảnh y khoa truyền thống và các mô hình phân đoạn đa phương thức dựa trên ngôn ngữ.

Tuy nhiên, LViT giả định rằng chú thích văn bản đi kèm ảnh là tương đối đầy đủ. Trong thực tế lâm sàng, báo cáo hoặc mô tả y khoa có thể thiếu một số thuộc tính quan trọng, chẳng hạn như vị trí, phạm vi hoặc số lượng tổn thương. ARSeg được đề xuất nhằm xử lý vấn đề này trong bài toán Medical Image Referring Segmentation (MIRS) [3]. Mô hình xây dựng các đặc trưng đặc thù theo thuộc tính và sử dụng cơ chế tương tác chéo đa phương thức để giảm sự phụ thuộc vào văn bản đầy đủ. Ngoài ra, các hàm mất mát cân bằng thuộc tính được thiết kế để tránh việc mô hình thiên lệch về những thuộc tính xuất hiện thường xuyên hơn.

So với LViT, ARSeg nhấn mạnh tính bền vững của mô hình khi prompt văn bản bị thiếu hoặc mất cân bằng. Đây là một hướng mở rộng quan trọng, bởi

dữ liệu y khoa thực tế thường không có cấu trúc hoàn hảo như trong bộ dữ liệu chuẩn. Nhìn chung, LViT tập trung vào việc chứng minh hiệu quả của việc đưa văn bản vào phân đoạn ảnh y khoa, còn ARSeg mở rộng vấn đề sang bối cảnh văn bản không hoàn chỉnh và gần hơn với thực tế lâm sàng.

2.5 Phân đoạn linh hoạt theo prompt và thế giới mở

Bên cạnh các mô hình phân đoạn y khoa có điều kiện theo văn bản, một nhánh nghiên cứu khác hướng đến khả năng phân đoạn linh hoạt trong giai đoạn suy luận. Thay vì huấn luyện mô hình cho một tập lớp cố định, các phương pháp này cho phép mô hình nhận prompt dưới nhiều dạng khác nhau, chẳng hạn như văn bản, ảnh ví dụ, hộp bao hoặc điểm gợi ý.

CLIPSeg là một ví dụ tiêu biểu cho hướng phân đoạn dựa trên prompt [4]. Công trình này mở rộng mô hình CLIP bằng một bộ giải mã Transformer để tạo bản đồ phân đoạn từ prompt văn bản hoặc ảnh ví dụ. Nhờ sử dụng không gian biểu diễn chung của CLIP, CLIPSeg có thể thực hiện nhiều tác vụ như referring expression segmentation, zero-shot segmentation và one-shot segmentation trong cùng một mô hình. Điểm mạnh của hướng tiếp cận này là tính linh hoạt: người dùng có thể mô tả vùng cần phân đoạn bằng ngôn ngữ tự nhiên hoặc cung cấp một ảnh tham chiếu thay vì phải huấn luyện lại mô hình cho từng lớp mới.

Grounded SAM tiếp tục mở rộng ý tưởng phân đoạn thế giới mở bằng cách kết hợp nhiều mô hình nền tảng [5]. Trong pipeline này, Grounding DINO được sử dụng để phát hiện vùng ảnh tương ứng với văn bản đầu vào, sau đó các hộp giới hạn được dùng làm prompt cho Segment Anything Model (SAM) để sinh mặt nạ phân đoạn. Cách kết hợp này tận dụng thế mạnh riêng của từng mô hình: Grounding DINO có khả năng định vị đối tượng theo từ vựng mở, còn SAM có khả năng tạo mặt nạ chất lượng cao từ prompt trực quan.

Mặc dù CLIPSeg và Grounded SAM chủ yếu được phát triển cho ảnh tự nhiên hoặc bối cảnh tổng quát, các công trình này cho thấy xu hướng quan trọng của lĩnh vực phân đoạn: mô hình ngày càng ít phụ thuộc vào tập nhãn cố định và ngày càng tương tác nhiều hơn với prompt. Đối với ảnh y khoa, xu hướng này gợi mở khả năng xây dựng các hệ thống phân đoạn linh hoạt, trong đó bác sĩ có thể chỉ định vùng quan tâm bằng văn bản hoặc gợi ý trực quan.

Tuy nhiên, việc chuyển các mô hình thế giới mở sang y khoa vẫn cần xử lý khác biệt miền dữ liệu, tiêu chuẩn an toàn và độ chính xác lâm sàng.

2.6 Học biểu diễn đa phương thức ảnh–văn bản trong y khoa

Một hướng nghiên cứu liên quan mật thiết đến LViT là học biểu diễn đa phương thức giữa ảnh y khoa và văn bản y khoa. Thay vì chỉ huấn luyện mô hình cho một tác vụ phân đoạn cụ thể, các phương pháp này thường tiền huấn luyện bộ mã hóa ảnh và văn bản trên các cặp ảnh–báo cáo, sau đó chuyển giao biểu diễn đã học sang các tác vụ như phân loại, truy hồi, hỏi đáp, sinh báo cáo hoặc phân đoạn.

MedViLL là một công trình tiêu biểu trong hướng tiền huấn luyện thị giác–ngôn ngữ cho y khoa [6]. Mô hình sử dụng kiến trúc dựa trên BERT kết hợp cơ chế attention đa phương thức để học từ ảnh X-quang và báo cáo không cấu trúc. Thông qua các mục tiêu tiền huấn luyện đa phương thức, MedViLL hướng đến việc cải thiện hiệu quả trên nhiều tác vụ hạ nguồn như phân loại chẩn đoán, truy hồi ảnh–báo cáo, hỏi đáp y khoa và sinh báo cáo. Công trình này cho thấy văn bản y khoa không chỉ là chú thích phụ trợ, mà còn có thể đóng vai trò quan trọng trong việc hình thành biểu diễn thị giác có ý nghĩa lâm sàng.

MGCA tiếp cận bài toán học biểu diễn đa phương thức ở mức chi tiết hơn bằng cách căn chỉnh ảnh và báo cáo X-quang ở nhiều cấp độ [7]. Cụ thể, mô hình xem xét sự tương ứng giữa ảnh và văn bản ở cấp độ bệnh lý, cấp độ instance và cấp độ token/vùng cục bộ. Cách căn chỉnh đa hạt này giúp bộ mã hóa hình ảnh học được cả ngữ nghĩa tổng thể lẫn chi tiết cục bộ liên quan đến bệnh lý. Khi chuyển sang các tác vụ hạ nguồn, đặc biệt là phân đoạn ngữ nghĩa, biểu diễn đã được tiền huấn luyện có thể giúp mô hình đạt hiệu quả tốt hơn ngay cả khi số lượng dữ liệu tinh chỉnh bị hạn chế.

Các công trình như MedViLL và MGCA cung cấp nền tảng quan trọng cho các mô hình phân đoạn đa phương thức. Nếu LViT khai thác văn bản trực tiếp trong kiến trúc phân đoạn, thì các mô hình tiền huấn luyện đa phương thức tập trung vào việc học không gian biểu diễn chung trước khi áp dụng vào tác vụ

hạ nguồn. Hai hướng tiếp cận này có thể bổ sung cho nhau: biểu diễn ảnh–văn bản được tiền huấn luyện tốt có thể cải thiện chất lượng đặc trưng đầu vào, trong khi kiến trúc phân đoạn như LViT giúp tận dụng trực tiếp tín hiệu văn bản ở cấp độ pixel.

2.7 Tổng kết

Các công trình liên quan cho thấy phân đoạn ảnh y khoa đang chuyển từ các mô hình có giám sát dựa trên ảnh đơn thuần sang các mô hình linh hoạt hơn, có khả năng tận dụng dữ liệu không nhãn và thông tin ngôn ngữ. Các mô hình CNN như U-Net đặt nền móng cho phân đoạn ảnh y khoa nhờ khả năng giữ chi tiết không gian, trong khi Transformer giúp mở rộng khả năng mô hình hóa quan hệ toàn cục. Học bán giám sát giải quyết phần nào vấn đề thiếu dữ liệu gán nhãn, nhưng cần kiểm soát chất lượng nhãn giả để tránh lan truyền sai số.

Trong bối cảnh phân đoạn theo văn bản, LAVT chứng minh hiệu quả của dung hợp sớm giữa ảnh và ngôn ngữ trên ảnh tự nhiên, còn LViT đưa ý tưởng này vào ảnh y khoa bằng cách kết hợp kiến trúc CNN–Transformer, chú thích văn bản, PLAM, Language-Vision loss và EPI [2, 1]. Các hướng mở rộng như ARSeg cho thấy cần quan tâm đến tính không đầy đủ của prompt trong thực tế lâm sàng [3]. Song song với đó, CLIPSeg, Grounded SAM, MedViLL và MGCA cho thấy tiềm năng của prompt, mô hình nền tảng và học biểu diễn đa phương thức trong việc xây dựng các hệ thống phân đoạn linh hoạt hơn [4, 5, 6, 7].

Từ các phân tích trên, có thể thấy LViT là một công trình phù hợp với xu hướng kết hợp thị giác và ngôn ngữ cho phân đoạn ảnh y khoa. Mô hình vừa kế thừa ưu điểm của các kiến trúc phân đoạn truyền thống, vừa khai thác văn bản và dữ liệu không nhãn để cải thiện hiệu quả trong điều kiện dữ liệu y khoa hạn chế. Đây cũng là lý do báo cáo lựa chọn LViT làm đối tượng chính để phân tích, tái hiện và đánh giá trong các chương tiếp theo.

Chương 3

Phương pháp

3.1 Dữ liệu

Mô hình LViT trong báo cáo này được huấn luyện và kiểm thử trên ba tập dữ liệu y khoa có đi kèm mặt nạ phân đoạn và mô tả tổn thương. Các bộ dữ liệu này khác nhau về loại ảnh, số lượng mẫu và cách xây dựng chú thích văn bản, nhưng đều phục vụ chung cho bài toán phân đoạn tổn thương dựa trên thông tin thị giác và ngôn ngữ.

3.1.1 Mô tả các bộ dữ liệu

1. **QaTa-COV19-v2:**[1] bao gồm 9258 ảnh X-ray ngực được ghi chú thủ công các thương tổn do COVID-19. Nhóm nghiên cứu đã mở rộng phần chú thích với sự hỗ trợ của các chuyên gia. Nội dung chú thích tập trung vào tình trạng nhiễm bệnh ở một hoặc hai phổi, số lượng vùng thương tổn và vị trí tương đối của các vùng nhiễm bệnh. Ví dụ: "Bilateral pulmonary infection, two infected areas, upper left lung and upper right lung" (tạm dịch: "Nhiễm trùng phổi hai bên, hai vùng nhiễm bệnh, ở phía trên phổi trái và phía trên phổi phải").

2. **MosMedData+:**[2] bao gồm 2729 ảnh CT scan về nhiễm trùng phổi. Cấu trúc chú thích của tập dữ liệu này tương tự QaTa-COV19-v2, bao gồm phạm vi nhiễm bệnh, số vùng tổn thương và vị trí tương đối của vùng nhiễm. Ví dụ: "Unilateral pulmonary infection, two infected areas, middle lower left lung" (tạm dịch: "Nhiễm trùng phổi một bên, hai vùng nhiễm bệnh, ở giữa phía dưới phổi trái").

3. **ESO-CT:** bao gồm 286 ảnh X-ray được ghi chú độc lập bởi hai chuyên

[1] https://www.kaggle.com/datasets/aysendegerli/qatacov19-dataset
[2] http://medicalsegmentation.com/covid19

gia. Tập dữ liệu này tập trung vào ung thư thực quản và cung cấp thông tin vị trí tổn thương phục vụ cho bài toán phân đoạn.

3.1.2 Quy trình xây dựng chú thích văn bản

Phần ghi chú thông tin bệnh của các bộ dữ liệu không có sẵn ngay từ đầu, mà được nhóm nghiên cứu tạo ra và mở rộng với sự hỗ trợ trực tiếp của hai chuyên gia từ Khoa Xạ trị Ung thư [3].

Quy trình tạo và kiểm duyệt chất lượng chú thích được thực hiện chặt chẽ giữa các chuyên gia và nhóm nghiên cứu. Các bác sĩ X-quang tiến hành chú thích độc lập trên cùng một ảnh. Sau đó, kết quả được nhóm nghiên cứu đối chiếu để đảm bảo tính nhất quán, họ cũng kiểm tra chéo các đoạn văn bản này với mặt nạ phân đoạn gốc của ảnh nhằm bảo đảm rằng thông tin vị trí trong văn bản không sai lệch quá lớn so với vùng tổn thương thực tế.

3.1.3 Cấu trúc chú thích

Nội dung và cấu trúc chú thích được thiết kế theo đặc điểm của từng nhóm dữ liệu:

- **QaTa-COV19-v2 và MosMedData+:** Văn bản chú thích được cấu trúc hóa thống nhất, tập trung vào ba thuộc tính chính: phạm vi nhiễm bệnh, số lượng vùng tổn thương và vị trí ước chừng của vùng nhiễm.
- **ESO-CT:** Tập dữ liệu ung thư thực quản bao gồm các thông tin lâm sàng được bác sĩ X-quang chú thích thủ công. Để tạo văn bản mô tả, bác sĩ chia thực quản thành bốn phần từ trên xuống dưới, gồm cổ, ngực trên, ngực giữa và ngực dưới; sau đó ghi chú vị trí ước chừng của khối u dựa trên các phần này. Đoạn văn bản mô tả vị trí thô được sử dụng trực tiếp làm đầu vào cho mô hình.

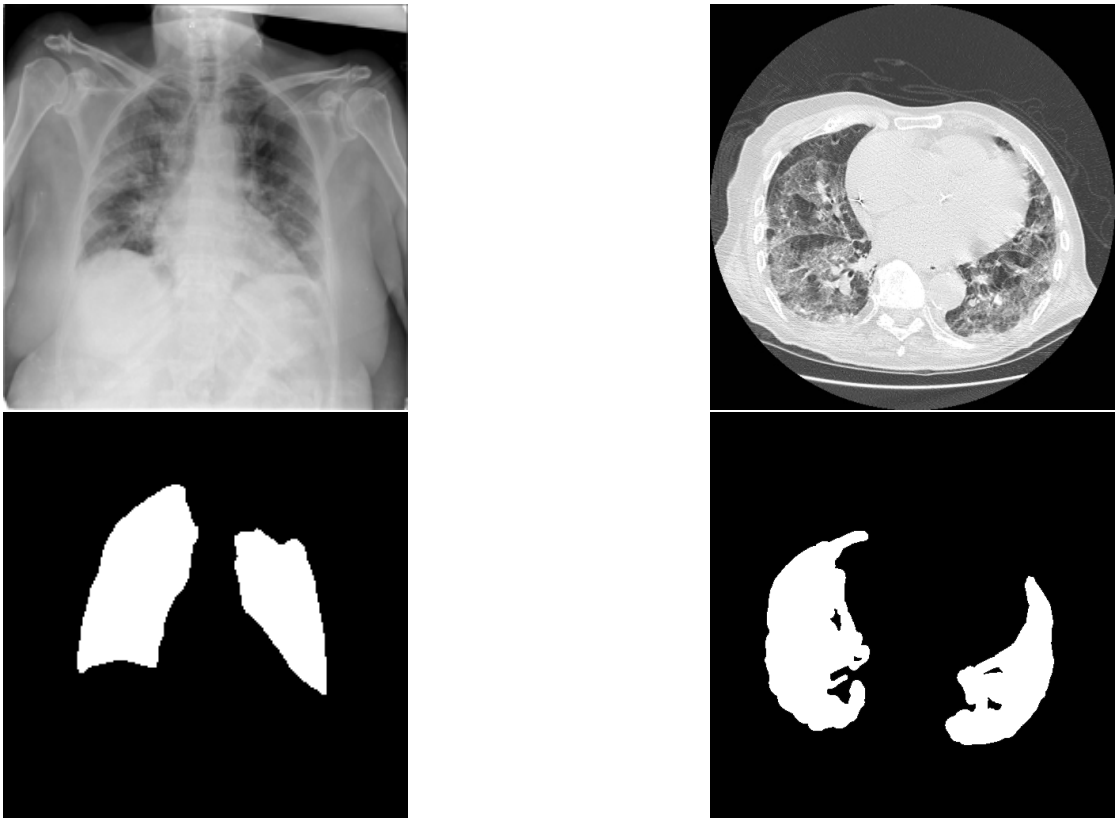
3.1.4 Phân chia dữ liệu

Số lượng mẫu trong từng tập huấn luyện, kiểm định và kiểm thử được chia như sau:

[3]Trung tâm Y tế Tây Nam trường Đại học Texas

	QaTa-COV19-v2	MosMedData+	ESO-CT
Tập huấn luyện	5716	2183	182
Tập kiểm định	1429	273	273
Tập kiểm thử	2113	273	58
Tổng cộng	9528	2729	286

Bảng 3.1: Phân phối dữ liệu trong các tập dữ liệu



QaTa-COV19-v2 (224 × 224) MosMedData+ (512 × 512)

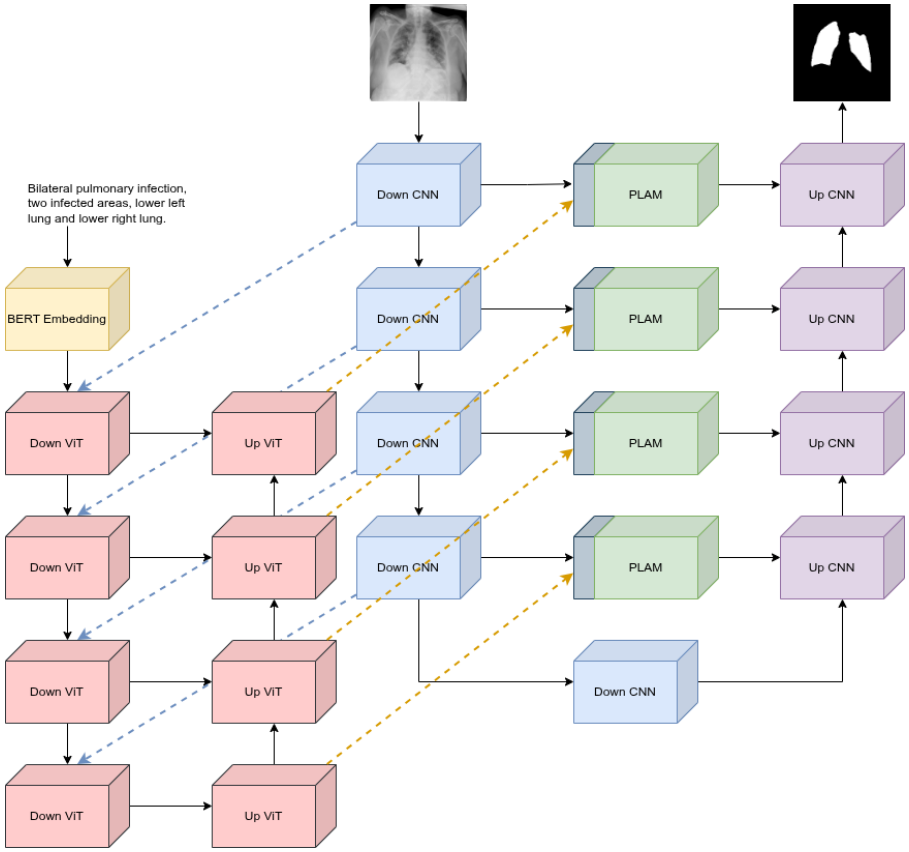
Hình 3.1: Ví dụ ảnh đầu vào và mặt nạ phân đoạn trong các bộ dữ liệu.

3.2 Kiến trúc mô hình

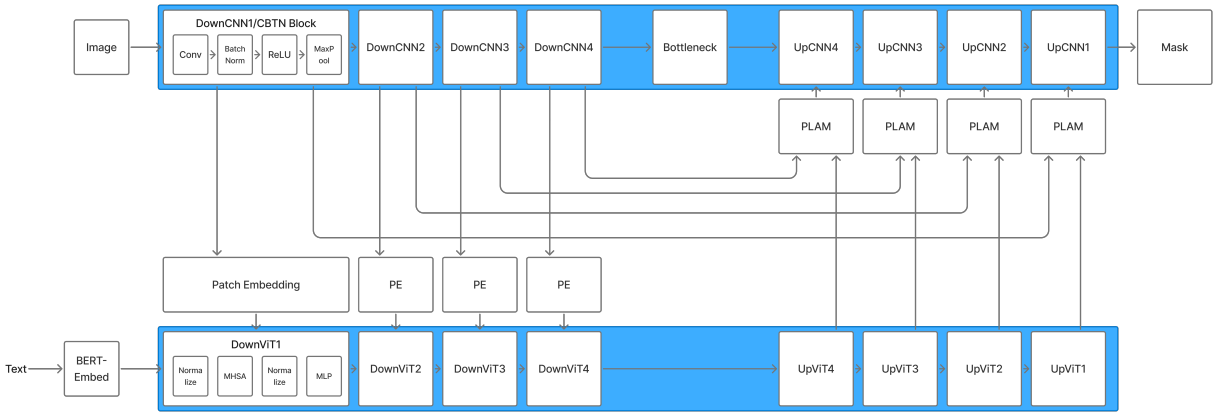
Mô hình LViT được xây dựng theo hướng kết hợp đặc trưng thị giác và đặc trưng ngôn ngữ nhằm thực hiện phân đoạn ảnh có điều kiện theo câu nhắc văn bản. Kiến trúc tổng quát gồm hai nhánh chính:

1. Nhánh CNN U-shape dùng để trích xuất đặc trưng cục bộ và bảo toàn thông tin không gian.

2. Nhánh ViT U-shape dùng để học quan hệ toàn cục và tích hợp thông tin văn bản vào biểu diễn hình ảnh.



Hình 3.2: Kiến trúc mô hình LViT.



Hình 3.3: Minh họa quá trình làm phẳng và xử lý đặc trưng trong LViT.

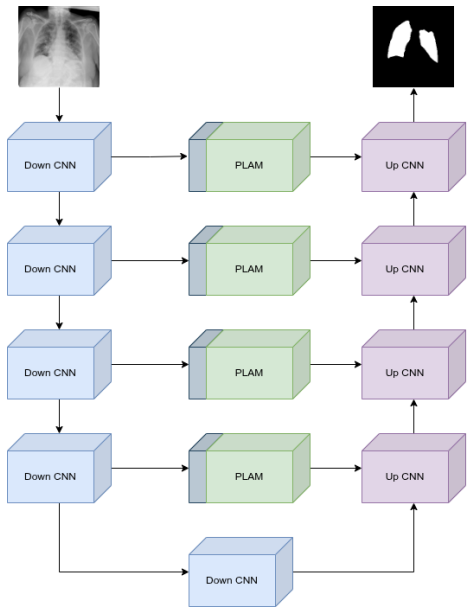
3.2.1 Nhánh CNN U-shape

Nhánh CNN nhận đầu vào là ảnh y khoa và tạo ra các đặc trưng thị giác ở nhiều mức độ phân giải khác nhau. Các khối tích chập giúp mô hình học các đặc trưng cục bộ như biên, kết cấu và hình dạng tổn thương, trong khi các phép giảm mẫu giúp mở rộng vùng tiếp nhận của mô hình. Đồng thời, nhánh CNN cũng đóng vai trò là đầu ra phân đoạn để tạo ra mặt nạ dự đoán xác suất.

$$
\begin{aligned}
D_i &= DownCNN_i = CTBN \\
&= ReLU(BatchNorm_i(Conv_i(\cdot)))
\end{aligned}
$$

$$
Y_{DownCNN,i+1} = MaxPool(D_i(Y_{DownCNN,i}))
$$

$$
Y_{DownCNN,0} = I
$$



Hình 3.4: Nhánh CNN U-shape và công thức cập nhật đặc trưng.

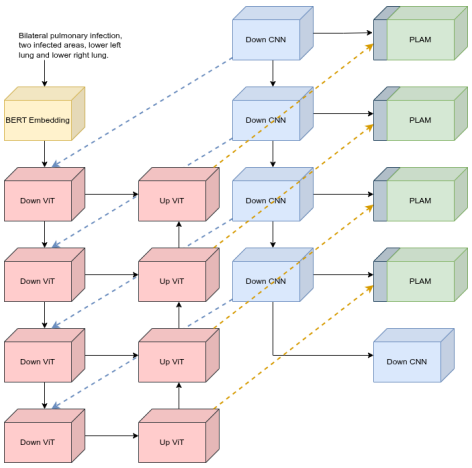
Trong đó, $Conv_i$ là phép tích chập tại tầng thứ i, $BatchNorm_i$ là chuẩn hóa theo batch, $ReLU$ là hàm kích hoạt phi tuyến và $MaxPool$ là phép giảm kích thước không gian. Kết quả của nhánh CNN được sử dụng làm nền tảng cho quá trình mã hóa thị giác và kết hợp với thông tin văn bản ở các bước sau.

Tại các nhánh skip connection, đặc trưng từ UpViT được điều chỉnh về cùng kích thước không gian với đặc trưng từ DownCNN để hai nguồn thông tin có thể được kết hợp trực tiếp. Đặc trưng DownCNN thường chứa nhiều chi tiết cục bộ như biên, kết cấu và vị trí không gian của vùng tổn thương, trong khi đặc trưng UpViT mang nhiều thông tin ngữ nghĩa và ngữ cảnh toàn cục hơn nhờ cơ chế attention. Việc kết hợp hai loại đặc trưng này giúp mô hình vừa giữ được độ chính xác ở mức pixel, vừa tận dụng được khả năng mô hình hóa quan hệ dài hạn của nhánh ViT. Sau bước căn chỉnh kích thước và hợp nhất đặc trưng, kết quả được đưa vào mô-đun PLAM nhằm bảo toàn thông tin cục bộ từ CNN, đồng thời bổ sung ngữ cảnh toàn cục từ nhánh ViT trước khi tiếp

tục quá trình giải mã mặt nạ.

3.2.2 Nhánh ViT U-shape

Khối DownViT đầu tiên nhận đầu vào là đặc trưng ảnh từ khối DownCNN thứ nhất, đồng thời kết hợp với đặc trưng văn bản được sinh ra từ lớp BERT-Embed của BERT_12_768_12. Thông qua cơ chế patch embedding, đặc trưng ảnh được chuyển thành các visual token để có thể xử lý bằng Transformer.



$$
\begin{aligned}
Y_{DownViT,1} &= ViT(x_{img,1} + CTBN(x_{text})) \\
x_{img,i} &= PatchEmbedding(Y_{DownCNN,i}) \\
x_{text} &= BERT_Embed(\text{text prompt})
\end{aligned}
$$

$$
\begin{aligned}
ViT(x) &= ViT_2(ViT_1(x)) \\
x' &= ViT_1(x) = MHSA(LN(x)) + x \\
Y &= ViT_2(x') = MLP(LN(x')) + x'
\end{aligned}
$$

Hình 3.5: Nhánh ViT U-shape và quá trình tích hợp đặc trưng ảnh-văn bản.

Trong các công thức trên, LN là Layer Normalization. Đặc trưng văn bản x_{text} được chiếu về không gian phù hợp thông qua $CTBN$ trước khi cộng với đặc trưng ảnh, giúp thông tin ngôn ngữ tham gia vào quá trình học biểu diễn thị giác.

Các khối ViT tiếp theo nhận đặc trưng từ khối ViT phía trên và đặc trưng từ khối DownCNN ở mức tương ứng.

$$
Y_{DownViT,i+1} = ViT(Y_{DownViT,i} + x_{img,i+1}), \quad i = 1, 2, 3
$$

Tại các khối UpViT, các token ngữ nghĩa được cộng với phần dư tương ứng từ nhánh DownViT nhằm bảo toàn thông tin toàn cục đã được học ở giai đoạn mã hóa. Cơ chế cộng phần dư này giúp đặc trưng ở nhánh giải mã không bị mất các quan hệ dài hạn giữa các vùng ảnh, đồng thời tiếp tục duy trì quá trình tương tác attention giữa các token. Nhờ đó, UpViT không chỉ khôi phục dần độ phân giải không gian mà còn giữ được ngữ cảnh ngữ nghĩa đã được tích hợp từ văn bản. Sau khi đi qua các khối UpViT, đặc trưng được điều chỉnh

về kích thước phù hợp để cộng trực tiếp với đặc trưng DownCNN ở cùng mức phân giải. Sự kết hợp này giúp mô hình tận dụng đồng thời thông tin toàn cục từ ViT và chi tiết cục bộ từ CNN trước khi đưa vào mô-đun PLAM để tiếp tục tinh chỉnh đặc trưng phục vụ cho quá trình giải mã mặt nạ.

3.2.3 Mô-đun Patch Embedding

Để kết hợp đặc trưng thị giác từ ảnh với đặc trưng văn bản trong nhánh Transformer, bản đồ đặc trưng hình ảnh cần được chuyển đổi từ dạng không gian hai chiều sang dạng chuỗi token. Ở nhánh CNN, đặc trưng ảnh thường được biểu diễn dưới dạng tensor gồm số kênh, chiều cao và chiều rộng. Trong khi đó, Transformer không xử lý trực tiếp ảnh như một lưới pixel hai chiều, mà tiếp nhận đầu vào dưới dạng một chuỗi các vector đặc trưng. Vì vậy, mô-đun Patch Embedding đóng vai trò trung gian, giúp chuyển đặc trưng ảnh sang định dạng phù hợp với cơ chế attention.

Cụ thể, mô-đun Patch Embedding chia bản đồ đặc trưng ảnh thành nhiều vùng nhỏ gọi là patch. Trong cài đặt thực tế, bước này thường được thực hiện bằng một lớp tích chập với kích thước kernel và stride tương ứng với kích thước patch. Mỗi patch sau khi đi qua phép chiếu sẽ được mã hóa thành một vector đặc trưng, gọi là visual token. Visual token này đại diện cho thông tin thị giác cục bộ của một vùng trong ảnh, chẳng hạn biên tổn thương, kết cấu mô hoặc sự thay đổi cường độ tại vùng bệnh lý.

Sau khi tạo ra các visual token, mô hình ghép chúng lại theo thứ tự không gian để tạo thành một chuỗi token hoàn chỉnh. Tuy nhiên, quá trình chuyển từ bản đồ đặc trưng hai chiều sang chuỗi một chiều có thể làm mất thông tin về vị trí tương đối giữa các patch. Để khắc phục điều này, mỗi visual token được cộng thêm positional embedding. Thành phần này giúp mô hình nhận biết token tương ứng đến từ vùng nào trong ảnh, ví dụ phía trên, phía dưới, bên trái hoặc bên phải. Đây là thông tin đặc biệt quan trọng trong phân đoạn ảnh y khoa, vì vị trí tổn thương thường liên quan trực tiếp đến nội dung mô tả trong câu nhắc văn bản.

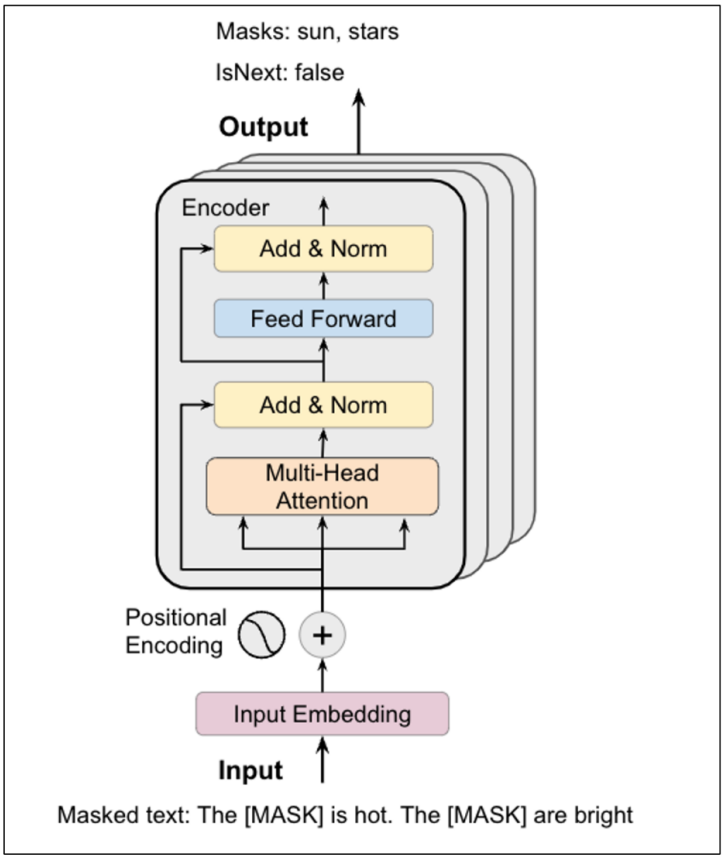
Sau bước Patch Embedding, chuỗi visual token được đưa vào các khối attention của nhánh ViT để học quan hệ toàn cục giữa các vùng ảnh. Đồng thời, vì đặc trưng văn bản cũng được biểu diễn dưới dạng các vector token, mô

hình có thể đưa thông tin thị giác và ngôn ngữ về cùng một không gian biểu diễn. Nhờ đó, các token hình ảnh không chỉ chứa thông tin về cấu trúc và vị trí của vùng tổn thương, mà còn có thể được điều kiện hóa bởi nội dung mô tả trong văn bản đầu vào.

3.2.4 Bộ mã hóa văn bản

Bộ mã hóa văn bản đóng vai trò chuyển câu mô tả y khoa thành các vector đặc trưng ngữ nghĩa để mô hình có thể sử dụng trong quá trình phân đoạn. Trước hết, câu mô tả được tách thành các token, sau đó mỗi token được ánh xạ sang một vector nhúng thông qua lớp Embedding của BERT. Các vector này chứa thông tin về ý nghĩa của từng thành phần trong câu, chẳng hạn như vị trí tổn thương, số lượng vùng nhiễm bệnh, phạm vi nhiễm bệnh và các đặc điểm mô tả liên quan. Nhờ đó, đặc trưng văn bản có thể đóng vai trò như một tín hiệu điều kiện, giúp nhánh thị giác tập trung vào đúng vùng mục tiêu thay vì chỉ dựa vào đặc trưng hình ảnh thuần túy.

Trong LViT, các câu mô tả y khoa thường có cấu trúc tương đối cố định và ngắn gọn, ví dụ bao gồm phạm vi nhiễm bệnh, số vùng tổn thương và vị trí tương đối. Do đó, mô hình không nhất thiết phải sử dụng toàn bộ các tầng Transformer của BERT để suy luận ngữ cảnh phức tạp như trong các bài toán xử lý ngôn ngữ tự nhiên tổng quát. Thay vào đó, việc sử dụng lớp Embedding của BERT đã đủ để cung cấp biểu diễn ban đầu cho các token văn bản, đồng thời giúp giảm số lượng tham số, tiết kiệm chi phí tính toán và hạn chế nguy cơ quá khớp khi dữ liệu y khoa có quy mô không quá lớn.



Hình 3.6: Bộ mã hóa văn bản dựa trên BERT.

3.2.5 Mô-đun Reconstruct

Sau khi các khối ViT học được quan hệ ngữ nghĩa giữa đặc trưng hình ảnh và đặc trưng văn bản, dữ liệu cần được chuyển trở lại dạng bản đồ đặc trưng để có thể kết hợp với nhánh CNN. Lý do là nhánh ViT biểu diễn dữ liệu dưới dạng chuỗi token, trong đó mỗi token đại diện cho một patch hoặc một vùng đặc trưng của ảnh. Ngược lại, nhánh CNN xử lý dữ liệu dưới dạng tensor không gian hai chiều, gồm số kênh, chiều cao và chiều rộng. Vì vậy, trước khi thực hiện cộng phần dư hoặc nối đặc trưng với nhánh CNN, chuỗi token từ ViT phải được tái cấu trúc thành bản đồ đặc trưng tương thích.

Mô-đun Reconstruct đảm nhiệm quá trình chuyển đổi này. Trước hết, chuỗi token được sắp xếp lại theo thứ tự không gian ban đầu của các patch để tạo thành một lưới hai chiều. Nếu ở bước Patch Embedding, bản đồ đặc trưng được chia thành các patch và làm phẳng thành chuỗi, thì ở bước Reconstruct, quá trình này được thực hiện theo chiều ngược lại: các token được đưa về đúng vị trí tương ứng trên mặt phẳng không gian. Nhờ đó, thông tin toàn cục học được

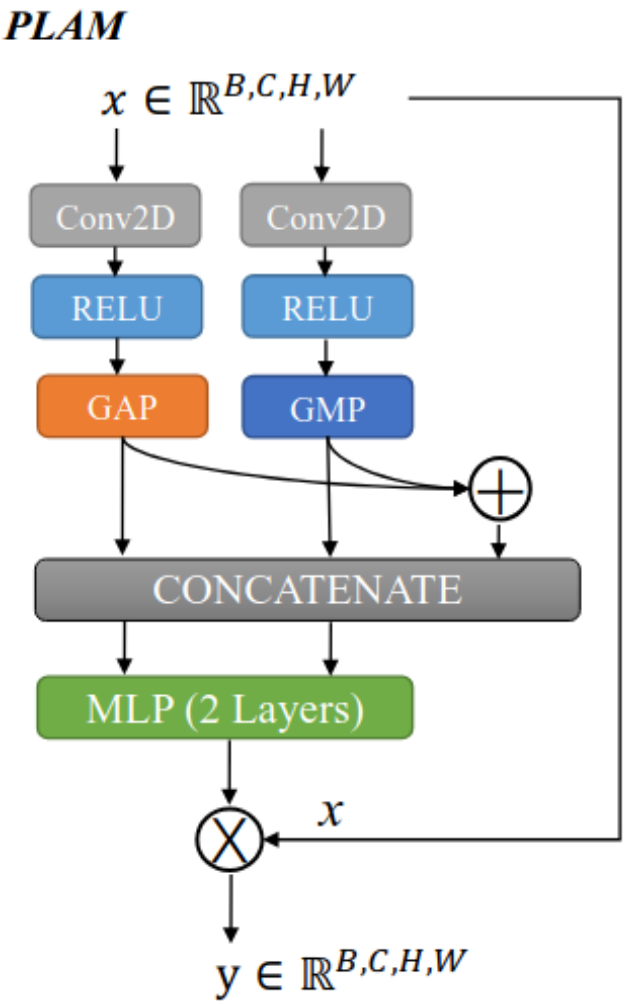
bởi Transformer có thể được biểu diễn lại dưới dạng bản đồ đặc trưng mà CNN có thể xử lý.

Sau khi khôi phục cấu trúc hai chiều, bản đồ đặc trưng thường vẫn có độ phân giải thấp hơn so với đặc trưng ở nhánh CNN tương ứng, vì mỗi token ban đầu chỉ đại diện cho một vùng patch thay vì một pixel riêng lẻ. Do đó, mô-đun Reconstruct cần thực hiện bước tăng kích thước không gian, chẳng hạn bằng nội suy hoặc các thao tác upsampling, để đưa bản đồ đặc trưng về cùng kích thước với nhánh CNN. Bước căn chỉnh này rất quan trọng, vì các phép toán như cộng phần dư hoặc ghép kênh chỉ thực hiện được khi hai tensor có cùng chiều cao và chiều rộng.

Cuối cùng, kết quả sau khi tái cấu trúc và tăng kích thước được đưa qua một lớp tích chập để điều chỉnh số kênh và tinh chỉnh lại biểu diễn đặc trưng. Lớp tích chập này giúp chuyển đặc trưng từ không gian token của ViT sang không gian đặc trưng phù hợp hơn với CNN, đồng thời làm mượt các thông tin sau bước nội suy. Nhờ mô-đun Reconstruct, LViT có thể kết hợp hiệu quả ưu điểm của Transformer trong việc học ngữ cảnh toàn cục với ưu điểm của CNN trong việc giữ chi tiết không gian cục bộ, phục vụ tốt hơn cho quá trình giải mã mặt nạ phân đoạn.

3.2.6 Mô-đun PLAM

Mô-đun PLAM được thiết kế nhằm bảo toàn đặc trưng cục bộ của ảnh, đồng thời tăng cường khả năng khai thác thông tin ngữ nghĩa từ đặc trưng văn bản. Trong kiến trúc LViT, nhánh Transformer có ưu điểm trong việc học các quan hệ toàn cục giữa các vùng ảnh thông qua cơ chế self-attention. Tuy nhiên, do tập trung vào tương tác toàn cục, Transformer có thể làm suy giảm một số chi tiết cục bộ quan trọng như biên tổn thương, kết cấu nhỏ hoặc sự thay đổi cường độ tại các vùng hẹp. Đây là những thông tin có vai trò quan trọng trong phân đoạn ảnh y khoa, đặc biệt khi vùng bệnh lý có kích thước nhỏ hoặc ranh giới không rõ ràng.



Hình 3.7: Mô-đun PLAM trong kiến trúc LViT.

PLAM được đưa vào để bù đắp hạn chế này bằng cách kết hợp thông tin từ nhiều nhánh đặc trưng khác nhau. Cụ thể, mô-đun sử dụng hai nhánh song song gồm Global Average Pooling và Global Max Pooling. Global Average Pooling giúp mô hình nắm bắt xu hướng tổng quát của toàn bộ bản đồ đặc trưng, trong khi Global Max Pooling nhấn mạnh các đặc điểm mạnh nhất, thường tương ứng với những vùng có tín hiệu nổi bật hoặc đặc trưng phân biệt cao. Việc sử dụng đồng thời hai phép pooling giúp PLAM thu được cả thông tin ngữ cảnh tổng quát lẫn các dấu hiệu cục bộ quan trọng.

Sau khi trích xuất đặc trưng từ hai nhánh pooling, các đặc trưng được cộng với nhau để kết hợp những kênh có ngữ nghĩa tương tự, từ đó giảm trùng lặp thông tin và tiết kiệm chi phí tính toán. Đồng thời, các đặc trưng cũng được nối lại nhằm bảo toàn thông tin riêng của từng nhánh, tránh làm mất các đặc điểm bổ sung giữa Global Average Pooling và Global Max Pooling. Đặc trưng

sau khi nối được đưa qua lớp MLP để học trọng số điều chỉnh kênh và căn chỉnh lại kích thước biểu diễn. Cuối cùng, trọng số này được nhân với đặc trưng đầu vào của PLAM để tái hiệu chỉnh mức độ quan trọng của từng kênh trước khi cộng phần dư vào nhánh UpCNN. Nhờ vậy, PLAM giúp nhánh giải mã vừa giữ được chi tiết cục bộ từ CNN, vừa được bổ sung ngữ cảnh ngữ nghĩa từ nhánh ViT và văn bản.

3.3 Hàm mất mát

Trong mô hình LViT, hàm mất mát được thiết kế khác nhau tùy thuộc vào dữ liệu đang được huấn luyện là dữ liệu có nhãn hay dữ liệu không có nhãn.

3.3.1 Hàm mất mát có giám sát

Đối với dữ liệu có nhãn, mô hình sử dụng trung bình cộng của hai hàm mất mát cơ bản được sử dụng trong phân đoạn ảnh là Dice loss (L_{Dice}) và Cross-Entropy (L_{CE}):

$$
\begin{aligned}
L_{Sup} &= \frac{1}{2}(L_{Dice} + L_{CE}) \\
L_{Dice} &= 1 - \sum_{i=1}^{N}\sum_{j=1}^{C} \frac{1}{NC} \cdot \frac{2|p_{ij} \cap y_{ij}|}{(|p_{ij}| + |y_{ij}|)} \\
L_{CE} &= -\sum_{i=1}^{N}\sum_{j=1}^{C} \frac{1}{N} \cdot y_{ij} log(p_{ij})
\end{aligned}
$$

trong đó, N là số lượng pixel, C là số lớp, p_{ij} là xác suất pixel i thuộc lớp j, y_{ij} là giá trị pixel i thuộc lớp j (bằng 1 nếu pixel i thuộc lớp j và bằng 0 trong những trường hợp khác).

Dice loss giúp mô hình tối ưu độ chồng lắp giữa mặt nạ dự đoán và mặt nạ chuẩn, trong khi Cross-Entropy giúp tối ưu xác suất phân loại tại từng pixel.

3.3.2 Language Vision Loss

Đối với dữ liệu không có nhãn, mô hình sử dụng hàm mất mát tương tự như trường hợp có giám sát, nhưng cộng thêm thành phần Language Vision Loss:

$$L = \frac{1}{2}(L_{Dice} + L_{CE}) + 0.1L_{LV}$$

Language Vision Loss được định nghĩa dựa trên độ tương đồng giữa đặc trưng hình ảnh và đặc trưng văn bản:

$$\begin{aligned} L_{LV} &= 1 - ImgSim \\ ImgSim &= \frac{x_{img,p} \cdot x_{img,c}}{|x_{img,p}||x_{img,c}|} \\ TextSim &= \frac{x_{text,p} \cdot x_{text,c}}{|x_{text,p}||x_{text,c}|} \end{aligned}$$

Quá trình tính toán LV loss gồm hai bước chính, tương ứng với việc tìm một nhãn đối chiếu phù hợp bằng văn bản và sau đó ràng buộc đặc trưng hình ảnh của nhãn giả với nhãn đối chiếu đó.

1. **Tìm độ tương đồng văn bản (TextSim):** Với mỗi ảnh không nhãn, đầu vào vẫn đi kèm một đoạn chú thích bệnh mô tả vị trí hoặc đặc điểm tổn thương. Sau khi mô hình sinh ra nhãn giả cho ảnh này, đoạn chú thích tương ứng được mã hóa thành vector đặc trưng văn bản $x_{text,p}$. Mô hình sau đó so sánh vector này với các vector đặc trưng văn bản của những mẫu có nhãn trong tập huấn luyện, ký hiệu là $x_{text,c}$, bằng độ tương đồng cosine. Mẫu có văn bản đối chiếu gần nhất về mặt ngữ nghĩa được xem là mẫu tham chiếu phù hợp nhất. Mặt nạ thật của mẫu có nhãn này được chọn làm nhãn đối chiếu, vì nó được giả định mô tả một vùng tổn thương có vị trí hoặc đặc điểm tương tự với nhãn giả đang xét.

2. **Tìm độ tương đồng hình ảnh (ImgSim):** Sau khi xác định được nhãn đối chiếu từ bước TextSim, mô hình tiếp tục so sánh đặc trưng hình ảnh của nhãn giả với đặc trưng hình ảnh của nhãn đối chiếu. Cụ thể, vector đặc trưng của vùng dự đoán từ ảnh không nhãn được ký hiệu là $x_{img,p}$, còn vector đặc trưng của vùng đối chiếu từ ảnh có nhãn được ký hiệu

là $x_{img,c}$. Độ tương đồng cosine giữa hai vector này cho biết nhãn giả có gần với nhãn đối chiếu hay không trong không gian đặc trưng hình ảnh. Nếu hai đặc trưng càng giống nhau, giá trị $ImgSim$ càng lớn và $L_{LV} = 1 - ImgSim$ càng nhỏ.

Mục đích của LV loss là tận dụng trực tiếp thông tin từ văn bản y tế để tạo thêm tín hiệu giám sát cho các ảnh không có nhãn. Thay vì chỉ tin vào mặt nạ do mô hình tự dự đoán, LV loss sử dụng chú thích văn bản để tìm một mẫu có nhãn mang ý nghĩa gần nhất, rồi dùng mẫu đó như một điểm neo tham chiếu. Vì các cơ quan và tổn thương trên ảnh y tế thường có vị trí giải phẫu tương đối ổn định, sự tương đồng giữa các mô tả văn bản có thể cung cấp gợi ý hữu ích về vị trí phân đoạn. Nhờ vậy, LV loss giúp hạn chế trường hợp mô hình dự đoán mặt nạ lệch khỏi vùng cơ quan hoặc vùng bệnh lý mà văn bản đang mô tả, đồng thời làm cho nhãn giả nhất quán hơn với tri thức ngữ nghĩa từ chú thích y khoa.

3.4 Cơ chế sinh nhãn giả

Với các ảnh không nhãn, mô hình không có mặt nạ chuẩn để tính trực tiếp các hàm mất mát phân đoạn như Dice loss và Cross-Entropy. Vì vậy, cần có một cơ chế sinh nhãn giả nhằm tạo ra các mặt nạ tạm thời cho dữ liệu không nhãn. Các nhãn giả này đóng vai trò như tín hiệu giám sát bổ sung, giúp mô hình tiếp tục cập nhật trọng số và khai thác được lượng dữ liệu chưa được chú thích thủ công.

Tuy nhiên, nhãn giả do mô hình tự dự đoán thường không ổn định, đặc biệt ở các giai đoạn đầu của quá trình huấn luyện. Nếu sử dụng trực tiếp dự đoán ở một vòng huấn luyện duy nhất, mặt nạ có thể bị nhiễu, bị lệch khỏi vùng tổn thương hoặc thay đổi mạnh giữa các vòng lặp. Điều này có thể khiến mô hình học theo các nhãn sai và làm giảm chất lượng phân đoạn. Do đó, thay vì chỉ dùng dự đoán hiện tại, LViT sử dụng một cơ chế tích lũy dự đoán qua nhiều vòng huấn luyện để tạo ra nhãn giả ổn định hơn.

Nhóm nghiên cứu phát triển cơ chế Exponential Pseudo-label Iteration (EPI) dựa trên ý tưởng của trung bình động hàm mũ (Exponential Moving Average - EMA). Giả định chính của cơ chế này là sau một số vòng huấn luyện,

trọng số của mô hình không thay đổi hoàn toàn ngẫu nhiên mà thường dao động quanh một vùng nghiệm tương đối ổn định. Khi đó, các mặt nạ dự đoán cho cùng một ảnh ở các vòng huấn luyện liên tiếp cũng có xu hướng dao động quanh ranh giới phân đoạn hợp lý của vùng bệnh lý. Nếu tổng hợp các dự đoán này bằng trung bình động, những sai số ngẫu nhiên có thể được làm mượt, trong khi các vùng được dự đoán nhất quán sẽ được giữ lại.

Đối với dữ liệu không có nhãn, quy trình sinh nhãn giả gồm các bước sau:

1. **Dự đoán mặt nạ hiện tại:** Ở vòng huấn luyện t, mô hình nhận ảnh không nhãn làm đầu vào và sinh ra bản đồ xác suất hiện tại, ký hiệu là $P_{current}$.

2. **Kết hợp với nhãn giả trước đó:** Dự đoán hiện tại được kết hợp với nhãn giả đã tích lũy từ vòng trước thông qua cơ chế EMA:

$$P_t = \beta P_{t-1} + (1 - \beta) P_{current}$$

   Trong đó, P_t là nhãn giả được cập nhật tại vòng huấn luyện t, P_{t-1} là nhãn giả ở vòng trước, $P_{current}$ là dự đoán hiện tại của mô hình và β là hệ số làm mượt.

3. **Sử dụng nhãn giả để huấn luyện:** Nhãn giả P_t sau khi cập nhật được dùng như mặt nạ tham chiếu tạm thời để tính các thành phần mất mát phân đoạn cho ảnh không nhãn, chẳng hạn Dice loss và Cross-Entropy. Nhờ đó, dữ liệu không nhãn vẫn có thể đóng góp vào quá trình tối ưu mô hình.

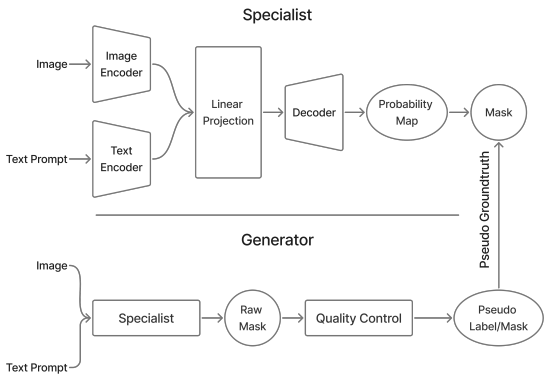
Hệ số β điều khiển mức độ phụ thuộc vào lịch sử dự đoán. Khi β lớn, nhãn giả thay đổi chậm hơn và ổn định hơn, nhưng có thể phản ứng chậm với các cải thiện mới của mô hình. Ngược lại, khi β nhỏ, nhãn giả chịu ảnh hưởng nhiều hơn từ dự đoán hiện tại, giúp cập nhật nhanh hơn nhưng dễ bị nhiễu hơn. Vì vậy, lựa chọn β cần cân bằng giữa tính ổn định và khả năng thích nghi của nhãn giả.

Mục tiêu của EPI là làm cho mặt nạ giả nhất quán hơn qua các vòng huấn luyện, hạn chế trường hợp mô hình thay đổi dự đoán quá đột ngột trên cùng một ảnh. Nhờ việc tích lũy thông tin theo thời gian, các vùng dự đoán ổn định

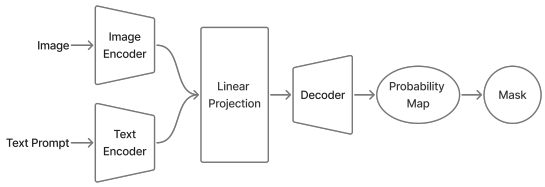
được củng cố, còn các sai số dao động nhất thời có xu hướng bị triệt tiêu. Điều này giúp mô hình học được các chi tiết phân đoạn một cách bền vững hơn trên dữ liệu không nhãn, đồng thời tận dụng hiệu quả hơn nguồn dữ liệu y khoa chưa được chú thích đầy đủ.

3.5 Các pipeline huấn luyện và sử dụng mô hình

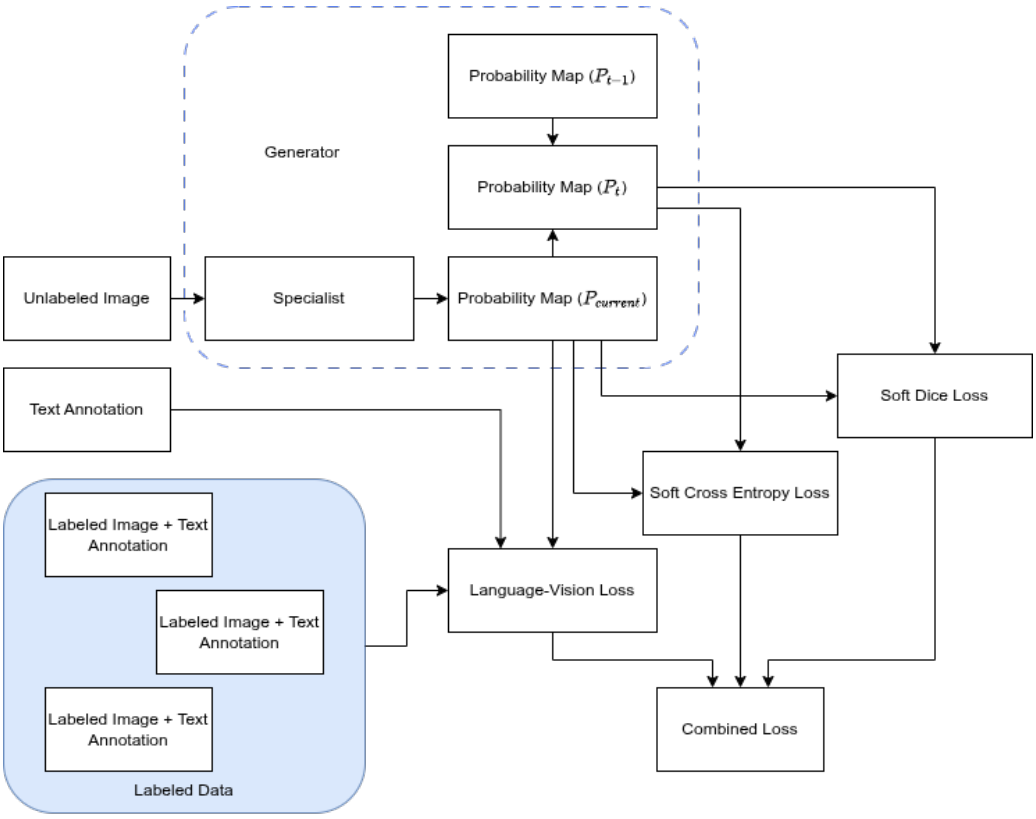
Để trực quan hoá toàn bộ quy trình hoạt động của LViT, phần này trình bày ba pipeline chính: pipeline huấn luyện ngoại tuyến, pipeline sử dụng mô hình sau huấn luyện và pipeline chi tiết cho quá trình tính toán hàm mất mát kết hợp với sinh nhãn giả. Ba pipeline này tương ứng với ba góc nhìn khác nhau của hệ thống: cách mô hình học từ dữ liệu, cách mô hình được triển khai để dự đoán mặt nạ, và cách các tín hiệu giám sát được xây dựng trong bối cảnh học bán giám sát.



Hình 3.8: Pipeline huấn luyện mô hình



Hình 3.9: Pipeline sử dụng mô hình



Hình 3.10: Pipeline tính toán hàm mất mát và xây dựng nhãn giả chi tiết

Hình 3.8 mô tả pipeline huấn luyện mô hình ở chế độ ngoại tuyến. Trong giai đoạn này, hệ thống sử dụng cả dữ liệu có nhãn và dữ liệu không nhãn. Đối với dữ liệu có nhãn, mặt nạ chuẩn được dùng trực tiếp để tính các hàm mất mát giám sát như Dice loss và Cross-Entropy. Đối với dữ liệu không nhãn, mô hình cần thêm cơ chế sinh nhãn giả để tạo ra mặt nạ tạm thời phục vụ quá trình huấn luyện. Pipeline này gồm hai thành phần quan trọng: *Specialist* và *Generator*. Specialist chịu trách nhiệm sinh mặt nạ phân đoạn ban đầu dựa trên ảnh đầu vào và câu nhắc văn bản, trong khi Generator tổng hợp và cập nhật các nhãn giả ổn định hơn từ các dự đoán qua nhiều vòng huấn luyện.

Trong pipeline huấn luyện, các bước như *Quality Control*, *Pseudo Groundtruth Generation* và *Loss Calculation* đóng vai trò trung gian quan trọng. Quality Control giúp kiểm soát chất lượng nhãn giả trước khi sử dụng cho huấn luyện. Pseudo Groundtruth Generation cập nhật mặt nạ giả bằng cơ chế EPI/EMA để làm mượt các dự đoán qua thời gian. Loss Calculation kết hợp các thành phần mất mát từ dữ liệu có nhãn, dữ liệu không nhãn và tín hiệu căn chỉnh ngôn ngữ-thị giác. Các bước này không được thiết kế như các mô-đun độc lập, mà được tích hợp vào nhiều giai đoạn khác nhau của quá trình huấn luyện và

được trình bày chi tiết hơn trong Hình 3.10.

Hình 3.9 mô tả pipeline sử dụng mô hình trong thực tế sau khi quá trình huấn luyện đã hoàn tất. Ở giai đoạn suy luận, người dùng cung cấp một ảnh y khoa và một câu nhắc văn bản mô tả vùng cần phân đoạn. Ảnh được đưa qua nhánh mã hóa thị giác, trong khi câu nhắc được chuyển thành đặc trưng ngữ nghĩa thông qua bộ mã hóa văn bản. Hai nguồn đặc trưng này được kết hợp trong mô hình để sinh ra bản đồ xác suất phân đoạn. Sau đó, bản đồ xác suất được xử lý bằng một ngưỡng quyết định để tạo ra mặt nạ nhị phân cuối cùng. Mặt nạ này biểu diễn vùng tổn thương hoặc cơ quan phù hợp với nội dung câu nhắc đầu vào.

Điểm quan trọng của pipeline online là mô hình có tính linh hoạt theo câu nhắc. Cùng một ảnh đầu vào có thể tạo ra các mặt nạ khác nhau nếu người dùng thay đổi mô tả văn bản. Điều này giúp mô hình phù hợp hơn với các tình huống tương tác trong y khoa, nơi bác sĩ hoặc nhà nghiên cứu có thể muốn tập trung vào một vùng tổn thương, một cơ quan hoặc một đặc điểm bệnh lý cụ thể.

Hình 3.10 mô tả chi tiết quá trình xây dựng nhãn giả và tính toán hàm mất mát cho ảnh không nhãn. Trước hết, mô hình nhận ảnh không nhãn cùng câu nhắc văn bản tương ứng để sinh ra bản đồ xác suất hiện tại $P_{current}$. Mỗi phần tử trong $P_{current}$ biểu diễn xác suất pixel tương ứng thuộc về vùng cần phân đoạn, thay vì chỉ đưa ra quyết định nhị phân là nền hoặc tổn thương. Do đó, $P_{current}$ không chỉ cho biết vị trí vùng dự đoán mà còn thể hiện mức độ tự tin của mô hình tại từng điểm ảnh.

Bản đồ xác suất hiện tại này được kết hợp với nhãn giả ở vòng trước P_{t-1} thông qua cơ chế EPI để tạo ra bản đồ xác suất giả mới P_t. Về bản chất, EPI hoạt động như một phép trung bình động theo thời gian: những vùng được mô hình dự đoán nhất quán qua nhiều vòng huấn luyện sẽ được củng cố, trong khi các vùng chỉ xuất hiện do nhiễu hoặc sai số tạm thời sẽ bị làm giảm ảnh hưởng. Nhờ vậy, P_t thường ổn định hơn so với dự đoán đơn lẻ ở vòng hiện tại và có thể được sử dụng như một pseudo groundtruth đáng tin cậy hơn cho quá trình huấn luyện trên dữ liệu không nhãn.

Điểm quan trọng là các hàm mất mát trong bước này được áp dụng theo hướng *soft*. Điều này có nghĩa là mục tiêu huấn luyện không bắt buộc phải là mặt nạ nhị phân chỉ gồm các giá trị 0 và 1, mà có thể là một bản đồ xác suất

với các giá trị thực nằm trong khoảng từ 0 đến 1. Ví dụ, một pixel có giá trị 0.8 trong nhãn giả thể hiện rằng pixel đó có khả năng cao thuộc vùng tổn thương, trong khi giá trị 0.4 thể hiện mức độ không chắc chắn lớn hơn. Cách biểu diễn này giữ lại nhiều thông tin hơn so với việc gán cứng pixel đó thành 0 hoặc 1.

Việc sử dụng nhãn mềm đặc biệt phù hợp với phân đoạn ảnh y khoa, vì ranh giới giữa vùng bệnh lý và mô lành thường không rõ ràng tuyệt đối. Trong nhiều trường hợp, các pixel nằm gần biên tổn thương có thể mang thông tin mơ hồ, khiến cả mô hình lẫn chuyên gia chú thích khó đưa ra quyết định hoàn toàn chắc chắn. Nếu áp dụng ngưỡng nhị phân quá sớm trong huấn luyện, các vùng có xác suất trung gian sẽ bị mất thông tin về độ không chắc chắn. Ngược lại, khi giữ nhãn giả ở dạng xác suất, mô hình có thể học được biểu diễn phân đoạn mềm và điều chỉnh dần ranh giới dự đoán qua các vòng tối ưu.

Cách tiếp cận này cũng giúp Dice loss và Cross-Entropy nhận được tín hiệu huấn luyện mượt hơn. Thay vì phạt mô hình theo một nhãn cứng duy nhất, các hàm mất mát có thể so sánh trực tiếp dự đoán của mô hình với phân phối xác suất P_t. Điều này làm giảm nguy cơ mô hình học quá mạnh từ các nhãn giả sai ở giai đoạn đầu, đồng thời cho phép các dự đoán có độ tin cậy cao đóng góp nhiều hơn vào quá trình cập nhật tham số. Về mặt ý tưởng, cơ chế này tương tự Knowledge Distillation, trong đó một phân phối mềm được dùng làm mục tiêu để truyền đạt thông tin giàu hơn so với nhãn lớp cố định.

Sau khi có P_t, hệ thống sử dụng bản đồ xác suất giả này để tính các hàm mất mát phân đoạn như Dice loss và Cross-Entropy. Đồng thời, bản đồ xác suất ban đầu $P_{current}$ được kết hợp với câu nhắc văn bản đi kèm để tính Language-Vision Loss. Thành phần Language-Vision Loss giúp kiểm tra xem vùng dự đoán có nhất quán với mô tả văn bản hay không, từ đó bổ sung tín hiệu giám sát ngữ nghĩa cho dữ liệu không nhãn. Cuối cùng, các thành phần mất mát này được kết hợp theo trọng số để tạo ra hàm mất mát tổng, dùng để cập nhật tham số của mô hình.

Ba pipeline trong phần này cho thấy LViT không chỉ là một mô hình phân đoạn ảnh thông thường, mà là một hệ thống học đa phương thức có khả năng tận dụng đồng thời ảnh, văn bản, nhãn chuẩn và nhãn giả. Pipeline huấn luyện giúp mô hình học từ cả dữ liệu có nhãn và không nhãn; pipeline online cho phép sử dụng mô hình với câu nhắc văn bản; còn pipeline tính loss mô tả cách các tín hiệu giám sát được kết hợp để cải thiện chất lượng phân đoạn.

Chương 4

Cài đặt

4.1 Độ đo đánh giá

Để đánh giá hiệu suất phân đoạn của mô hình LViT và so sánh với các phương pháp tiên tiến khác (SOTA), báo cáo này sử dụng hai độ đo chính: **chỉ số Dice (Dice score)** và **mIoU (mean Intersection over Union)**.

- **Chỉ số Dice (Dice score):** Đây là độ đo đánh giá mức độ trùng khớp giữa mặt nạ phân đoạn do mô hình dự đoán và mặt nạ nhãn chuẩn. Giá trị Dice càng cao cho thấy kết quả phân đoạn càng gần với nhãn chuẩn. Chỉ số này có mối liên hệ trực tiếp với hàm mất mát Dice, thường được biểu diễn dưới dạng $Dice = 1 - L_{Dice}$.

$$Dice = \sum_{i=1}^{N} \sum_{j=1}^{C} \frac{1}{NC} \cdot \frac{2|p_{ij} \cap y_{ij}|}{(|p_{ij}| + |y_{ij}|)}$$

- **mIoU (mean Intersection over Union):** Độ đo này tính tỷ lệ giữa phần giao nhau và phần hợp của vùng dự đoán so với vùng nhãn chuẩn, sau đó lấy trung bình trên các lớp cần phân đoạn. mIoU càng cao cho thấy vùng dự đoán càng khớp với vùng tổn thương thực tế.

$$mIoU = \sum_{i=1}^{N} \sum_{j=1}^{C} \frac{1}{NC} \cdot \frac{|p_{ij} \cap y_{ij}|}{|p_{ij} \cup y_{ij}|}$$

Trong đó:

- N: Tổng số điểm ảnh.
- C: Số lớp phân đoạn. Trong báo cáo này, C được thiết lập bằng 1.

- p_{ij}: Xác suất mô hình dự đoán điểm ảnh i thuộc về lớp j.
- y_{ij}: Nhãn chuẩn của điểm ảnh, có giá trị bằng 1 nếu điểm ảnh i thuộc về lớp j và bằng 0 trong trường hợp ngược lại.

4.2 Môi trường thử nghiệm

Thử nghiệm được thực hiện trên nền tảng Kaggle với cấu hình GPU T4 x2. Đây là môi trường phù hợp cho quá trình huấn luyện mô hình học sâu ở quy mô vừa, đặc biệt với các mô hình phân đoạn ảnh y khoa có kết hợp nhánh CNN và nhánh Transformer như LViT. Việc sử dụng GPU giúp tăng tốc đáng kể các phép tính ma trận, lan truyền tiến và lan truyền ngược trong quá trình tối ưu tham số.

Mô hình được huấn luyện riêng biệt trên hai tập dữ liệu QaTa-COV19-v2 và MosMedData+. Tập ESO-CT đã được đề cập trong phần phương pháp; tuy nhiên, tại thời điểm thực hiện báo cáo này, bộ dữ liệu này chưa được công bố công khai nên không thể truy cập để tiến hành thử nghiệm. Cách huấn luyện riêng từng tập dữ liệu giúp đánh giá khả năng học biểu diễn của LViT trên từng loại ảnh y khoa cụ thể, bao gồm ảnh X-ray ngực và ảnh CT phổi. Hai tập dữ liệu này đều có mặt nạ phân đoạn và ghi chú y khoa đi kèm, do đó phù hợp với mục tiêu đánh giá mô hình phân đoạn đa phương thức dựa trên cả thông tin ảnh và văn bản.

Trước khi đưa vào mô hình, tất cả ảnh đầu vào được thay đổi kích thước về 224×224. Đây là kích thước đầu vào phổ biến của Vision Transformer, đặc biệt trong các mô hình tiền huấn luyện trên ImageNet. Việc sử dụng cùng kích thước này giúp đảm bảo sự tương thích với cơ chế chia ảnh thành các patch và với vector mã hoá vị trí trong nhánh Transformer. Ngoài ra, việc chuẩn hoá kích thước ảnh cũng giúp các batch có cùng kích thước tensor, giảm độ phức tạp khi huấn luyện và tạo điều kiện so sánh công bằng giữa các tập dữ liệu.

Các siêu tham số được lựa chọn theo hướng cân bằng giữa chất lượng học và giới hạn tài nguyên của môi trường Kaggle. Do ảnh y khoa và mặt nạ phân đoạn yêu cầu lưu trữ nhiều bản đồ đặc trưng trung gian, batch size được đặt nhỏ để tránh vượt quá bộ nhớ GPU. Learning rate được chọn ở mức tương đối nhỏ nhằm giúp quá trình tối ưu ổn định hơn, đặc biệt khi mô hình kết hợp

nhiều thành phần mất mát khác nhau. Cấu hình hyperparameter được thiết lập như sau:

	QaTa-COV19-v2		**MosMedData+**	
	Supervised	Semi-supervised	Supervised	Semi-supervised
Optimizer	Adam			
Tỉ lệ nhãn	100%	25%	100%	25%
Batch size	24	16	24	16
Learning rate	0.0003		0.001	
Scheduler	Cosine Annealing Restarts			
Epochs	100			

4.3 Chú thích mã nguồn

Cấu trúc mã nguồn mô hình LViT được tổ chức như sau:

```
src/
├── datasets/
│   ├── Covid19/
│   └── MosMedDataPlus/
├── nets/
│   ├── LViT.py
│   ├── pixlevel.py
│   ├── textlevel.py
│   ├── UNet.py
│   └── Vit.py
├── Config.py
├── Load_Dataset.py
├── requirements.txt
├── test_model.py
├── train_model.py
├── Train_one_epoch.py
└── utils.py
```

Do môi trường thử nghiệm trong báo cáo này khác với môi trường thực thi được sử dụng trong công trình gốc, một số thành phần mã nguồn cần được điều chỉnh để có thể chạy ổn định trên nền tảng hiện tại. Cụ thể, báo cáo vẫn giữ lại các thư viện Python và cấu trúc cài đặt chính liên quan đến LViT, nhưng có rà soát và chỉnh sửa một số đoạn mã nhằm bảo đảm tương thích với phiên bản mới hơn của các thư viện học sâu, thư viện xử lý ảnh và các hàm hỗ trợ đọc dữ liệu.

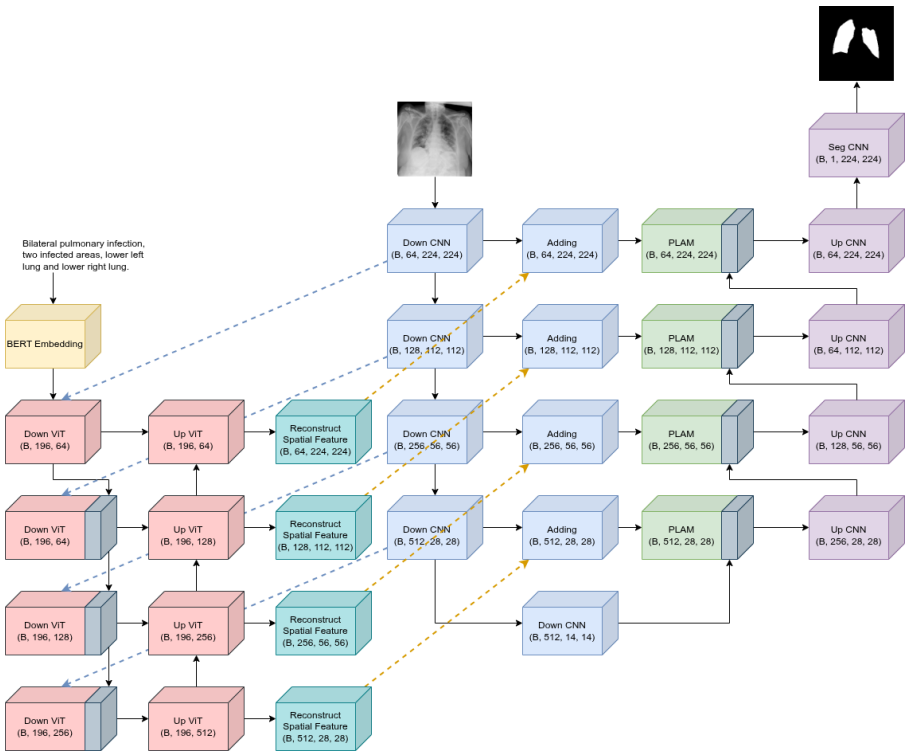
Các thay đổi này chủ yếu tập trung vào những phần có khả năng bị ảnh hưởng bởi sự khác biệt phiên bản, chẳng hạn như cú pháp gọi hàm, xử lý tensor, định dạng dữ liệu đầu vào, quản lý bộ nhớ. Mục tiêu của các chỉnh sửa là giữ nguyên ý tưởng và luồng xử lý chính của mô hình LViT, đồng thời giúp mã nguồn có thể thực thi được trong môi trường Kaggle và với cấu trúc dữ liệu được sử dụng trong báo cáo này.

Những chỉnh sửa này không nhằm thay đổi bản chất kiến trúc mô hình hay phương pháp huấn luyện được trình bày trong các chương trước. Thay vào đó, chúng đóng vai trò tái lập thí nghiệm trong điều kiện phần mềm và dữ liệu hiện có. Danh sách thay đổi cụ thể, bao gồm các file được chỉnh sửa và lý do chỉnh sửa, cách chạy mã nguồn được trình bày chi tiết trong file README đính kèm trong thư mục mã nguồn.

4.4 Cài đặt thực tế

Các sơ đồ ở phần phương pháp cung cấp cái nhìn tổng quan về luồng xử lý của mô hình LViT, trong đó nhấn mạnh sự kết hợp giữa nhánh CNN, nhánh ViT và đặc trưng văn bản. Tuy nhiên, khi chuyển từ mô tả phương pháp sang cài đặt thực tế, một số thao tác cần được điều chỉnh để phù hợp với cách biểu diễn tensor trong các thư viện học máy. Ví dụ, các phép cộng, phép nối đặc trưng hoặc truyền dữ liệu giữa hai nhánh chỉ có thể thực hiện khi các tensor có cùng kích thước không gian, cùng số chiều hoặc đã được chiếu về cùng miền biểu diễn. Vì vậy, kiến trúc trong cài đặt có một số khác biệt so với sơ đồ khái niệm, dù vẫn giữ nguyên ý tưởng chính của mô hình.

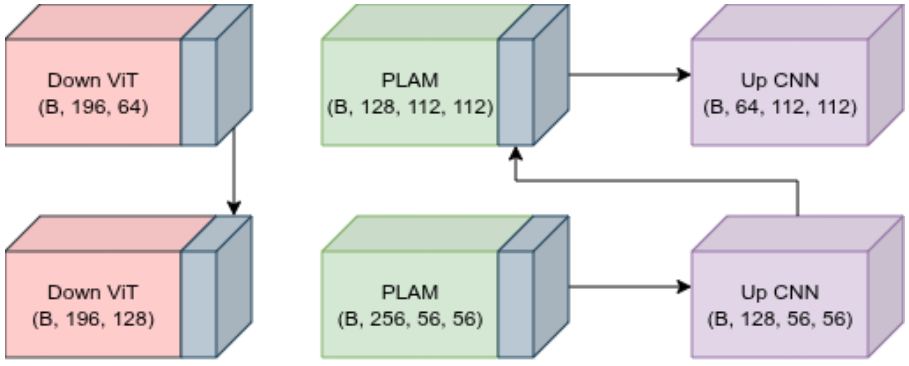
Trong quá trình cài đặt, mỗi ảnh đầu vào được biểu diễn dưới dạng tensor bốn chiều gồm batch size, số kênh, chiều cao và chiều rộng. Các đặc trưng trung gian sinh ra từ nhánh CNN thường giữ cấu trúc không gian hai chiều, trong khi đặc trưng ở nhánh ViT cần được chuyển thành chuỗi token thông qua thao tác chia patch và làm phẳng. Do hai kiểu biểu diễn này khác nhau, mô hình cần thêm các bước biến đổi như reshape, transpose, projection, upsampling hoặc downsampling để bảo đảm dữ liệu có thể được kết hợp đúng cách. Những bước này không luôn được thể hiện đầy đủ trong sơ đồ phương pháp, nhưng lại rất quan trọng trong cài đặt thực tế.



Hình 4.1: Minh họa kiến trúc LViT trong cài đặt.

Bên cạnh việc mô tả các thành phần chính của mô hình, hình trên còn thể hiện kích thước dữ liệu được xử lý qua từng bước. Việc ghi rõ kích thước tensor giúp kiểm tra tính hợp lệ của kiến trúc trong quá trình cài đặt, đặc biệt tại các vị trí giao nhau giữa nhánh CNN và nhánh ViT. Nếu kích thước tensor không khớp, các phép toán như cộng phần dư, nối đặc trưng hoặc truyền qua khối tích chập sẽ không thể thực hiện. Do đó, sơ đồ cài đặt đóng vai trò như một bản kiểm tra luồng dữ liệu, giúp bảo đảm rằng đầu ra của mỗi khối có thể trở thành đầu vào hợp lệ cho khối tiếp theo.

Một ví dụ quan trọng là các khối nối đặc trưng được minh họa trong hình dưới đây:

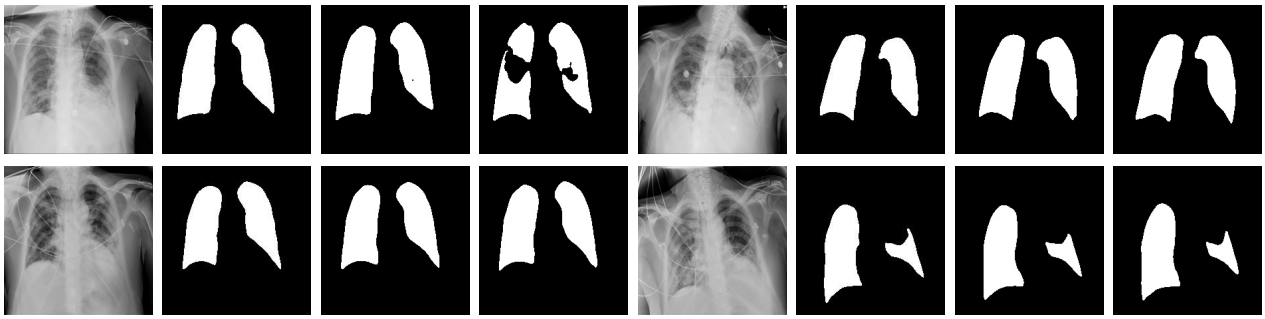


Hình 4.2: Phép nối dữ liệu theo chiều kênh.

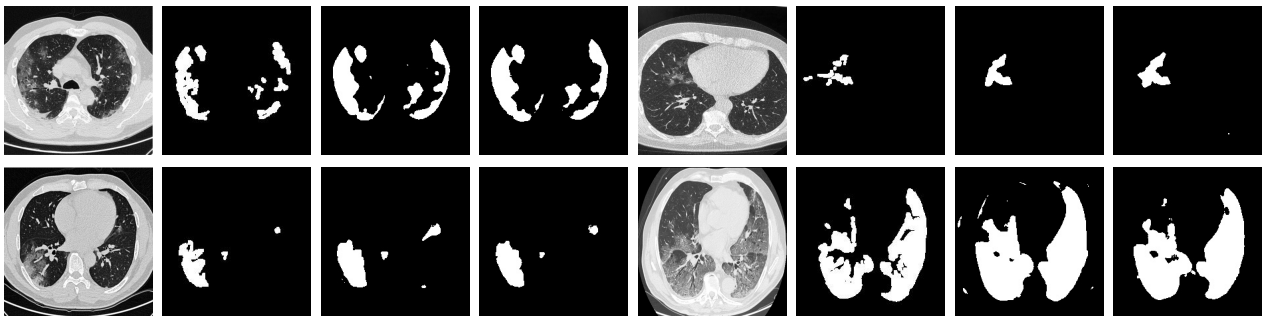
Các khối màu xám thể hiện phép nối đặc trưng, trong đó nhiều tensor từ các nhánh khác nhau được ghép lại theo chiều kênh. Phép nối này làm tăng số kênh của dữ liệu, cho phép mô hình giữ lại đồng thời thông tin cục bộ từ CNN và thông tin ngữ nghĩa/toàn cục từ ViT. Tuy nhiên, trước khi nối, các tensor phải có cùng kích thước không gian. Vì vậy, tại những khối có đầu vào không tương đồng về chiều cao hoặc chiều rộng, cài đặt thực tế cần thực hiện thao tác tăng hoặc giảm kích thước.

4.5 Kết quả thử nghiệm

Kết quả thử nghiệm được tổng hợp từ quá trình huấn luyện, kiểm định và kiểm thử mô hình LViT trên hai tập dữ liệu QaTa-COV19-v2 và MosMedData+. Với mỗi tập dữ liệu, báo cáo xem xét hai cấu hình: huấn luyện có giám sát hoàn toàn (supervised) và huấn luyện bán giám sát (semi-supervised). Trong cấu hình bán giám sát, một phần dữ liệu được xem như không có nhãn bằng cách bỏ qua mặt nạ gốc trong quá trình huấn luyện, từ đó mô phỏng bối cảnh dữ liệu y khoa thiếu chú thích pixel.



Hình 4.3: So sánh trực quan dự đoán trên QaTa-COV19, thứ tự từ trái sang phải là ảnh gốc, ground truth, mask supervised và mask semi-supervised.



Hình 4.4: So sánh trực quan dự đoán trên MosMedData+, thứ tự trong mỗi nhóm là ảnh gốc, ground truth, mask supervised và mask semi-supervised.

Bảng 4.1: Kết quả huấn luyện, kiểm định và kiểm thử của LViT trên các cấu hình thực nghiệm

Dữ liệu	**Cấu hình**	**Train Dice**	**Val Dice**	**Test Dice**	**Test IoU**
Covid19	Supervised	86.32	79.44	81.27	72.46
Covid19	Semi-supervised	85.91	75.28	76.72	66.93
MosMedData+	Supervised	79.73	67.20	13.39	11.00
MosMedData+	Semi-supervised	78.79	63.86	12.92	10.44

Trên tập Covid19, mô hình đạt kết quả tương đối ổn định. Ở cấu hình supervised, Test Dice đạt 81.27% và Test IoU đạt 72.46%. Đây là kết quả phù hợp với xu hướng quan sát được trong quá trình huấn luyện, vì Train Dice đạt 86.32% và Val Dice đạt 79.44%, cho thấy khoảng cách giữa huấn luyện, kiểm định và kiểm thử không quá lớn. Khi chuyển sang cấu hình semi-supervised, Test Dice giảm còn 76.72% và Test IoU giảm còn 66.93%. Mức giảm này là hợp lý vì mô hình không còn được sử dụng đầy đủ nhãn thật trong quá trình huấn luyện, trong khi phần sinh nhãn giả trong mã nguồn tái lập không hoàn toàn tương đương với một quy trình bán giám sát hoàn chỉnh trong công trình gốc.

Trên tập MosMedData+, kết quả có sự khác biệt rõ rệt giữa train/validation và test. Ở cấu hình supervised, Train Dice đạt 79.73% và Val Dice đạt 67.20%, nhưng Test Dice chỉ đạt 13.39% và Test IoU đạt 11.00%. Cấu hình semi-supervised cũng cho xu hướng tương tự, với Train Dice đạt 78.79%, Val Dice đạt 63.86%, nhưng Test Dice chỉ đạt 12.92% và Test IoU đạt 10.44%. Điều này cho thấy mô hình có học được đặc trưng trên tập huấn luyện, nhưng khả năng tổng quát hóa sang tập kiểm thử của MosMedData+ chưa tốt.

Nguyên nhân của sự khác biệt này đến từ nhiều yếu tố. Thứ nhất, MosMedData+ là dữ liệu CT phổi, có đặc điểm hình ảnh khác với ảnh X-ray trong Covid19.

Dữ liệu CT có cấu trúc lát cắt, độ tương phản, phân bố cường độ và vùng tổn thương phức tạp hơn, nên quá trình tiền xử lý và chuẩn hóa dữ liệu ảnh hưởng mạnh đến chất lượng dự đoán. Thứ hai, phiên bản dữ liệu MosMedData+ được sử dụng trong quá trình tái lập có sự khác biệt về cách tổ chức và định dạng so với dữ liệu được mô tả trong công trình gốc, làm tăng nguy cơ sai khác trong bước đọc ảnh, ánh xạ mặt nạ và chia tập train/validation/test. Thứ ba, do giới hạn thời gian huấn luyện miễn phí trên Kaggle, mô hình chỉ được huấn luyện trong số epoch cố định, trong khi công trình gốc sử dụng cơ chế early stopping và không trình bày rõ số epoch thực tế trước khi dừng. Vì vậy, mô hình trong báo cáo có thể chưa đạt trạng thái hội tụ tốt nhất, đặc biệt trên MosMedData+.

Ngoài ra, trong mã nguồn được công bố của bài báo chính thức, phần học bán giám sát không được cài đặt đầy đủ, do đó báo cáo phải chỉnh sửa mã nguồn để có thể thử nghiệm cấu hình này. Về mặt dữ liệu, dữ liệu không nhãn được tạo ra bằng cách lấy 75% dữ liệu gốc và bỏ qua phần nhãn đính kèm. Cách mô phỏng này giúp kiểm tra ý tưởng học bán giám sát, nhưng vẫn có khoảng cách so với một thiết lập bán giám sát hoàn chỉnh, nơi dữ liệu không nhãn thật sự có thể có phân bố khác và cần cơ chế kiểm soát chất lượng nhãn giả chặt chẽ hơn.

Bảng 4.2: Kết quả so sánh LViT thử nghiệm với LViT công bố và các phương pháp SOTA

Phương pháp	**Văn bản**	**Tỉ lệ nhãn**	**QaTa-COV19**		**MosMedData+**	
			Dice (%)	mIoU (%)	Dice (%)	mIoU (%)
LViT-T-Exp (1/4)	✓	25%	76.72	66.93	12.92	10.44
LViT-T-Exp	✓	100%	81.27	72.46	13.39	11.00
LViT-TW (1/4)	×	25%	79.08	69.42	70.65	58.07
LViT-TW (1/2)	×	50%	80.35	70.74	71.89	59.63
LViT-TW	×	100%	81.12	71.37	72.58	60.40
LViT-T (1/4)	✓	25%	80.95	71.31	72.48	60.31
LViT-T (1/2)	✓	50%	82.73	73.99	73.56	61.05
LViT-T	✓	100%	83.66	75.11	74.57	61.33
U-Net	×	100%	79.02	69.46	64.60	50.73
UNet++	×	100%	79.62	70.25	71.75	58.39
nnUNet	×	100%	80.42	70.81	72.59	60.36
GLoRIA	×	100%	79.94	70.68	72.42	60.18
LAVT	×	100%	79.28	69.89	73.29	60.41

Trong bảng trên, hậu tố **Exp** biểu thị các kết quả được tái lập trong báo

cáo này, lấy từ quá trình huấn luyện và đánh giá thực nghiệm trên môi trường Kaggle. Ký hiệu **T** trong LViT-T chỉ phiên bản Tiny của LViT, trong đó mỗi khối DownViT sử dụng một lớp Transformer. Ký hiệu **W** trong LViT-TW biểu thị biến thể *without text*, tức mô hình không sử dụng chú thích văn bản khi huấn luyện và suy luận. Các dòng không có hậu tố Exp là kết quả được công bố trong bảng so sánh gốc của công trình LViT. Vì vậy, bảng này không chỉ so sánh giữa các phương pháp, mà còn cho thấy khoảng cách giữa kết quả tái lập trong báo cáo và kết quả đã công bố.

Đối với dữ liệu Covid19, kết quả tái lập ở cấu hình 100% nhãn đạt 81.27% Dice và 72.46% mIoU. Khi so với LViT-T công bố ở cùng tỉ lệ nhãn, mô hình tái lập thấp hơn 2.39 điểm Dice và 2.65 điểm mIoU. Khoảng cách này tương đối nhỏ so với các khác biệt thường gặp khi tái lập mô hình học sâu, đặc biệt khi môi trường phần mềm, cách chia dữ liệu và điều kiện dừng huấn luyện không hoàn toàn giống công trình gốc. Kết quả này cho thấy pipeline tái lập trên Covid19 đã giữ được phần lớn hiệu quả của LViT.

Ở cấu hình 25% nhãn, LViT-T-Exp đạt 76.72% Dice và 66.93% mIoU, thấp hơn LViT-T công bố lần lượt 4.23 và 4.38 điểm. Mức giảm này lớn hơn cấu hình 100% nhãn, cho thấy thiết lập bán giám sát trong báo cáo chưa tái hiện đầy đủ hiệu quả của cơ chế học bán giám sát trong công trình gốc. Nguyên nhân chính là phần học bán giám sát trong mã nguồn công bố không được cài đặt đầy đủ, nên báo cáo phải tự điều chỉnh để mô phỏng dữ liệu không nhãn bằng cách bỏ qua nhãn của một phần dữ liệu gốc.

Đối với MosMedData+, sự khác biệt giữa kết quả tái lập và kết quả công bố là rất lớn. Ở cấu hình 100% nhãn, LViT-T công bố đạt 74.57% Dice và 61.33% mIoU, trong khi LViT-T-Exp chỉ đạt 13.39% Dice và 11.00% mIoU. Ở cấu hình 25% nhãn, kết quả tái lập cũng chỉ đạt 12.92% Dice và 10.44% mIoU, thấp hơn rất nhiều so với 72.48% Dice và 60.31% mIoU của LViT-T công bố. Điều này cho thấy mô hình tái lập trên MosMedData+ chưa tổng quát tốt sang tập kiểm thử, mặc dù Train Dice và Val Dice vẫn đạt mức tương đối cao trong bảng kết quả phía trên.

Khi so sánh giữa LViT-T và LViT-TW trong kết quả công bố, có thể thấy thông tin văn bản giúp cải thiện hiệu suất ở cả hai bộ dữ liệu. Với 100% nhãn, LViT-T tăng từ 81.12% lên 83.66% Dice trên QaTa-COV19 và từ 72.58% lên 74.57% Dice trên MosMedData+ so với LViT-TW. Điều này củng cố nhận định

rằng chú thích văn bản đóng vai trò như tín hiệu ngữ nghĩa bổ sung, giúp mô hình định hướng vùng cần phân đoạn tốt hơn so với chỉ sử dụng đặc trưng ảnh.

Mặt khác, trong các kết quả công bố của LViT, cấu hình chỉ sử dụng 25% dữ liệu có nhãn vẫn đạt Dice và mIoU tương đối ổn định so với nhiều phương pháp SOTA sử dụng toàn bộ nhãn. Điều này cho thấy cơ chế tạo nhãn giả EPI có vai trò quan trọng trong việc khai thác phần dữ liệu không nhãn: thay vì chỉ học từ số lượng mặt nạ thủ công bị giới hạn, mô hình có thể tận dụng dự đoán trung gian để bổ sung tín hiệu giám sát trong quá trình huấn luyện. Nhờ đó, không gian đặc trưng học được ít phụ thuộc hơn vào một tập nhãn nhỏ ban đầu và có khả năng bao quát tốt hơn các biến thiên về hình dạng, kích thước và vị trí tổn thương.

Tuy nhiên, kết quả tái lập trong báo cáo này cũng cho thấy hiệu quả của cấu hình 25% nhãn phụ thuộc mạnh vào mức độ hoàn chỉnh của quy trình bán giám sát. Trên Covid19, LViT-T-Exp vẫn đạt kết quả chấp nhận được dù thấp hơn mô hình công bố, cho thấy ý tưởng tận dụng dữ liệu ít nhãn vẫn có giá trị trong điều kiện thực nghiệm hạn chế. Ngược lại, trên MosMedData+, kết quả thấp cho thấy cách mô phỏng dữ liệu không nhãn bằng việc bỏ qua nhãn gốc chưa đủ để tái hiện đầy đủ lợi ích của EPI, đặc biệt khi dữ liệu CT có cấu trúc lát cắt phức tạp, vùng tổn thương khó phân biệt và thời gian huấn luyện bị giới hạn. Vì vậy, EPI có tiềm năng giúp giảm chi phí chú thích dữ liệu y khoa, nhưng cần quy trình sinh, lọc và cập nhật nhãn giả chặt chẽ hơn để phát huy hiệu quả ổn định.

Chương 5

Kết luận

5.1 Tổng kết

Báo cáo đã trình bày quá trình tìm hiểu, phân tích và cài đặt mô hình LViT cho bài toán phân đoạn ảnh y khoa có điều kiện theo câu nhắc văn bản. Khác với các phương pháp phân đoạn truyền thống chỉ dựa trên thông tin thị giác, LViT khai thác đồng thời đặc trưng ảnh và đặc trưng ngôn ngữ nhằm giúp mô hình tập trung tốt hơn vào vùng tổn thương được mô tả trong câu nhắc. Cách tiếp cận này phù hợp với bối cảnh y khoa, nơi thông tin hình ảnh thường đi kèm với mô tả lâm sàng, vị trí tổn thương hoặc ghi chú chuyên môn từ bác sĩ.

Về mặt phương pháp, báo cáo đã phân tích các thành phần chính của kiến trúc LViT, bao gồm nhánh CNN U-shape, nhánh ViT U-shape, bộ mã hóa văn bản, mô-đun Patch Embedding, mô-đun Reconstruct, PLAM, Language-Vision Loss và cơ chế sinh nhãn giả EPI. Nhánh CNN giúp bảo toàn thông tin không gian và chi tiết cục bộ của ảnh, trong khi nhánh ViT hỗ trợ học quan hệ toàn cục giữa các vùng ảnh thông qua cơ chế attention. Đặc trưng văn bản được đưa vào mô hình như một tín hiệu điều kiện, giúp quá trình phân đoạn không chỉ phụ thuộc vào ảnh đầu vào mà còn được định hướng bởi mô tả ngữ nghĩa.

Báo cáo cũng đã trình bày ba pipeline chính của hệ thống: pipeline huấn luyện ngoại tuyến, pipeline suy luận sau huấn luyện và pipeline tính toán hàm mất mát kết hợp với sinh nhãn giả. Các pipeline này cho thấy LViT không chỉ là một mô hình phân đoạn ảnh đơn thuần, mà là một hệ thống đa phương thức có khả năng kết hợp dữ liệu ảnh, văn bản, nhãn chuẩn và nhãn giả. Trong đó, cơ chế EPI và cách sử dụng nhãn mềm giúp mô hình tận dụng dữ liệu không nhãn ở mức phương pháp luận, đồng thời giảm sự phụ thuộc vào các nhãn nhị phân cứng trong quá trình huấn luyện.

Về mặt cài đặt, báo cáo đã mô tả môi trường thử nghiệm, cấu trúc mã nguồn và các điều chỉnh cần thiết để tái lập mô hình trong môi trường hiện tại.

Do có sự khác biệt giữa môi trường thực thi của công trình gốc và môi trường thử nghiệm trong báo cáo, một số thành phần mã nguồn cần được chỉnh sửa để tương thích với phiên bản thư viện mới, cách tổ chức dữ liệu và giới hạn tài nguyên trên Kaggle. Những chỉnh sửa này chủ yếu mang tính kỹ thuật, không làm thay đổi bản chất kiến trúc hay ý tưởng phương pháp của LViT.

5.2 Hạn chế

Mặc dù báo cáo đã trình bày đầy đủ kiến trúc và quy trình cài đặt của LViT, quá trình thực nghiệm vẫn còn một số hạn chế. Thứ nhất, báo cáo chỉ tập trung huấn luyện và đánh giá trên các tập dữ liệu có nhãn như QaTa-COV19-v2 và MosMedData+. Các cơ chế học bán giám sát và sinh nhãn giả được phân tích ở mức phương pháp luận, nhưng chưa được triển khai đầy đủ trong phần thực nghiệm. Do đó, báo cáo chưa đánh giá được toàn diện tác động của EPI đối với dữ liệu không nhãn.

Thứ hai, khả năng truy cập dữ liệu y khoa còn bị giới hạn. Tập ESO-CT được đề cập trong phần phương pháp, nhưng không được sử dụng trong thực nghiệm do dữ liệu chưa được công bố công khai tại thời điểm thực hiện báo cáo. Điều này làm giảm phạm vi đánh giá của mô hình trên các loại ảnh và bệnh lý khác nhau.

Thứ ba, quá trình tái lập mô hình chịu ảnh hưởng bởi sự khác biệt về môi trường phần mềm, cấu trúc dữ liệu và tài nguyên tính toán. Một số siêu tham số và bước xử lý cần được điều chỉnh để phù hợp với môi trường Kaggle, vì vậy kết quả thực nghiệm có thể khác so với công trình gốc nếu điều kiện huấn luyện không hoàn toàn giống nhau.

5.3 Hướng phát triển

Trong tương lai, hướng phát triển đầu tiên là hoàn thiện phần thực nghiệm bán giám sát bằng cách triển khai đầy đủ cơ chế sinh nhãn giả EPI trên dữ liệu không nhãn. Việc này sẽ giúp đánh giá rõ hơn khả năng tận dụng dữ liệu y khoa chưa được chú thích, vốn là một vấn đề quan trọng trong thực tế do chi phí gán nhãn cao.

Hướng phát triển tiếp theo là mở rộng đánh giá trên nhiều bộ dữ liệu và

nhiều loại ảnh y khoa hơn, chẳng hạn CT, MRI, X-ray hoặc ảnh mô bệnh học. Việc thử nghiệm trên nhiều miền dữ liệu khác nhau sẽ giúp kiểm tra khả năng tổng quát hóa của LViT, đồng thời làm rõ mức độ phụ thuộc của mô hình vào cấu trúc câu nhắc văn bản và chất lượng chú thích.

Ngoài ra, có thể nghiên cứu thêm các cách mã hóa văn bản mạnh hơn thay vì chỉ sử dụng lớp embedding của BERT. Việc khai thác sâu hơn ngữ cảnh trong câu mô tả y khoa có thể giúp mô hình hiểu tốt hơn các quan hệ phức tạp như vị trí tổn thương, mức độ lan rộng, số lượng vùng bệnh lý hoặc đặc điểm hình thái. Bên cạnh đó, các mô hình nền tảng y khoa hiện đại cũng có thể được tích hợp để cải thiện khả năng căn chỉnh giữa đặc trưng ảnh và đặc trưng ngôn ngữ.

Tóm lại, LViT là một hướng tiếp cận tiềm năng cho bài toán phân đoạn ảnh y khoa đa phương thức. Bằng cách kết hợp thông tin thị giác và ngôn ngữ, mô hình có thể tận dụng tốt hơn tri thức mô tả từ chuyên gia và hỗ trợ phân đoạn theo ngữ cảnh cụ thể. Dù vẫn còn một số hạn chế trong quá trình tái lập và thực nghiệm, báo cáo đã làm rõ được cơ sở phương pháp, kiến trúc mô hình và các vấn đề kỹ thuật quan trọng khi triển khai LViT trong thực tế.

Tài liệu tham khảo

[1] Zihan Li **andothers**. *LViT: Language meets Vision Transformer in Medical Image Segmentation*. en. arXiv:2206.14718 [cs]. **june** 2023. DOI: 10.48550/arXiv.2206.14718. URL: http://arxiv.org/abs/2206.14718 (**urlseen** 23/03/2026).

[2] Zhao Yang **andothers**. *LAVT: Language-Aware Vision Transformer for Referring Image Segmentation*. Version Number: 2. 2021. DOI: 10.48550/ARXIV.2112.02244. URL: https://arxiv.org/abs/2112.02244 (**urlseen** 13/04/2026).

[3] Qijie Wang, Xian Lin **and** Zengqiang Yan. "Towards Robust Medical Image Referring Segmentation with Incomplete Textual Prompts". en. **in**().

[4] Timo Lüddecke **and** Alexander S. Ecker. *Image Segmentation Using Text and Image Prompts*. Version Number: 2. 2021. DOI: 10.48550/ARXIV.2112.10003. URL: https://arxiv.org/abs/2112.10003 (**urlseen** 13/04/2026).

[5] Tianhe Ren **andothers**. *Grounded SAM: Assembling Open-World Models for Diverse Visual Tasks*. Version Number: 1. 2024. DOI: 10.48550/ARXIV.2401.14159. URL: https://arxiv.org/abs/2401.14159 (**urlseen** 13/04/2026).

[6] Jong Hak Moon **andothers**. "Multi-modal Understanding and Generation for Medical Images and Text via Vision-Language Pre-Training". **in**(2021): Version Number: 3. DOI: 10.48550/ARXIV.2105.11333. URL: https://arxiv.org/abs/2105.11333 (**urlseen** 13/04/2026).

[7] Fuying Wang **andothers**. *Multi-Granularity Cross-modal Alignment for Generalized Medical Visual Representation Learning*. Version Number: 1. 2022. DOI: 10.48550/ARXIV.2210.06044. URL: https://arxiv.org/abs/2210.06044 (**urlseen** 13/04/2026).