

PHÂN ĐOẠN ẢNH VỚI DỮ LIỆU NHÃN HẠN CHẾ + TEXT PROMPT

Đề án môn học: Ứng dụng Xử lý ảnh và video

Chung Tín Đạt MSSV: 23122024

Nhóm: CTD

Giảng viên hướng dẫn: PGS. TS. Lý Quốc Ngọc

Khoa Công nghệ Thông tin

Trường Đại học Khoa học Tự nhiên

Ngày 14 tháng 4 năm 2026



Mục lục

- 1 Giới thiệu
 - Bối cảnh
 - Động lực nghiên cứu
 - Ý nghĩa khoa học
 - Ý nghĩa thực tiễn
 - Phát biểu bài toán
- 2 Các công trình nghiên cứu liên quan
- 3 Phương pháp
 - Dữ liệu
 - Kiến trúc mô hình
 - Hàm mất mát
 - Cơ chế sinh nhãn giả
- 4 Cài đặt và thử nghiệm
- 5 Kết luận và hướng phát triển
 - Kết luận
 - Hướng phát triển



Mục lục

- 1 Giới thiệu
 - Bối cảnh
 - Động lực nghiên cứu
 - Ý nghĩa khoa học
 - Ý nghĩa thực tiễn
 - Phát biểu bài toán
- 2 Các công trình nghiên cứu liên quan
- 3 Phương pháp
 - Dữ liệu
 - Kiến trúc mô hình
 - Hàm mất mát
 - Cơ chế sinh nhãn giả
- 4 Cài đặt và thử nghiệm
- 5 Kết luận và hướng phát triển
 - Kết luận
 - Hướng phát triển



Giới thiệu: Bối cảnh

Trong thập kỷ qua, các mạng học sâu (CNN, Vision Transformer) chủ yếu hoạt động dựa trên *Closed-vocabulary*. Các mô hình này bị giới hạn bởi tập dữ liệu huấn luyện và thiếu khả năng tổng quát hóa khi chuyển sang các miền dữ liệu mới.

Sự xuất hiện của các mô hình nền tảng (Foundation Models) như CLIP và SAM đã thúc đẩy sự chuyển dịch sang *Open-vocabulary Segmentation*. Các mô hình theo kiến trúc này có khả năng phân đoạn các đối tượng chưa từng xuất hiện trong quá trình huấn luyện thông qua các thông tin mô tả bổ sung (prompts).



Giới thiệu: Bối cảnh

Tuy nhiên, trong lĩnh vực y khoa, các mô hình phân đoạn bệnh vẫn bị giới hạn bởi sự thiếu sót về tập dữ liệu được dán nhãn chất lượng cao [1].

Bên cạnh dữ liệu hình ảnh, các mô hình có xu hướng phát triển các cơ chế học dựa trên câu nhắc (*Prompting*) nhằm tận dụng tri thức đa phương thức.

Mô hình tiêu biểu:

- **MedSAM:** Sử dụng *visual prompts* (points/boxes) để hướng dẫn vùng tập trung.
- **LViT:** Tích hợp *text prompts* để nhúng kiến thức bệnh lý vào quá trình phân đoạn, giúp cải thiện hiệu suất trong điều kiện dữ liệu nhãn hạn chế.



Giới thiệu: Bối cảnh

Sự hiệu quả của các kiến trúc kết hợp Prompting bắt nguồn từ khả năng thiết lập một không gian biểu diễn chung giữa thị giác và ngôn ngữ thông qua cơ chế căn chỉnh đa phương thức. Quá trình này tạo ra một bộ lọc ngữ nghĩa mạnh mẽ, giúp mô hình tự động loại bỏ các vùng nhiễu và tập trung tối đa vào các cấu trúc giải phẫu được mô tả cụ thể trong câu lệnh dẫn dắt.

Thay vì chỉ biết đây là "khối u", văn bản cung cấp các đặc điểm hình thái chuyên sâu: *"bờ không đều"*, *"mật độ thấp"*, *"thâm nhiễm xung quanh"*. Ngôn ngữ y khoa giúp mô hình "hiểu" được các ràng buộc sinh học của cơ quan, từ đó đưa ra mặt nạ phân đoạn hợp lý hơn về mặt y khoa.



Giới thiệu: Động lực nghiên cứu: Ý nghĩa khoa học

Sự phát triển của trí tuệ nhân tạo và thị giác máy tính trong nhiều lĩnh vực đã chứng minh vai trò của việc phân đoạn ảnh tự động. Tuy nhiên, các tập dữ liệu để đáp ứng nhu cầu huấn luyện với các nhãn chất lượng cao vẫn chưa được đáp ứng. Việc tạo ra các nhãn chuẩn này không chỉ tiêu tốn chi phí và thời gian mà còn đòi hỏi sự tham gia trực tiếp của các chuyên gia, khiến việc mở rộng mô hình cho các hiện tượng, bệnh lý hiếm hoặc các thiết bị hình ảnh mới trở nên vô cùng khó khăn.



Giới thiệu: Động lực nghiên cứu: Ý nghĩa khoa học

Động lực chính của nghiên cứu này xuất phát từ việc khai thác nguồn tri thức lâm sàng dồi dào tồn tại dưới dạng ngôn ngữ tự nhiên. Chỉ sử dụng thông tin hình ảnh để mô hình xử lý là không phù hợp trong thực tế các lĩnh vực.

Đặc biệt trong y khoa, mỗi hình ảnh chụp chiếu luôn đi kèm với các báo cáo bệnh lý chi tiết, chứa đựng những mô tả tinh vi về đặc điểm hình thái và vị trí tổn thương mà nhãn pixel đơn thuần không thể truyền tải hết. Việc phát triển các kiến trúc hướng văn bản không chỉ đơn thuần là một cải tiến về mặt kỹ thuật, mà là một nỗ lực nhằm "dạy" cho máy tính cách hiểu kiến thức chuyên ngành thông qua lăng kính tri thức của chuyên gia.



Giới thiệu: Động lực nghiên cứu: Ý nghĩa thực tiễn

Nghiên cứu này còn được thúc đẩy bởi nhu cầu về một hệ thống AI có tính tương tác và linh hoạt. Thay vì một mô hình "hộp đen" chỉ đưa ra kết quả cố định, sự hỗ trợ của text prompt cho phép chuyên gia trực tiếp điều chỉnh và tinh chỉnh vùng phân đoạn thông qua các câu lệnh mô tả, tạo nên một vòng lặp cộng tác giữa người và máy.

Đây chính là chìa khóa để giải quyết bài toán thiếu hụt dữ liệu, đồng thời mở ra khả năng cá nhân hóa chẩn đoán trong y khoa, giúp AI trở nên gần gũi và hiệu quả hơn trong môi trường lâm sàng thực tế, giúp các mô hình có thể thích nghi nhanh với bệnh lý mới thông qua mô tả thay vì phải huấn luyện lại từ đầu.



Giới thiệu: Phát biểu bài toán

Phân đoạn ảnh là quá trình nhóm các pixel thuộc cùng một đối tượng ngữ nghĩa và tách biệt khỏi các nhóm đối tượng khác. Có thể hiểu, phân đoạn ảnh là tìm cách làm giảm một *khoảng cách được định nghĩa trước* của các pixel thuộc cùng đối tượng và làm tăng *khoảng cách* với các pixel thuộc đối tượng khác.



Giới thiệu: Phát biểu bài toán

Với các mô hình phân đoạn kết hợp câu nhắc văn bản (text prompt), có thể định nghĩa như sau:

Đầu vào:

Một ảnh kích thước $H \times W$ được xem như hàm số $I : \Omega \rightarrow \mathbb{R}^C$

$$\Omega = \{(x, y) | 1 \leq x \leq H, 1 \leq y \leq W\} \quad C = \{1, 3\}$$

Câu nhắc văn bản là một chuỗi các token $T = \{w_1, w_2, \dots, w_L\}$

Đầu ra:

Mặt nạ phân đoạn M tập hợp các giá trị 0, 1 tương ứng đại diện cho pixel thuộc hoặc không thuộc đối tượng.

$$M(x, y) = \begin{cases} 1 & \text{nếu } (x, y) \in \text{vùng mục tiêu được chỉ định bởi } T \\ 0 & \text{nếu ngược lại} \end{cases}$$



Giới thiệu: Phát biểu bài toán

Bài toán phân đoạn dựa trên văn bản là tìm kiếm một ánh xạ F sao cho:

$$F : (I, T) \rightarrow M$$

Quy trình thực hiện: Các mô hình phân đoạn dựa trên câu nhắc văn bản là sự kết hợp giữa hai hàm trích xuất đặc trưng (Encoders), một hàm tương tác giữa các phương thức, một hàm tạo mặt nạ phân đoạn (Decoder).



Giới thiệu: Phát biểu bài toán

- ① Trích xuất đặc trưng thị giác (E_v): Biến đổi ảnh thành một vector đặc trưng trong không gian d chiều.

$$f_v = E_v(I) \in \mathbb{R}^{h \times w \times d}$$

- ② Trích xuất đặc trưng ngôn ngữ (E_l): Biến đổi văn bản thành một vector đặc trưng trong không gian d' chiều.

$$f_l = E_l(T) \in \mathbb{R}^{L \times d'}$$

- ③ Đưa các đặc trưng về không gian nhúng chung D .


- Ảnh: $z_v = f_v \cdot W_v + b_v$ $W_v \in \mathbb{R}^{d \times D}$ $z_v \in \mathbb{R}^{(h \times w) \times D}$
- Văn bản: $z_l = f_l \cdot W_l + b_l$ $W_l \in \mathbb{R}^{d' \times D}$ $z_l \in \mathbb{R}^{L \times D}$

- ④ Tương tác và giải mã mặt nạ (ϕ, P): Các đặc trưng hình ảnh và văn bản tương tác với nhau để làm giàu thông tin hình ảnh. Sau khi có đặc trưng hợp nhất, hàm cho ra mặt nạ phân đoạn.

$$f_u = \phi(z_v, z_l) \quad f_u \in \mathbb{R}^{(h \times w) \times D}$$

$$M = P(f_u)$$





Hình 1: Pipeline hoạt động của mô hình

Mục lục

- 1 Giới thiệu
 - Bối cảnh
 - Động lực nghiên cứu
 - Ý nghĩa khoa học
 - Ý nghĩa thực tiễn
 - Phát biểu bài toán
- 2 Các công trình nghiên cứu liên quan
- 3 Phương pháp
 - Dữ liệu
 - Kiến trúc mô hình
 - Hàm mất mát
 - Cơ chế sinh nhãn giả
- 4 Cài đặt và thử nghiệm
- 5 Kết luận và hướng phát triển
 - Kết luận
 - Hướng phát triển



Các công trình nghiên cứu liên quan

Công trình	Đầu vào	Đầu ra
[2] MedViLL	Ảnh X-quang ngực (chụp thẳng) và văn bản báo cáo lâm sàng	Phân loại chẩn đoán, truy xuất ảnh-báo cáo, VQA y tế và tạo báo cáo
[3] MGCA	Ảnh X-quang ngực và văn bản báo cáo y tế	Biểu diễn thị giác dùng để chuyển giao cho tác vụ phân loại, phát hiện, phân vùng
[4] LAVT	Một bức ảnh và một đoạn văn bản mô tả đối tượng cần tìm	Mask phân vùng ở mức độ điểm ảnh của đối tượng
[1] LViT	Ảnh y tế (X-quang, CT) và văn bản ghi chú y tế (text annotation)	Mask phân vùng ngữ nghĩa mức độ điểm ảnh



Các công trình nghiên cứu liên quan

Công trình	Image Encoder	Text Encoder
[2] MedViLL	ResNet-50	BERT Wordpiece Tokenizer
[3] MGCA	ViT-B/16 hoặc ResNet-50	BioClinical BERT
[4] LAVT	Hierarchical Vision Transformer	BERT base model
[1] LViT	Nhánh CNN dạng U- shape kết hợp với nhánh ViT dạng U-shape	BERT-Embed



Các công trình nghiên cứu liên quan

Công trình	Objective	Kế thừa
[2] MedViLL	Masked Language Modeling (MLM) và Image Report Matching (IRM)	BERT và ResNet
[3] MGCA	InfoNCE loss (cho ITA, CTA) và Cross-entropy (cho CPA)	ViT/ResNet và BERT
[4] LAVT	Cross-entropy	Swin Transformer và BERT
[1] LViT	LV (Language-Vision) loss kết hợp Dice loss & Cross-entropy	U-Net, CNN, ViT và BERT



Các công trình nghiên cứu liên quan

Công trình	Đóng góp
[2] MedViLL	Đề xuất cơ chế Bidirectional Auto-regressive (BAR) self-attention giúp giải quyết đồng thời bài toán hiểu (VLU) và tạo văn bản (VLG)
[3] MGCA	Khung căn chỉnh đa phương thức đa độ hạt (MGCA) ở 3 mức: token, instance, và prototype (cấp độ bệnh lý) giúp học đặc trưng toàn diện
[4] LAVT	Thiết kế Pixel-Word Attention Module (PWAM) để hợp nhất thông tin ngôn ngữ và thị giác từ sớm ngay tại các tầng của Vision Transformer
[1] LViT	Kết hợp văn bản y tế để bù đắp sự thiếu hụt chất lượng ảnh. Đề xuất cơ chế Exponential Pseudo label Iteration (EPI) nâng cao chất lượng nhãn giả trong học bán giám sát và dùng PLAM để giữ đặc trưng cục bộ



Các công trình nghiên cứu liên quan

Công trình	Khó khăn
[2] MedViLL	Dữ liệu y tế có chiều không gian lớn, tính không đồng nhất và thiên vị. Việc học chung cho cả tác vụ VLU và VLG rất khó khăn
[3] MGCA	Các phương pháp trước đây bỏ qua quan hệ ngữ nghĩa ở mức bệnh lý. Các vùng chứa bệnh lý (pathology) trong ảnh thường rất nhỏ
[4] LAVT	Các phương pháp cũ dùng bộ giải mã đa phương thức (cross-modal decoder) cồng kềnh, chưa khai thác hết sức mạnh bồi cảnh của Transformer
[1] LViT	Khó khăn lấy dữ liệu dán nhãn chất lượng cao do chi phí y tế đắt đỏ. Ranh giới tổn thương y tế mờ, khó căn chỉnh chính xác ảnh-text; chi phí tính toán của self-attention cao



Mục lục

- 1 Giới thiệu
 - Bối cảnh
 - Động lực nghiên cứu
 - Ý nghĩa khoa học
 - Ý nghĩa thực tiễn
 - Phát biểu bài toán
- 2 Các công trình nghiên cứu liên quan
- 3 Phương pháp
 - Dữ liệu
 - Kiến trúc mô hình
 - Hàm mất mát
 - Cơ chế sinh nhãn giả
- 4 Cài đặt và thử nghiệm
- 5 Kết luận và hướng phát triển
 - Kết luận
 - Hướng phát triển



Phương pháp: Dữ liệu

- 1 QaTa-COV19: bao gồm 9258 ảnh X-ray ngực được ghi chú thủ công thương tổn do COVID-19 lần đầu tiên. Nhóm nghiên cứu đã mở rộng ghi chú với sự hỗ trợ của các chuyên gia. Ghi chú tập trung vào cả hai phổi có nhiễm bệnh, số vùng thương tổn, vị trí tương đối của vùng nhiễm bệnh. Ví dụ: "Bilateral pulmonary infection, two infected areas, upper left lung and upper right lung" (tạm dịch: "Cả hai phổi bị nhiễm bệnh, hai vùng bị nhiễm, phía trên phổi trái và phía trên phổi phải").
- 2 MosMesData+¹: bao gồm 2729 ảnh CT scan về nhiễm trùng phổi. Ghi chú của tập dữ liệu có cấu trúc tương tự QaTa-COV19. Ví dụ: "Unilateral pulmonary infection, two infected areas, middle lower left lung" (tạm dịch: "Một bên phổi bị nhiễm bệnh, hai vùng bị nhiễm, ở giữa phía dưới phổi trái").
- 3 ESO-CT: bao gồm 286 ảnh X-ray được ghi chú độc lập bởi hai chuyên gia.

¹<http://medicalsegmentation.com/covid19>

Phương pháp: Kiến trúc mô hình

- 1 Nhánh CNN U-shape
- 2 Nhánh ViT U-shape




Phương pháp: Kiến trúc mô hình: CNN

Nhánh CNN nhận đầu vào là một ảnh và đầu ra là mặt nạ phân đoạn.

$$D_i = \text{DownCNN}_i = \text{CTBN} \\ = \text{ReLU}(\text{BatchNorm}_i(\text{Conv}_i(\cdot)))$$


$$Y_{\text{DownCNN},i+1} = \text{MaxPool}(D_i(Y_{\text{DownCNN},i}))$$

$$Y_{\text{DownCNN},1} = I$$



Phương pháp: Kiến trúc mô hình: ViT

Nhánh ViT nhận đầu vào là đặc trưng ảnh của khối DownCNN đầu tiên cùng với đặc trưng văn bản từ lớp BERT-Embed từ BERT_12_768_12.



$$ViT(x) = ViT_2(ViT_1(x))$$

$$x' = ViT_1(x) = MHSA(LN(x)) + x$$

$$Y = ViT_2(x') = MLP(LN(x')) + x'$$

$$x_{img,i} = PatchEmbedding(Y_{DownCNN,i})$$

$$Y_{DownViT,1} = ViT(x_{img,1} + CTBN(x_{text}))$$

$$Y_{DownViT,i+1} = ViT(Y_{DownViT,i} + x_{img,i+1})$$



Hello world. Tôi là Chung Tín Đạt



Mục lục

- 1 Giới thiệu
 - Bối cảnh
 - Động lực nghiên cứu
 - Ý nghĩa khoa học
 - Ý nghĩa thực tiễn
 - Phát biểu bài toán
- 2 Các công trình nghiên cứu liên quan
- 3 Phương pháp
 - Dữ liệu
 - Kiến trúc mô hình
 - Hàm mất mát
 - Cơ chế sinh nhãn giả
- 4 Cài đặt và thử nghiệm
- 5 Kết luận và hướng phát triển
 - Kết luận
 - Hướng phát triển



Cài đặt và thử nghiệm

Hello world. Tôi là Chung Tín Đạt



Mục lục

- 1 Giới thiệu
 - Bối cảnh
 - Động lực nghiên cứu
 - Ý nghĩa khoa học
 - Ý nghĩa thực tiễn
 - Phát biểu bài toán
- 2 Các công trình nghiên cứu liên quan
- 3 Phương pháp
 - Dữ liệu
 - Kiến trúc mô hình
 - Hàm mất mát
 - Cơ chế sinh nhãn giả
- 4 Cài đặt và thử nghiệm
- 5 Kết luận và hướng phát triển
 - Kết luận
 - Hướng phát triển



Kết luận và hướng phát triển: Kết luận

Hello world. Tôi là Chung Tín Đạt



-  **Zihan Li and others.** *LViT: Language meets Vision Transformer in Medical Image Segmentation.* en. [arXiv:2206.14718](https://arxiv.org/abs/2206.14718) [cs]. **june 2023.** DOI: [10.48550/arXiv.2206.14718](https://doi.org/10.48550/arXiv.2206.14718). URL: <http://arxiv.org/abs/2206.14718> (**urlseen 23/03/2026**).
-  **Jong Hak Moon and others.** “Multi-modal Understanding and Generation for Medical Images and Text via Vision-Language Pre-Training”. **in(2021):** Version Number: 3. DOI: [10.48550/ARXIV.2105.11333](https://doi.org/10.48550/ARXIV.2105.11333). URL: <https://arxiv.org/abs/2105.11333> (**urlseen 13/04/2026**).
-  **Fuying Wang and others.** *Multi-Granularity Cross-modal Alignment for Generalized Medical Visual Representation Learning.* Version Number: 1. 2022. DOI: [10.48550/ARXIV.2210.06044](https://doi.org/10.48550/ARXIV.2210.06044). URL: <https://arxiv.org/abs/2210.06044> (**urlseen 13/04/2026**).





Zhao Yang and others. *LAVT: Language-Aware Vision Transformer for Referring Image Segmentation.* Version Number: 2. 2021. DOI: 10.48550/ARXIV.2112.02244. URL: <https://arxiv.org/abs/2112.02244> (**urlseen** 13/04/2026).

