

PHÂN ĐOẠN ẢNH VỚI DỮ LIỆU NHÃN HẠN CHẾ + TEXT PROMPT

Đề án môn học: Ứng dụng Xử lý ảnh và video

Chung Tín Đạt MSSV: 23122024

Nhóm: CTD

Giảng viên hướng dẫn: PGS. TS. Lý Quốc Ngọc

Khoa Công nghệ Thông tin

Trường Đại học Khoa học Tự nhiên

Ngày 21 tháng 4 năm 2026



1 Giới thiệu

- Bối cảnh
- Động lực nghiên cứu
 - Ý nghĩa khoa học
 - Ý nghĩa thực tiễn
- Phát biểu bài toán

2 Phương pháp

- Dữ liệu
- Kiến trúc mô hình
- Hàm mất mát
- Cơ chế sinh nhãn giả

3 Cài đặt và thử nghiệm

4 Kết luận và hướng phát triển

- Kết luận
- Hướng phát triển



1 Giới thiệu

- Bối cảnh
- Động lực nghiên cứu
 - Ý nghĩa khoa học
 - Ý nghĩa thực tiễn
- Phát biểu bài toán

2 Phương pháp

- Dữ liệu
- Kiến trúc mô hình
- Hàm mất mát
- Cơ chế sinh nhãn giả

3 Cài đặt và thử nghiệm

4 Kết luận và hướng phát triển

- Kết luận
- Hướng phát triển



Giới thiệu: Bối cảnh

Trong thập kỷ qua, các mạng học sâu (CNN, Vision Transformer) chủ yếu hoạt động dựa trên *Closed-vocabulary*. Các mô hình này bị giới hạn bởi tập dữ liệu huấn luyện và thiếu khả năng tổng quát hóa khi chuyển sang các miền dữ liệu mới.

Sự xuất hiện của các mô hình nền tảng (Foundation Models) như CLIP và SAM đã thúc đẩy sự chuyển dịch sang *Open-vocabulary Segmentation*. Các mô hình theo kiến trúc này có khả năng phân đoạn các đối tượng chưa từng xuất hiện trong quá trình huấn luyện thông qua các thông tin mô tả bổ sung (prompts).



Giới thiệu: Bối cảnh

Tuy nhiên, trong lĩnh vực y khoa, các mô hình phân đoạn bệnh vẫn bị giới hạn bởi sự thiếu sót về tập dữ liệu được dán nhãn chất lượng cao [1].

Bên cạnh dữ liệu hình ảnh, các mô hình có xu hướng phát triển các cơ chế học dựa trên câu nhắc (*Prompting*) nhằm tận dụng tri thức đa phương thức.

Mô hình tiêu biểu:

- **MedSAM:** Sử dụng *visual prompts* (points/boxes) để hướng dẫn vùng tập trung.
- **LViT:** Tích hợp *text prompts* để nhúng kiến thức bệnh lý vào quá trình phân đoạn, giúp cải thiện hiệu suất trong điều kiện dữ liệu nhãn hạn chế.



Giới thiệu: Bối cảnh

Sự hiệu quả của các kiến trúc kết hợp Prompting bắt nguồn từ khả năng thiết lập một không gian biểu diễn chung giữa thị giác và ngôn ngữ thông qua cơ chế căn chỉnh đa phương thức. Quá trình này tạo ra một bộ lọc ngữ nghĩa mạnh mẽ, giúp mô hình tự động loại bỏ các vùng nhiễu và tập trung tối đa vào các cấu trúc giải phẫu được mô tả cụ thể trong câu lệnh dẫn dắt.

Thay vì chỉ biết đây là "khối u", văn bản cung cấp các đặc điểm hình thái chuyên sâu: *"bờ không đều"*, *"mật độ thấp"*, *"thâm nhiễm xung quanh"*. Ngôn ngữ y khoa giúp mô hình "hiểu" được các ràng buộc sinh học của cơ quan, từ đó đưa ra mặt nạ phân đoạn hợp lý hơn về mặt y khoa.



Sự phát triển của trí tuệ nhân tạo và thị giác máy tính trong nhiều lĩnh vực đã chứng minh vai trò của việc phân đoạn ảnh tự động. Tuy nhiên, các tập dữ liệu để đáp ứng nhu cầu huấn luyện với các nhãn chất lượng cao vẫn chưa được đáp ứng. Việc tạo ra các nhãn chuẩn này không chỉ tiêu tốn chi phí và thời gian mà còn đòi hỏi sự tham gia trực tiếp của các chuyên gia, khiến việc mở rộng mô hình cho các hiện tượng, bệnh lý hiếm hoặc các thiết bị hình ảnh mới trở nên vô cùng khó khăn.



Giới thiệu: Động lực nghiên cứu: Ý nghĩa khoa học

Động lực chính của nghiên cứu này xuất phát từ việc khai thác nguồn tri thức lâm sàng dồi dào tồn tại dưới dạng ngôn ngữ tự nhiên. Chỉ sử dụng thông tin hình ảnh để mô hình xử lý là không phù hợp trong thực tế các lĩnh vực.

Đặc biệt trong y khoa, mỗi hình ảnh chụp chiếu luôn đi kèm với các báo cáo bệnh lý chi tiết, chứa đựng những mô tả tinh vi về đặc điểm hình thái và vị trí tổn thương mà nhãn pixel đơn thuần không thể truyền tải hết. Việc phát triển các kiến trúc hướng văn bản không chỉ đơn thuần là một cải tiến về mặt kỹ thuật, mà là một nỗ lực nhằm "dạy" cho máy tính cách hiểu kiến thức chuyên ngành thông qua lăng kính tri thức của chuyên gia.



Giới thiệu: Động lực nghiên cứu: Ý nghĩa thực tiễn

Nghiên cứu này còn được thúc đẩy bởi nhu cầu về một hệ thống AI có tính tương tác và linh hoạt. Thay vì một mô hình "hộp đen" chỉ đưa ra kết quả cố định, sự hỗ trợ của text prompt cho phép chuyên gia trực tiếp điều chỉnh và tinh chỉnh vùng phân đoạn thông qua các câu lệnh mô tả, tạo nên một vòng lặp cộng tác giữa người và máy.

Đây chính là chìa khóa để giải quyết bài toán thiếu hụt dữ liệu, đồng thời mở ra khả năng cá nhân hóa chẩn đoán trong y khoa, giúp AI trở nên gần gũi và hiệu quả hơn trong môi trường lâm sàng thực tế, giúp các mô hình có thể thích nghi nhanh với bệnh lý mới thông qua mô tả thay vì phải huấn luyện lại từ đầu.



Giới thiệu: Phát biểu bài toán

Phân đoạn ảnh là quá trình nhóm các pixel thuộc cùng một đối tượng ngữ nghĩa và tách biệt khỏi các nhóm đối tượng khác. Có thể hiểu, phân đoạn ảnh là tìm cách làm giảm một *khoảng cách được định nghĩa trước* của các pixel thuộc cùng đối tượng và làm tăng *khoảng cách* với các pixel thuộc đối tượng khác.



Giới thiệu: Phát biểu bài toán

Với các mô hình phân đoạn kết hợp câu nhắc văn bản (text prompt), có thể định nghĩa như sau:

Đầu vào:

Một ảnh kích thước $H \times W$ được xem như hàm số $I : \Omega \rightarrow \mathbb{R}^C$

$$\Omega = \{(x, y) | 1 \leq x \leq H, 1 \leq y \leq W\} \quad C = \{1, 3\}$$

Câu nhắc văn bản là một chuỗi các token $T = \{w_1, w_2, \dots, w_L\}$

Đầu ra:

Với một ngưỡng α cho trước, mặt nạ phân đoạn M tập hợp các giá trị 0, 1 tương ứng đại diện cho pixel thuộc hoặc không thuộc đối tượng.

$$M(x, y) = \begin{cases} 1 & \text{nếu } (x, y) \in \text{vùng mục tiêu được chỉ định bởi } T \\ 0 & \text{nếu ngược lại} \end{cases}$$



Giới thiệu: Phát biểu bài toán

Bài toán phân đoạn dựa trên văn bản là tìm kiếm một ánh xạ F sao cho:

$$F : (I, T) \rightarrow M$$

Quy trình thực hiện: Các mô hình phân đoạn dựa trên câu nhắc văn bản là sự kết hợp giữa hai hàm trích xuất đặc trưng (Encoders), một hàm tương tác giữa các phương thức, một hàm tạo mặt nạ phân đoạn (Decoder).



Giới thiệu: Phát biểu bài toán

- 1 Trích xuất đặc trưng thị giác (E_v): Biến đổi ảnh thành một vector đặc trưng trong không gian d chiều.

$$f_v = E_v(I) \in \mathbb{R}^{h \times w \times d}$$

- 2 Trích xuất đặc trưng ngôn ngữ (E_l): Biến đổi văn bản thành một vector đặc trưng trong không gian d' chiều.

$$f_l = E_l(T) \in \mathbb{R}^{L \times d'}$$

- 3 Đưa các đặc trưng về không gian nhúng chung D .

- Ảnh: $z_v = f_v \cdot W_v + b_v$ $W_v \in \mathbb{R}^{d \times D}$ $z_v \in \mathbb{R}^{(h \times w) \times D}$
- Văn bản: $z_l = f_l \cdot W_l + b_l$ $W_l \in \mathbb{R}^{d' \times D}$ $z_l \in \mathbb{R}^{L \times D}$




- 4 Tương tác và giải mã mặt nạ (ϕ, P) : Các đặc trưng hình ảnh và văn bản tương tác với nhau để làm giàu thông tin hình ảnh. Sau khi có đặc trưng hợp nhất, hàm cho ra mặt nạ phân đoạn.

$$f_u = \phi(z_v, z_l) \quad f_u \in \mathbb{R}^{(h \times w) \times D}$$

$$M = \begin{cases} 1 & \text{nếu } P(f_u) > \alpha \\ 0 & \text{nếu ngược lại} \end{cases}$$





Hình 1: Pipeline hoạt động của mô hình

1 Giới thiệu

- Bối cảnh
- Động lực nghiên cứu
 - Ý nghĩa khoa học
 - Ý nghĩa thực tiễn
- Phát biểu bài toán

2 Phương pháp

- Dữ liệu
- Kiến trúc mô hình
- Hàm mất mát
- Cơ chế sinh nhãn giả

3 Cài đặt và thử nghiệm

4 Kết luận và hướng phát triển

- Kết luận
- Hướng phát triển



Phương pháp: Dữ liệu

- 1 QaTa-COV19-v2: bao gồm 9258 ảnh X-ray ngực được ghi chú thủ công thương tổn do COVID-19 lần đầu tiên. Nhóm nghiên cứu đã mở rộng ghi chú với sự hỗ trợ của các chuyên gia. Ghi chú tập trung vào cả hai phổi có nhiễm bệnh, số vùng thương tổn, vị trí tương đối của vùng nhiễm bệnh. Ví dụ: "Bilateral pulmonary infection, two infected areas, upper left lung and upper right lung"(tạm dịch: "Cả hai phổi bị nhiễm bệnh, hai vùng bị nhiễm, phía trên phổi trái và phía trên phổi phải").
- 2 MosMesData+¹: bao gồm 2729 ảnh CT scan về nhiễm trùng phổi. Ghi chú của tập dữ liệu có cấu trúc tương tự QaTa-COV19. Ví dụ: "Unilateral pulmonary infection, two infected areas, middle lower left lung"(tạm dịch: "Một bên phổi bị nhiễm bệnh, hai vùng bị nhiễm, ở giữa phía dưới phổi trái").
- 3 ESO-CT: bao gồm 286 ảnh X-ray được ghi chú độc lập bởi hai chuyên gia.

¹<http://medicalsegmentation.com/covid19>




Cụ thể, số lượng mẫu được chia trong từng tập như sau:


- 1 QaTa-COV19-v2: Train (5716), Val (1429), Test (2113).
- 2 MosMedData+: Train (2183), Val (273), Test (273).
- 3 ESO-CT: Train (182), Val (46), Test (58).



Phương pháp: Dữ liệu




QaTa-COV19-v2 (224 x 224)




MosMedData+ (512 x 512)



Phương pháp: Kiến trúc mô hình



Phương pháp: Kiến trúc mô hình



Phương pháp: Kiến trúc mô hình

- 1 Nhánh CNN U-shape
- 2 Nhánh ViT U-shape




Phương pháp: Kiến trúc mô hình: CNN

Nhánh CNN nhận đầu vào là một ảnh và đầu ra là bản đồ xác suất.

$$D_i = \text{DownCNN}_i = \text{CTBN} \\ = \text{ReLU}(\text{BatchNorm}_i(\text{Conv}_i(\cdot)))$$


$$Y_{\text{DownCNN},i+1} = \text{MaxPool}(D_i(Y_{\text{DownCNN},i}))$$

$$Y_{\text{DownCNN},0} = I$$



Phương pháp: Kiến trúc mô hình: ViT

Nhánh ViT nhận đầu vào là đặc trưng ảnh của khối DownCNN đầu tiên cùng với đặc trưng văn bản từ lớp BERT-Embed của BERT 12 768 12.



$$ViT(x) = ViT_2(ViT_1(x))$$

$$x' = ViT_1(x) = MHSA(LN(x)) + x$$

$$Y = ViT_2(x') = MLP(LN(x')) + x'$$


$$x_{img,i} = PatchEmbedding(Y_{DownCNN,i})$$

$$Y_{DownViT,1} = ViT(x_{img,1} + CTBN(x_{text}))$$

$$Y_{DownViT,i+1} = ViT(Y_{DownViT,i} + x_{img,i+1})$$




Phương pháp: Kiến trúc mô hình: ViT



Phương pháp: Kiến trúc mô hình: PLAM

PLAM



Phương pháp: Kiến trúc mô hình: PLAM

Mô-đun PLAM được thiết kế để bảo toàn đặc trưng cục bộ và tăng cường ngữ nghĩa trong đặc trưng văn bản.

Transformer thường có xu hướng thiên về việc học các đặc trưng toàn cục (global features) và bỏ qua chi tiết cục bộ. PLAM được thiết kế để bù đắp cho sự thiếu hụt này của cơ chế self-attention, giúp bảo tồn tối đa các đặc trưng cục bộ.

Phép cộng giúp hợp nhất các đặc trưng trên các kênh có ngữ nghĩa tương tự nhau nhằm tiết kiệm tính toán, trong khi phép nối giúp tích hợp thông tin trực quan và bảo tồn các đặc trưng gốc của từng phần. Sau khi nối, mô-đun sử dụng cấu trúc MLP để căn chỉnh kích thước, đồng thời hòa trộn thêm các đặc trưng ngữ nghĩa từ văn bản vào hình ảnh.



Phương pháp: Hàm mất mát

Trong mô hình LViT, hàm mất mát (loss function) được thiết kế khác nhau tùy thuộc vào việc dữ liệu đang được huấn luyện là dữ liệu có nhãn (học giám sát) hay dữ liệu không có nhãn (học bán giám sát):

- Đối với dữ liệu có nhãn (Supervised): Mô hình sử dụng trung bình cộng của hai hàm mất mát cơ bản là Dice loss (L_{Dice}) và Cross-Entropy (L_{CE}).

$$L_{Sup} = \frac{1}{2}(L_{Dice} + L_{CE})$$

- Đối với dữ liệu không có nhãn (Unsupervised): Mô hình sử dụng hàm mất mát tương tự như trên nhưng cộng thêm một thành phần hàm mất mát đặc biệt có tên là Language Vision Loss.

$$L_{Sup} = \frac{1}{2}(L_{Dice} + L_{CE}) + \alpha L_{LV}$$



Phương pháp: Hàm mất mát: LV Loss

$$L_{LV} = 1 - \text{ImgSim}$$

$$\text{ImgSim} = \frac{x_{\text{img},p} \cdot x_{\text{img},c}}{\|x_{\text{img},p}\| \|x_{\text{img},c}\|}$$

$$\text{TextSim} = \frac{x_{\text{text},p} \cdot x_{\text{text},c}}{\|x_{\text{text},p}\| \|x_{\text{text},c}\|}$$

- 1 Tìm độ tương đồng văn bản (TextSim): Mô hình tính toán độ tương đồng cosine giữa vector đặc trưng văn bản tương ứng với nhãn giả ($x_{\text{text},p}$) và vector đặc trưng văn bản của nhãn đối chiếu ($x_{\text{text},c}$). Từ kết quả này, mô hình sẽ chọn ra văn bản đối chiếu có độ tương đồng cao nhất để lấy mask phân vùng tương ứng của nó.
- 2 Tìm độ tương đồng hình ảnh (ImgSim): Mô hình tính toán độ tương đồng cosine giữa vector đặc trưng của nhãn giả hình ảnh do mô hình dự đoán ra ($x_{\text{img},p}$) và vector đặc trưng của nhãn đối chiếu ($x_{\text{img},c}$).

Phương pháp: Hàm mất mát: LV Loss

Mục đích: Hàm mất mát LV được thiết kế để sử dụng trực tiếp các thông tin từ văn bản y tế nhằm giám sát quá trình huấn luyện trên các bức ảnh không có nhãn.

Cơ chế hoạt động: Vì các cơ quan trên ảnh y tế thường có vị trí tương đối cố định, mô hình sẽ tính toán độ tương đồng cosine (cosine similarity) giữa vector đặc trưng của văn bản tương ứng với nhãn giả (pseudo label) và vector văn bản của các nhãn đối chiếu (contrastive label).

Mục tiêu là giám sát vị trí phân đoạn, đảm bảo mask tạo ra phải nằm đúng vị trí cơ quan giải phẫu mà văn bản đang mô tả, tránh việc dự đoán sai lệch hoàn toàn. Đối với dữ liệu không nhãn, $\alpha = 0.1$. Đối với dữ liệu đã có nhãn chuẩn (ground truth), hàm LV loss không mang lại lợi ích đáng kể nên hệ số α được đặt bằng 0.



Phương pháp: Cơ chế sinh nhãn giả

Giả định:

Trong những vòng huấn luyện gần nhất (khoảng n thể hệ), các trọng số của mô hình thực chất chỉ đang dao động (dither) xung quanh một điểm tối ưu thực sự. Kéo theo đó, mask dự đoán cho ảnh A ở vòng 10, vòng 11, vòng 12... cũng đang dao động qua lại quanh ranh giới phân vùng chuẩn xác của vùng bệnh lý. Nếu chỉ lấy dự đoán của vòng hiện tại, mask có thể bị lệch hoặc nhiễu. Nhưng khi "đúc kết" (lấy trung bình cộng có trọng số) kết quả dự đoán của tất cả các vòng trước đó trên chính bức ảnh A, các sai số dao động sẽ tự triệt tiêu lẫn nhau, tạo ra một mask nhãn giả (pseudo label) mượt mà, ổn định và có độ tin cậy cao hơn rất nhiều để dẫn dắt mô hình học tập.



Phương pháp: Cơ chế sinh nhãn giả

Đối với dữ liệu không có nhãn:

- 1 Mô hình dự đoán mask cho mẫu.
- 2 Nhãn giả được cập nhật ra bằng cách tổng hợp nhãn từ các thế hệ trước trên ảnh hiện tại bằng cơ chế Trung bình động hàm mũ (EMA).

$$P_t = \beta P_{t-1} + (1 - \beta)P_t$$

Mục tiêu là mask tạo ra phải tương đồng với mask của các thế hệ trước, giúp mô hình không xảy ra trường hợp dự đoán mask quá khác biệt, mô hình dần học được chi tiết phân đoạn.



Mục lục

1 Giới thiệu

- Bối cảnh
- Động lực nghiên cứu
 - Ý nghĩa khoa học
 - Ý nghĩa thực tiễn
- Phát biểu bài toán

2 Phương pháp

- Dữ liệu
- Kiến trúc mô hình
- Hàm mất mát
- Cơ chế sinh nhãn giả

3 Cài đặt và thử nghiệm

4 Kết luận và hướng phát triển

- Kết luận
- Hướng phát triển



Cài đặt và thử nghiệm



Mục lục

- 1 Giới thiệu
 - Bối cảnh
 - Động lực nghiên cứu
 - Ý nghĩa khoa học
 - Ý nghĩa thực tiễn
 - Phát biểu bài toán
- 2 Phương pháp
 - Dữ liệu
 - Kiến trúc mô hình
 - Hàm mất mát
 - Cơ chế sinh nhãn giả
- 3 Cài đặt và thử nghiệm
- 4 Kết luận và hướng phát triển
 - Kết luận
 - Hướng phát triển



Kết luận và hướng phát triển: Kết luận





Zihan Li and others. *LViT: Language meets Vision Transformer in Medical Image Segmentation.* en. [arXiv:2206.14718](https://arxiv.org/abs/2206.14718) [cs]. **june 2023.**
DOI: [10.48550/arXiv.2206.14718](https://doi.org/10.48550/arXiv.2206.14718). URL:
<http://arxiv.org/abs/2206.14718> (**urlseen** 23/03/2026).

