PHÂN ĐOẠN ẢNH VỚI DỮ LIỆU NHÃN HẠN CHẾ + TEXT PROMPT

Đồ án môn học: Ứng dụng Xử lý ảnh và video

Chung Tín Đạt MSSV: 23122024

Nhóm: CTD
Giảng viên hướng dẫn: PGS. TS. Lý Quốc Ngọc
Khoa Công nghệ Thông tin
Trường Đại học Khoa học Tự nhiên

Ngày 6 tháng 7 năm 2026

Mục lục

1. Giới thiệu
   - Bối cảnh
   - Động lực nghiên cứu
     - Ý nghĩa khoa học
     - Ý nghĩa thực tiễn
   - Phát biểu bài toán
2. Phương pháp
   - Dữ liệu
   - Quy trình xây dựng chú thích văn bản
   - Cấu trúc chú thích
   - Kiến trúc mô hình
   - Hàm mất mát
   - Cơ chế sinh nhãn giả
   - Pipeline huấn luyện và sử dụng
3. Cài đặt và thử nghiệm
   - Môi trường thử nghiệm
   - Cài đặt thực tế
   - Kết quả thử nghiệm

Mục lục

1. Giới thiệu
   - Bối cảnh
   - Động lực nghiên cứu
     - Ý nghĩa khoa học
     - Ý nghĩa thực tiễn
   - Phát biểu bài toán
2. Phương pháp
   - Dữ liệu
   - Quy trình xây dựng chú thích văn bản
   - Cấu trúc chú thích
   - Kiến trúc mô hình
   - Hàm mất mát
   - Cơ chế sinh nhãn giả
   - Pipeline huấn luyện và sử dụng
3. Cài đặt và thử nghiệm
   - Môi trường thử nghiệm
   - Cài đặt thực tế
   - Kết quả thử nghiệm

Giới thiệu: Bối cảnh

Trong thập kỷ qua, các mạng học sâu (CNN, Vision Transformer) chủ yếu hoạt động dựa trên *Closed-vocabulary*. Các mô hình này bị giới hạn bởi tập dữ liệu huấn luyện và thiếu khả năng tổng quát hóa khi chuyển sang các miền dữ liệu mới.
Sự xuất hiện của các mô hình nền tảng (Foundation Models) như CLIP và SAM đã thúc đẩy sự chuyển dịch sang *Open-vocabulary Segmentation*. Các mô hình theo kiến trúc này có khả năng phân đoạn các đối tượng chưa từng xuất hiện trong quá trình huấn luyện thông qua các thông tin mô tả bổ sung (prompts).

Giới thiệu: Bối cảnh

Tuy nhiên, trong lĩnh vực y khoa, các mô hình phân đoạn bệnh vẫn bị giới hạn bởi sự thiếu sót về tập dữ liệu được dán nhãn chất lượng cao [1].
Bên cạnh dữ liệu hình ảnh, các mô hình có xu hướng phát triển các cơ chế học dựa trên câu nhắc (*Prompting*) nhằm tận dụng tri thức đa phương thức.
Mô hình tiêu biểu:

- **MedSAM:** Sử dụng *visual prompts* (points/boxes) để hướng dẫn vùng tập trung.
- **LViT:** Tích hợp *text prompts* để nhúng kiến thức bệnh lý vào quá trình phân đoạn, giúp cải thiện hiệu suất trong điều kiện dữ liệu nhãn hạn chế.

Giới thiệu: Bối cảnh

Sự hiệu quả của các kiến trúc kết hợp Prompting bắt nguồn từ khả năng thiết lập một không gian biểu diễn chung giữa thị giác và ngôn ngữ thông qua cơ chế căn chỉnh đa phương thức. Quá trình này tạo ra một bộ lọc ngữ nghĩa mạnh mẽ, giúp mô hình tự động loại bỏ các vùng nhiễu và tập trung tối đa vào các cấu trúc giải phẫu được mô tả cụ thể trong câu lệnh dẫn dắt.

Thay vì chỉ biết đây là "khối u", văn bản cung cấp các đặc điểm hình thái chuyên sâu: *"bờ không đều"*, *"mật độ thấp"*, *"thâm nhiễm xung quanh"*. Ngôn ngữ y khoa giúp mô hình "hiểu"được các ràng buộc sinh học của cơ quan, từ đó đưa ra mặt nạ phân đoạn hợp lý hơn về mặt y khoa.

Giới thiệu: Động lực nghiên cứu: Ý nghĩa khoa học

Sự phát triển của trí tuệ nhân tạo và thị giác máy tính trong nhiều lĩnh vực đã chứng minh vai trò của việc phân đoạn ảnh tự động. Tuy nhiên, các tập dữ liệu để đáp ứng nhu cầu huấn luyện với các nhãn chất lượng cao vẫn chưa được đáp ứng. Việc tạo ra các nhãn chuẩn này không chỉ tiêu tốn chi phí và thời gian mà còn đòi hỏi sự tham gia trực tiếp của các chuyên gia, khiến việc mở rộng mô hình cho các hiện tượng, bệnh lý hiếm hoặc các thiết bị hình ảnh mới trở nên vô cùng khó khăn.

Giới thiệu: Động lực nghiên cứu: Ý nghĩa khoa học

Động lực chính của nghiên cứu này xuất phát từ việc khai thác nguồn tri thức lâm sàng dồi dào tồn tại dưới dạng ngôn ngữ tự nhiên. Chỉ sử dụng thông tin hình ảnh để mô hình xử lý là không phù hợp trong thực tế các lĩnh vực.
Đặc biệt trong y khoa, mỗi hình ảnh chụp chiếu luôn đi kèm với các báo cáo bệnh lý chi tiết, chứa đựng những mô tả tinh vi về đặc điểm hình thái và vị trí tổn thương mà nhãn pixel đơn thuần không thể truyền tải hết.
Việc phát triển các kiến trúc hướng văn bản không chỉ đơn thuần là một cải tiến về mặt kỹ thuật, mà là một nỗ lực nhằm "dạy"cho máy tính cách hiểu kiến thức chuyên ngành thông qua lăng kính tri thức của chuyên gia.

Giới thiệu: Động lực nghiên cứu: Ý nghĩa thực tiễn

Nghiên cứu này còn được thúc đẩy bởi nhu cầu về một hệ thống AI có tính tương tác và linh hoạt. Thay vì một mô hình "hộp đen"chỉ đưa ra kết quả cố định, sự hỗ trợ của text prompt cho phép chuyên gia trực tiếp điều chỉnh và tinh chỉnh vùng phân đoạn thông qua các câu lệnh mô tả, tạo nên một vòng lặp cộng tác giữa người và máy.
Đây chính là chìa khóa để giải quyết bài toán thiếu hụt dữ liệu, đồng thời mở ra khả năng cá nhân hóa chẩn đoán trong y khoa, giúp AI trở nên gần gũi và hiệu quả hơn trong môi trường lâm sàng thực tế, giúp các mô hình có thể thích nghi nhanh với bệnh lý mới thông qua mô tả thay vì phải huấn luyện lại từ đầu.

Giới thiệu: Phát biểu bài toán

Phân đoạn ảnh là quá trình nhóm các pixel thuộc cùng một đối tượng ngữ nghĩa và tách biệt khỏi các nhóm đối tượng khác. Có thể hiểu, phân đoạn ảnh là tìm cách làm giảm một *khoảng cách được định nghĩa trước* của các pixel thuộc cùng đối tượng và làm tăng *khoảng cách* với các pixel thuộc đối tượng khác.

Giới thiệu: Phát biểu bài toán

Với các mô hình phân đoạn kết hợp câu nhắc văn bản (text prompt), có thể định nghĩa như sau:

Đầu vào:

Một ảnh kích thước $H \times W$ được xem như hàm số $I : \Omega \to \mathbb{R}^C$

$$\Omega = \{(x, y) | 1 \leq x \leq H, 1 \leq y \leq W\} \quad C = \{1, 3\}$$

Câu nhắc văn bản là một chuỗi các token $T = \{w_1, w_2, \cdots, w_L\}$

Đầu ra:
Đầu ra trung gian của mô hình là bản đồ xác suất **P** có cùng kích thước với ảnh đầu vào. Tại mỗi vị trí pixel, giá trị xác suất thể hiện mức độ tin cậy của mô hình rằng pixel đó thuộc về vùng mục tiêu được mô tả bởi câu nhắc văn bản.
Với một ngưỡng α cho trước, mặt nạ phân đoạn **M** tập hợp các giá trị 0, 1 tương ứng đại diện cho pixel thuộc hoặc không thuộc đối tượng.

$$M(x,y) = \begin{cases} 1 & \text{nếu } (x,y) \in \text{vùng mục tiêu được chỉ định bởi } T \\ 0 & \text{nếu ngược lại} \end{cases}$$

Giới thiệu: Phát biểu bài toán

Bài toán phân đoạn dựa trên văn bản là tìm kiếm một ánh xạ F sao cho:

$$F : (I, T) \rightarrow M$$

Quy trình thực hiện: Các mô hình phân đoạn dựa trên câu nhắc văn bản là sự kết hợp giữa hai hàm trích xuất đặc trưng (Encoders), một hàm tương tác giữa các phương thức, một hàm tạo mặt nạ phân đoạn (Decoder).

Giới thiệu: Phát biểu bài toán

1. Trích xuất đặc trưng thị giác (E_v): Biến đổi ảnh thành một vector đặc trưng trong không gian d chiều.

$$f_v = E_v(I) \in \mathbb{R}^{h \times w \times d}$$

2. Trích xuất đặc trưng ngôn ngữ (E_l): Biến đổi văn bản thành một vector đặc trưng trong không gian d' chiều.

$$f_l = E_l(T) \in \mathbb{R}^{L \times d'}$$

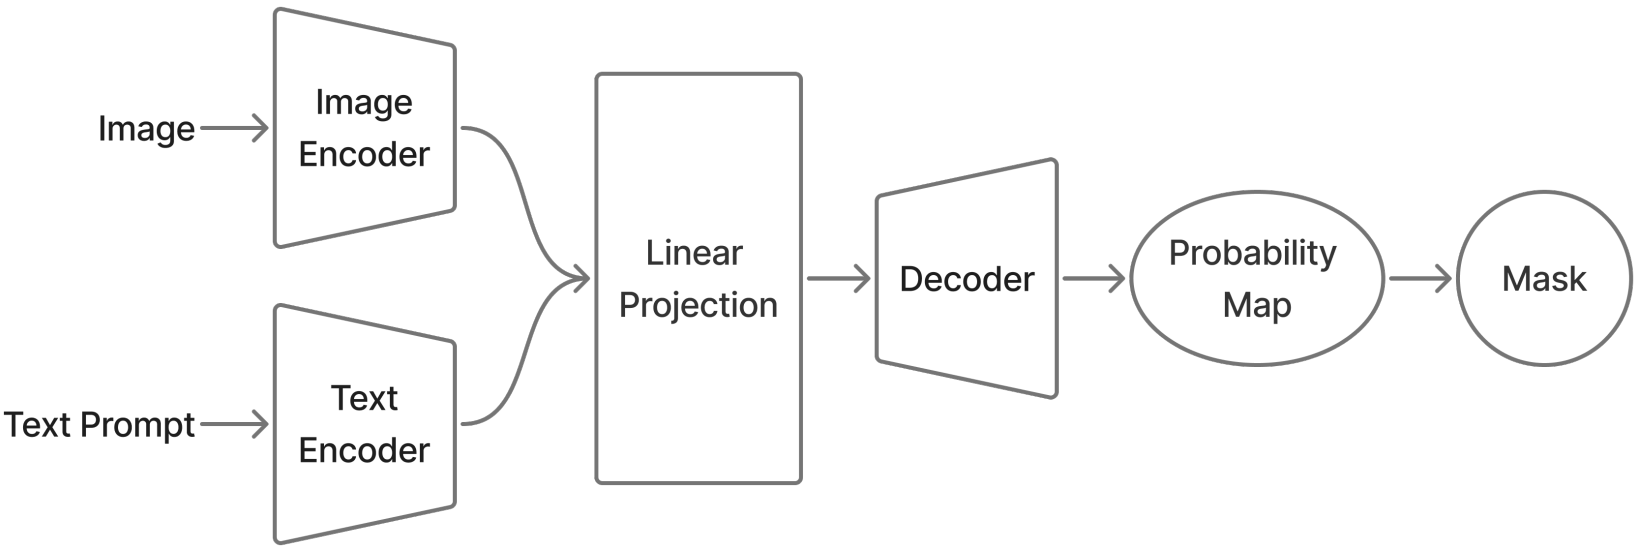
3. Đưa các đặc trưng về không gian nhúng chung D.
   - Ảnh: $z_v = f_v \cdot \boldsymbol{W_v} + b_v \quad \boldsymbol{W_v} \in \mathbb{R}^{d \times D} \quad z_v \in \mathbb{R}^{(h \times w) \times D}$
   - Văn bản: $z_l = f_l \cdot \boldsymbol{W_l} + b_l \quad \boldsymbol{W_l} \in \mathbb{R}^{d' \times D} \quad z_l \in \mathbb{R}^{L \times D}$

4. Tương tác và giải mã mặt nạ (ϕ, P): Các đặc trưng hình ảnh và văn bản tương tác với nhau để làm giàu thông tin hình ảnh. Sau khi có đặc trưng hợp nhất, hàm cho ra mặt nạ phân đoạn.

$$f_u = \phi(z_v, z_l) \quad f_u \in \mathbb{R}^{(h \times w) \times D}$$

$$M = \begin{cases} 1 & \text{nếu } P(f_u) > \alpha \\ 0 & \text{nếu ngược lại} \end{cases}$$

Giới thiệu



Hình 1: Pipeline hoạt động của mô hình

Mục lục

1. Giới thiệu
   - Bối cảnh
   - Động lực nghiên cứu
     - Ý nghĩa khoa học
     - Ý nghĩa thực tiễn
   - Phát biểu bài toán
2. Phương pháp
   - Dữ liệu
   - Quy trình xây dựng chú thích văn bản
   - Cấu trúc chú thích
   - Kiến trúc mô hình
   - Hàm mất mát
   - Cơ chế sinh nhãn giả
   - Pipeline huấn luyện và sử dụng
3. Cài đặt và thử nghiệm
   - Môi trường thử nghiệm
   - Cài đặt thực tế
   - Kết quả thử nghiệm

Phương pháp: Dữ liệu

1. QaTa-COV19-v2: bao gồm 9258 ảnh X-ray ngực được ghi chú thủ công thương tổn do COVID-19 lần đầu tiên. Nhóm nghiên cứu đã mở rộng ghi chú với sự hỗ trợ của các chuyên gia. Ghi chú tập trung vào cả hai phổi có nhiễm bệnh, số vùng thương tổn, vị trí tương đối của vùng nhiễm bệnh. Ví dụ: "Bilateral pulmonary infection, two infected areas, upper left lung and upper right lung"(tạm dịch: "Cả hai phổi bị nhiễm bệnh, hai vùng bị nhiễm, phía trên phổi trái và phía trên phổi phải").
2. MosMesData+: bao gồm 2729 ảnh CT scan về nhiễm trùng phổi. Ghi chú của tập dữ liệu có cấu trúc tương tự QaTa-COV19. Ví dụ: "Unilateral pulmonary infection, two infected areas, middle lower left lung"(tạm dịch: "Một bên phổi bị nhiễm bệnh, hai vùng bị nhiễm, ở giữa phía dưới phổi trái").
3. ESO-CT: bao gồm 286 ảnh X-ray được ghi chú độc lập bởi hai chuyên gia.

Phương pháp: Dữ liệu

Cụ thể, số lượng mẫu được chia trong từng tập như sau:

	QaTa-COV19-v2	**MosMedData+**	**ESO-CT**
Tập huấn luyện	5716	2183	182
Tập kiểm định	1429	273	273
Tập kiểm thử	2113	273	58
Tổng cộng	9528	2729	286

Bảng 1: Phân phối dữ liệu trong các tập dữ liệu

Phương pháp: Dữ liệu



QaTa-COV19-v2 (224 x 224)



MosMedData+ (512 x 512)

Phương pháp: Quy trình xây dựng chú thích văn bản

Phần ghi chú thông tin bệnh của các bộ dữ liệu không có sẵn ngay từ đầu, mà được nhóm nghiên cứu tạo ra và mở rộng với sự hỗ trợ trực tiếp của hai chuyên gia từ Khoa Xạ trị Ung thư [1].

Các bác sĩ X-quang tiến hành chú thích độc lập trên cùng một ảnh. Sau đó, kết quả được nhóm nghiên cứu đối chiếu để đảm bảo tính nhất quán, họ cũng kiểm tra chéo các đoạn văn bản này với mặt nạ phân đoạn gốc của ảnh nhằm bảo đảm rằng thông tin vị trí trong văn bản không sai lệch quá lớn so với vùng tổn thương thực tế.

[1] Trung tâm Y tế Tây Nam trường Đại học Texas

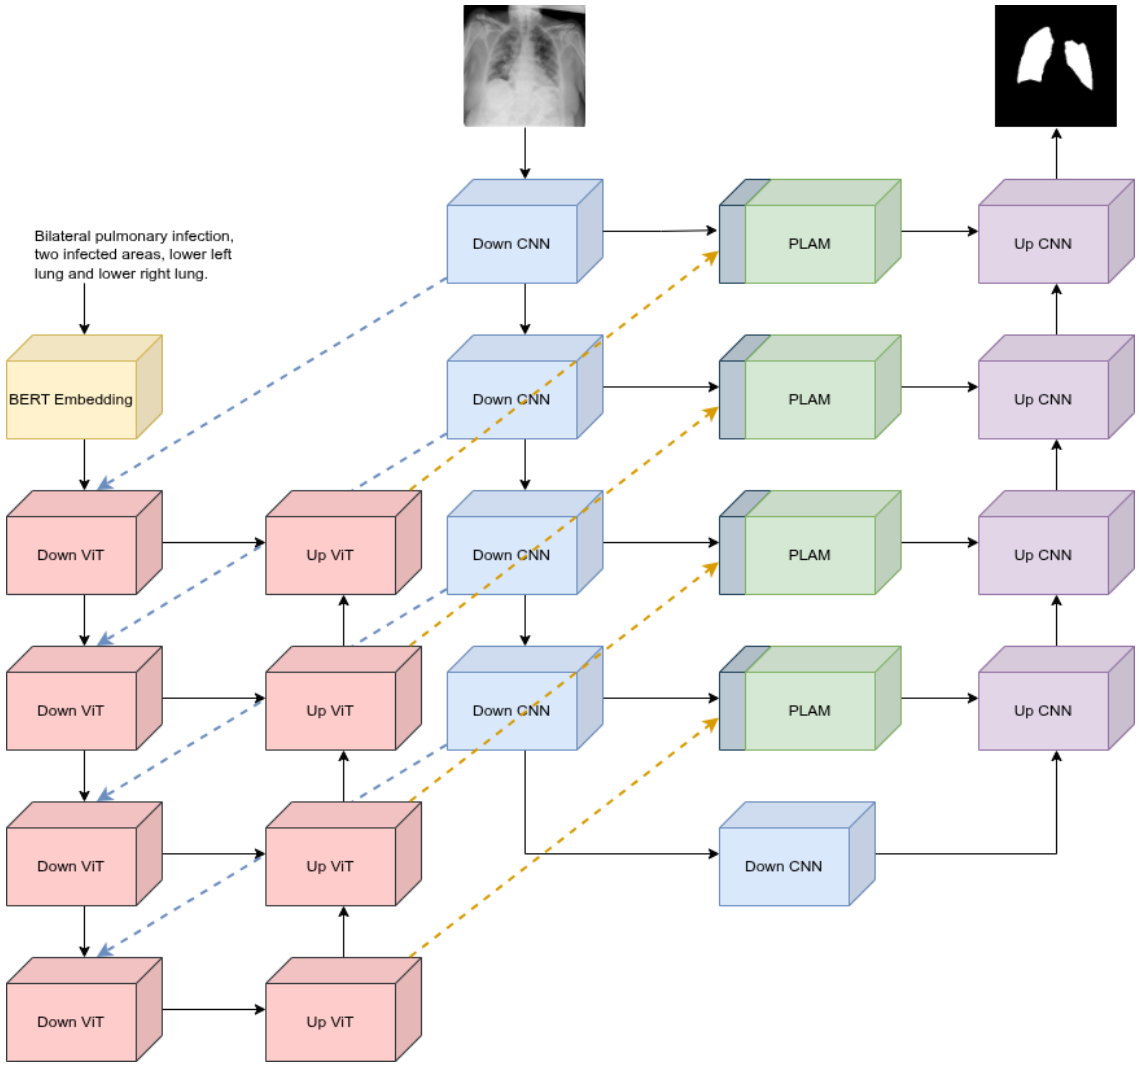
Phương pháp: Cấu trúc chú thích

- **QaTa-COV19-v2 và MosMedData+:** Văn bản chú thích được cấu trúc hóa thống nhất, tập trung vào ba thuộc tính chính: phạm vi nhiễm bệnh, số lượng vùng tổn thương và vị trí ước chừng của vùng nhiễm.
- **ESO-CT:** Tập dữ liệu ung thư thực quản bao gồm các thông tin lâm sàng được bác sĩ X-quang chú thích thủ công. Để tạo văn bản mô tả, bác sĩ chia thực quản thành bốn phần từ trên xuống dưới, gồm cổ, ngực trên, ngực giữa và ngực dưới; sau đó ghi chú vị trí ước chừng của khối u dựa trên các phần này. Đoạn văn bản mô tả vị trí thô được sử dụng trực tiếp làm đầu vào cho mô hình.

Phương pháp: Cấu trúc chú thích

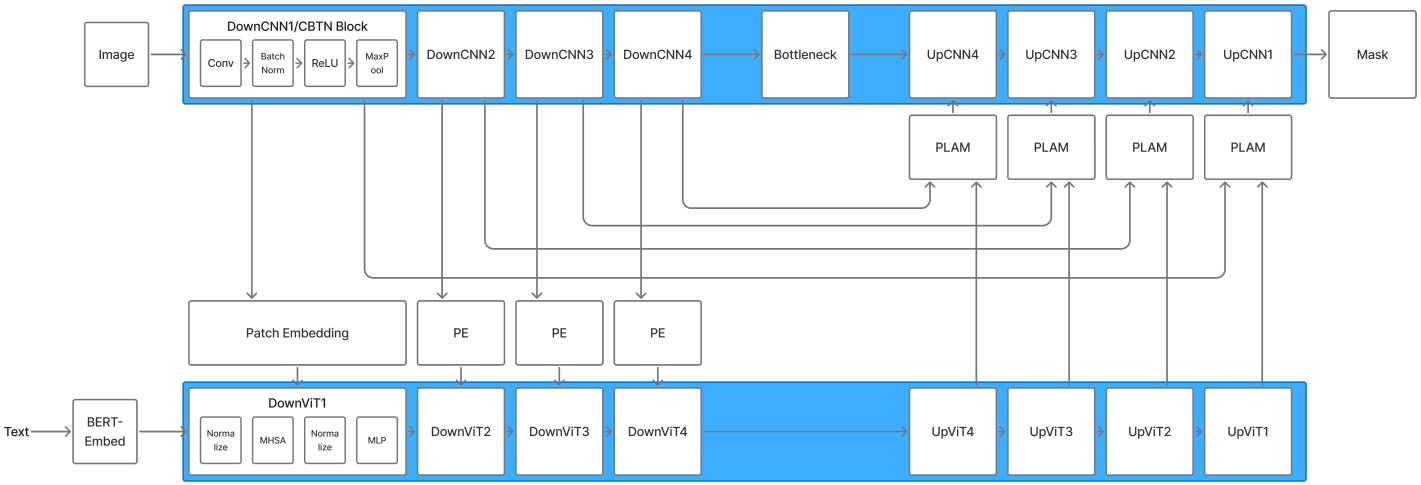
Tập ESO-CT được đề cập trong phần phương pháp; tuy nhiên, tại thời điểm thực hiện báo cáo này, bộ dữ liệu này chưa được công bố công khai nên không thể truy cập để tiến hành thử nghiệm.

Phương pháp: Kiến trúc mô hình



Hình 2: Kiến trúc LViT.

Phương pháp: Kiến trúc mô hình



Hình 3: Làm phẳng quá trình xử lý đặc trưng.

Phương pháp: Kiến trúc mô hình

1. Nhánh CNN U-shape
2. Nhánh ViT U-shape

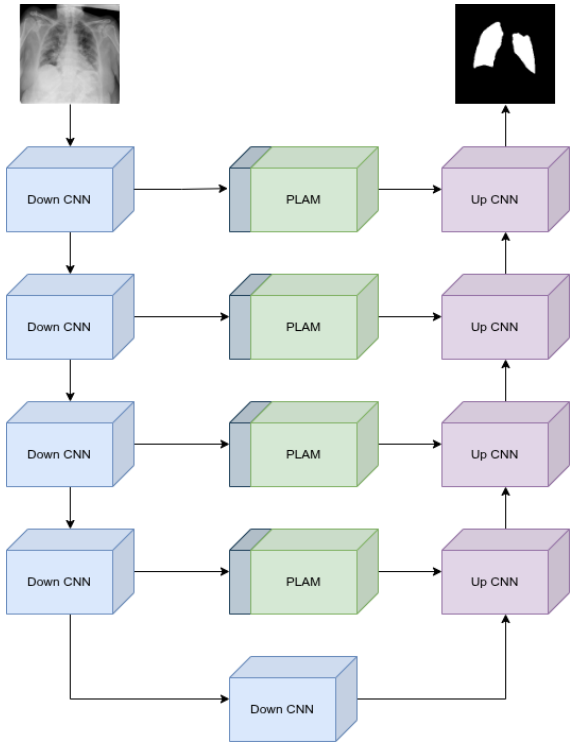
Phương pháp: Kiến trúc mô hình: CNN

Nhánh CNN nhận đầu vào là một ảnh và đầu ra là bản đồ xác suất.

$$D_i = DownCNN_i = CTBN$$
$$= ReLU(BatchNorm_i(Conv_i(\cdot)))$$

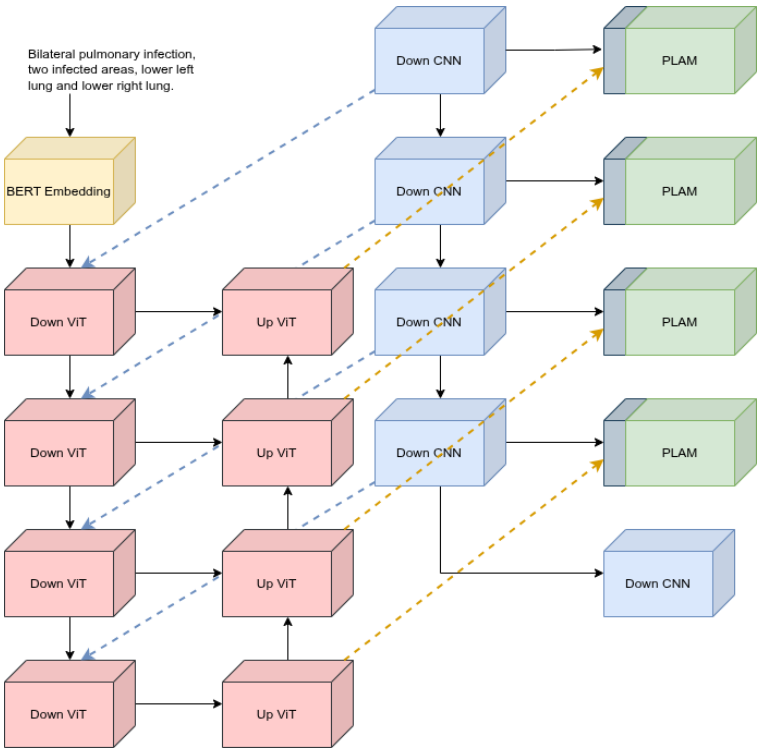
$$Y_{DownCNN,i+1} = MaxPool(D_i(Y_{DownCNN,i}))$$

$$Y_{DownCNN,0} = I$$



Phương pháp: Kiến trúc mô hình: ViT

Nhánh ViT nhận đầu vào là đặc trưng ảnh của khối DownCNN đầu tiên cùng với đặc trưng văn bản từ lớp BERT-Embed của BERT_12_768_12.



$$ViT(x) = ViT_2(ViT_1(x))$$

$$x' = ViT_1(x) = MHSA(LN(x)) + x$$

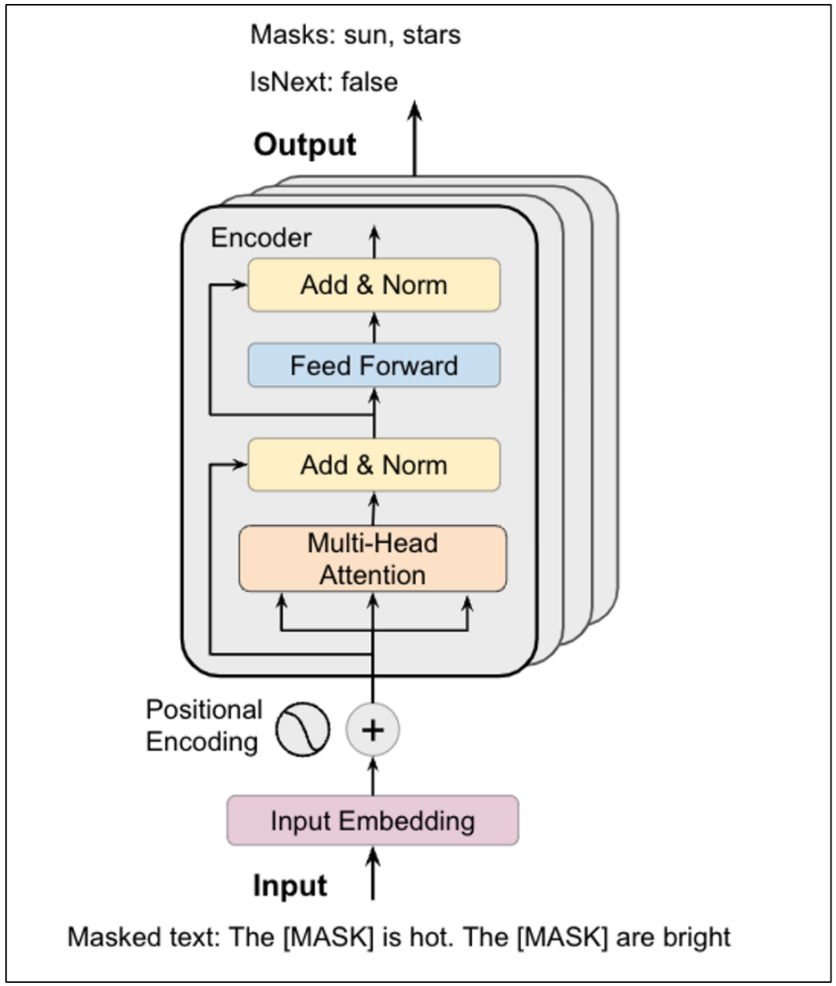
$$Y = ViT_2(x') = MLP(LN(x')) + x'$$

$$x_{img,i} = PatchEmbedding(Y_{DownCNN,i})$$

$$Y_{DownViT,1} = ViT(x_{img,1} + CTBN(x_{text}))$$

$$Y_{DownViT,i+1} = ViT(Y_{DownViT,i} + x_{img,i+1})$$

Phương pháp: Kiến trúc mô hình: BERT



Hình 4: Bộ mã hoá văn bản dựa trên BERT.

Phương pháp: Kiến trúc mô hình: BERT

Trong LViT, các câu mô tả y khoa thường có cấu trúc tương đối cố định và ngắn gọn, ví dụ bao gồm phạm vi nhiễm bệnh, số vùng tổn thương và vị trí tương đối. Do đó, mô hình không nhất thiết phải sử dụng toàn bộ các tầng Transformer của BERT để suy luận ngữ cảnh phức tạp như trong các bài toán xử lý ngôn ngữ tự nhiên tổng quát. Thay vào đó, việc sử dụng lớp Embedding của BERT đã đủ để cung cấp biểu diễn ban đầu cho các token văn bản, đồng thời giúp giảm số lượng tham số, tiết kiệm chi phí tính toán và hạn chế nguy cơ quá khớp khi dữ liệu y khoa có quy mô không quá lớn.

Phương pháp: Kiến trúc mô hình: PatchEmbedding

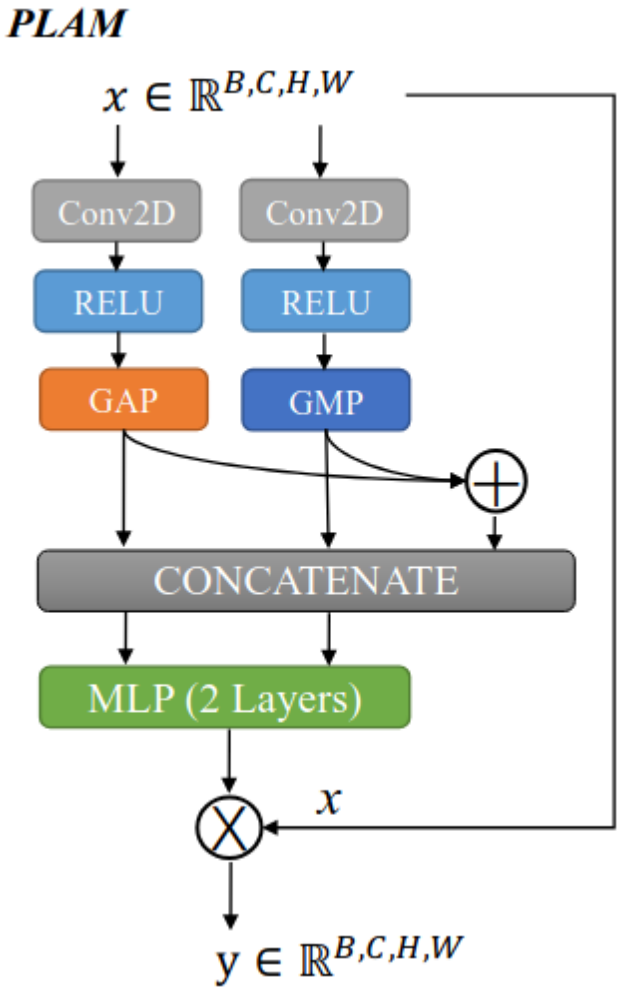
Để kết hợp đặc trưng thị giác từ ảnh với đặc trưng văn bản trong nhánh Transformer, bản đồ đặc trưng hình ảnh cần được chuyển đổi từ dạng không gian hai chiều sang dạng chuỗi visual token. Ở nhánh CNN, đặc trưng ảnh thường được biểu diễn dưới dạng tensor. Trong khi đó, Transformer chỉ tiếp nhận đầu vào dưới dạng một chuỗi các vector đặc trưng. Vì vậy, mô-đun Patch Embedding đóng vai trò trung gian, giúp chuyển đặc trưng ảnh sang định dạng token phù hợp với cơ chế attention.

Sau bước Patch Embedding, chuỗi visual token được đưa vào các khối attention của nhánh ViT để học quan hệ toàn cục giữa các vùng ảnh. Đồng thời, vì đặc trưng văn bản cũng được biểu diễn dưới dạng các vector token, mô hình có thể đưa thông tin thị giác và ngôn ngữ về cùng một không gian biểu diễn.

Phương pháp: Kiến trúc mô hình: Reconstruct

Sau khi các khối ViT học được quan hệ ngữ nghĩa giữa đặc trưng hình ảnh và đặc trưng văn bản, dữ liệu cần được chuyển trở lại dạng bản đồ đặc trưng để có thể kết hợp với nhánh CNN. Lý do là nhánh ViT biểu diễn dữ liệu dưới dạng chuỗi token, trong đó mỗi token đại diện cho một patch hoặc một vùng đặc trưng của ảnh. Ngược lại, nhánh CNN xử lý dữ liệu dưới dạng tensor không gian hai chiều, gồm số kênh, chiều cao và chiều rộng. Vì vậy, trước khi thực hiện cộng phần dư hoặc nối đặc trưng với nhánh CNN, chuỗi token từ ViT phải được tái cấu trúc thành bản đồ đặc trưng tương thích.

Phương pháp: Kiến trúc mô hình: PLAM



Hình 5: Mô-đun PLAM.

Phương pháp: Kiến trúc mô hình: PLAM

Trong kiến trúc LViT, nhánh Transformer có ưu điểm trong việc học các quan hệ toàn cục giữa các vùng ảnh thông qua cơ chế self-attention. Tuy nhiên, do tập trung vào tương tác toàn cục, Transformer có thể làm suy giảm một số chi tiết cục bộ quan trọng như biên tổn thương, kết cấu nhỏ hoặc sự thay đổi cường độ tại các vùng hẹp. Đây là những thông tin có vai trò quan trọng trong phân đoạn ảnh y khoa, đặc biệt khi vùng bệnh lý có kích thước nhỏ hoặc ranh giới không rõ ràng.

PLAM được đưa vào để bù đắp hạn chế này bằng cách kết hợp thông tin từ nhiều nhánh đặc trưng khác nhau. Global Average Pooling giúp mô hình nắm bắt xu hướng tổng quát của toàn bộ bản đồ đặc trưng, trong khi Global Max Pooling nhấn mạnh các đặc điểm mạnh nhất, thường tương ứng với những vùng có tín hiệu nổi bật hoặc đặc trưng phân biệt cao. Việc sử dụng đồng thời hai phép pooling giúp PLAM thu được cả thông tin ngữ cảnh tổng quát lẫn các dấu hiệu cục bộ quan trọng.

Phương pháp: Hàm mất mát

Trong mô hình LViT, hàm mất mát (loss function) được thiết kế khác nhau tùy thuộc vào việc dữ liệu đang được huấn luyện là dữ liệu có nhãn (học giám sát) hay dữ liệu không có nhãn (học bán giám sát):

- Đối với dữ liệu có nhãn (Supervised): Mô hình sử dụng trung bình cộng của hai hàm mất mát cơ bản là Dice loss (L_{Dice}) và Cross-Entropy (L_{CE}).

$$L_{Sup} = \frac{1}{2}(L_{Dice} + L_{CE})$$

- Đối với dữ liệu không có nhãn (Unsupervised): Mô hình sử dụng hàm mất mát tương tự như trên nhưng cộng thêm một thành phần hàm mất mát đặc biệt có tên là Language Vision Loss.

$$L_{Sup} = \frac{1}{2}(L_{Dice} + L_{CE}) + \alpha L_{LV}$$

Phương pháp: Hàm mất mát: LV Loss

$$TextSim = \frac{x_{text,p} \cdot x_{text,c}}{|x_{text,p}||x_{text,c}|}$$

Tìm độ tương đồng văn bản (TextSim): Với mỗi ảnh không nhãn, đầu vào vẫn đi kèm một đoạn chú thích bệnh mô tả. Sau khi mô hình sinh ra nhãn giả cho ảnh này, đoạn chú thích tương ứng được mã hóa thành vector đặc trưng văn bản $x_{text,p}$. Mô hình so sánh vector này với các vector đặc trưng văn bản của những mẫu có nhãn, ký hiệu là $x_{text,c}$. Mẫu có văn bản đối chiếu gần nhất về mặt ngữ nghĩa được xem là mẫu tham chiếu phù hợp nhất.

Phương pháp: Hàm mất mát: LV Loss

$$ImgSim = \frac{x_{img,p} \cdot x_{img,c}}{|x_{img,p}||x_{img,c}|}$$

$$L_{LV} = 1 - ImgSim$$

Tìm độ tương đồng hình ảnh (ImgSim): Sau khi xác định được nhãn đối chiếu từ bước TextSim, mô hình tiếp tục so sánh đặc trưng hình ảnh của nhãn giả với đặc trưng hình ảnh của nhãn đối chiếu. Cụ thể, vector đặc trưng của vùng dự đoán từ ảnh không nhãn được ký hiệu là $x_{img,p}$, còn vector đặc trưng của vùng đối chiếu từ ảnh có nhãn được ký hiệu là $x_{img,c}$. Độ tương đồng cosine giữa hai vector này cho biết nhãn giả có gần với nhãn đối chiếu hay không trong không gian đặc trưng hình ảnh.

Phương pháp: Hàm mất mát: LV Loss

Mục đích của LV loss là tận dụng trực tiếp thông tin từ văn bản y tế để tạo thêm tín hiệu giám sát cho các ảnh không có nhãn.

Thay vì chỉ tin vào mặt nạ do mô hình tự dự đoán, LV loss sử dụng chú thích văn bản để tìm một mẫu có nhãn mang ý nghĩa gần nhất, rồi dùng mẫu đó như một điểm neo tham chiếu. Vì các cơ quan và tổn thương trên ảnh y tế thường có vị trí giải phẫu tương đối ổn định, sự tương đồng giữa các mô tả văn bản có thể cung cấp gợi ý hữu ích về vị trí phân đoạn.

Nhờ vậy, LV loss giúp hạn chế trường hợp mô hình dự đoán mặt nạ lệch khỏi vùng cơ quan hoặc vùng bệnh lý mà văn bản đang mô tả, đồng thời làm cho nhãn giả nhất quán hơn với tri thức ngữ nghĩa từ chú thích y khoa.

Phương pháp: Cơ chế sinh nhãn giả

Với các ảnh không nhãn, mô hình không có mặt nạ chuẩn để tính trực tiếp các hàm mất mát phân đoạn như Dice loss và Cross-Entropy. Vì vậy, cần có một cơ chế sinh nhãn giả nhằm tạo ra các mặt nạ tạm thời cho dữ liệu không nhãn.

Tuy nhiên, nhãn giả do mô hình tự dự đoán thường không ổn định, đặc biệt ở các giai đoạn đầu của quá trình huấn luyện. Nếu sử dụng trực tiếp dự đoán ở một vòng huấn luyện duy nhất, mặt nạ có thể bị nhiễu, bị lệch khỏi vùng tổn thương hoặc thay đổi mạnh giữa các vòng lặp. Điều này có thể khiến mô hình học theo các nhãn sai và làm giảm chất lượng phân đoạn.

Phương pháp: Cơ chế sinh nhãn giả

Giả định:
Trong n vòng huấn luyện gần nhất, các trọng số của mô hình thực chất chỉ đang dao động xung quanh một điểm tối ưu thực sự. Kéo theo đó, mask dự đoán cho ảnh A ở vòng 10, vòng 11, vòng 12... cũng đang dao động qua lại quanh ranh giới phân vùng chuẩn xác của vùng bệnh lý.

Nếu chỉ lấy dự đoán của vòng hiện tại, mask có thể bị lệch hoặc nhiễu. Nhưng khi "đúc kết"kết quả dự đoán của tất cả các vòng trước đó trên chính bức ảnh A, các sai số dao động sẽ tự triệt tiêu lẫn nhau, tạo ra một mask nhãn giả (pseudo label) mượt mà, ổn định và có độ tin cậy cao hơn rất nhiều để dẫn dắt mô hình học tập.

Phương pháp: Cơ chế sinh nhãn giả

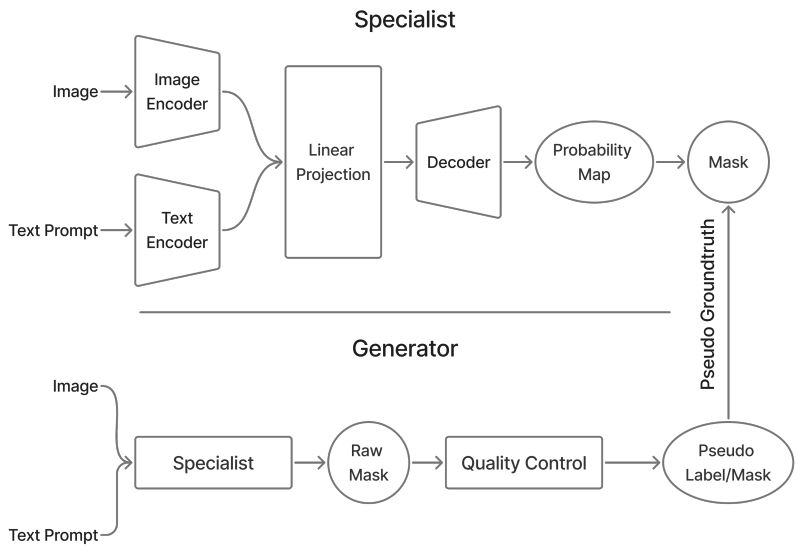
Đối với dữ liệu không có nhãn:

1. **Dự đoán mặt nạ hiện tại:** Ở vòng huấn luyện t, mô hình nhận ảnh không nhãn làm đầu vào và sinh ra bản đồ xác suất hiện tại $P_{current}$.
2. **Kết hợp với nhãn giả trước đó:** Dự đoán hiện tại được kết hợp với nhãn giả đã tích lũy từ vòng trước thông qua cơ chế EMA:

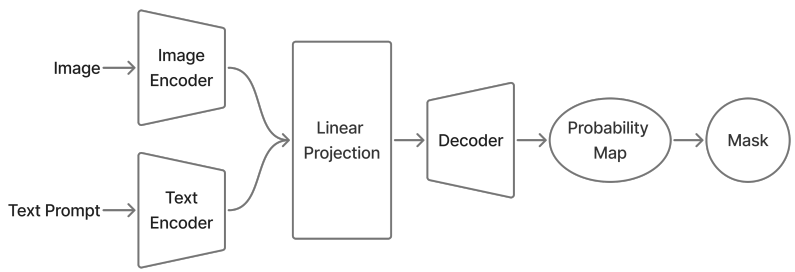
$$P_t = \beta P_{t-1} + (1 - \beta) P_{current}$$

   Trong đó, P_t là nhãn giả được cập nhật tại vòng huấn luyện t, P_{t-1} là nhãn giả ở vòng trước, $P_{current}$ là dự đoán hiện tại của mô hình và β là hệ số làm mượt.
3. **Sử dụng nhãn giả để huấn luyện:** Nhãn giả P_t sau khi cập nhật được dùng như mặt nạ tham chiếu tạm thời để tính các thành phần mất mát phân đoạn cho ảnh không nhãn, chẳng hạn Dice loss và Cross-Entropy. Nhờ đó, dữ liệu không nhãn vẫn có thể đóng góp vào quá trình tối ưu mô hình.

Phương pháp: Pipeline huấn luyện và sử dụng



Hình 6: Pipeline huấn luyện mô hình



Hình 7: Pipeline sử dụng mô hình

Phương pháp: Pipeline huấn luyện và sử dụng

Hình 6 mô tả pipeline huấn luyện mô hình ở chế độ ngoại tuyến. Trong giai đoạn này, hệ thống sử dụng cả dữ liệu có nhãn và dữ liệu không nhãn. Đối với dữ liệu có nhãn, mặt nạ chuẩn được dùng trực tiếp. Đối với dữ liệu không nhãn, mô hình cần thêm cơ chế sinh nhãn giả để tạo ra mặt nạ tạm thời phục vụ quá trình huấn luyện.

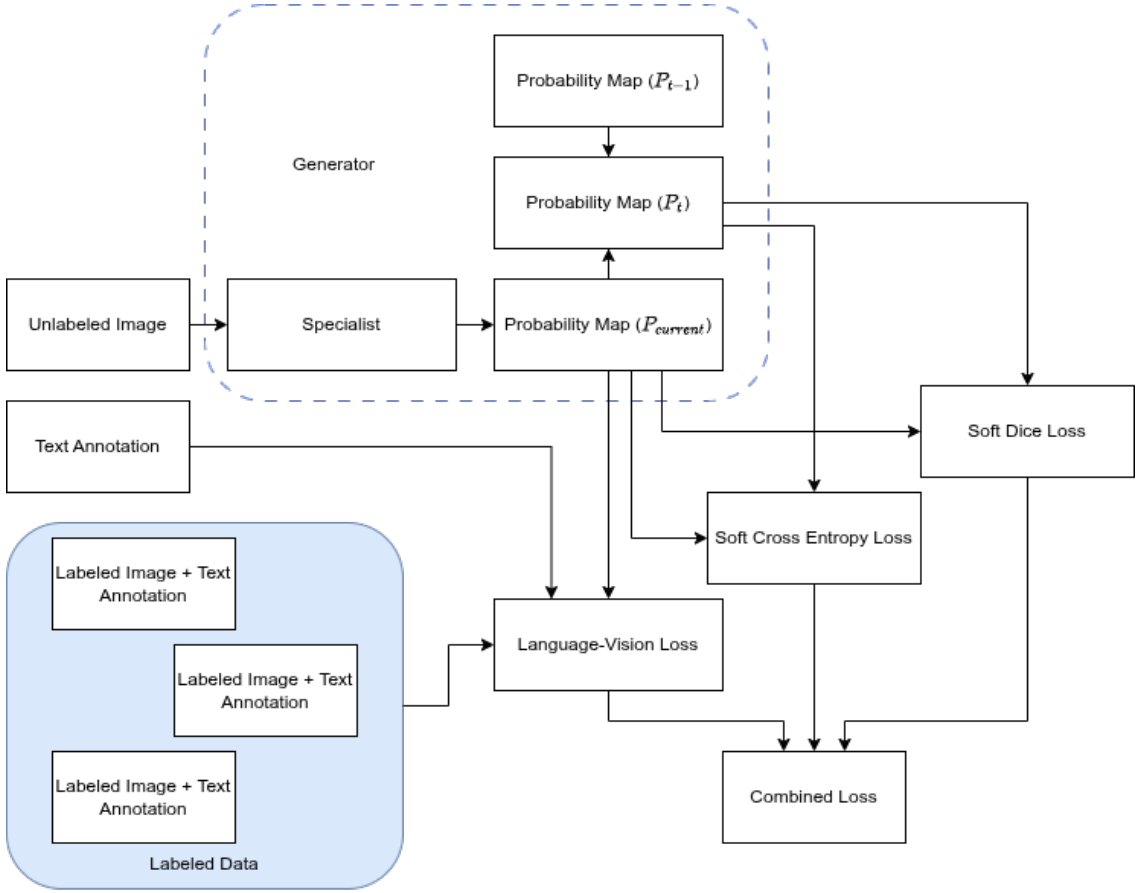
Pipeline này gồm hai thành phần quan trọng: *Specialist* và *Generator*. Specialist chịu trách nhiệm sinh mặt nạ phân đoạn ban đầu dựa trên ảnh đầu vào và câu nhắc văn bản, trong khi Generator tổng hợp và cập nhật các nhãn giả ổn định hơn từ các dự đoán qua nhiều vòng huấn luyện.

Phương pháp: Pipeline huấn luyện và sử dụng

Hình 7 mô tả pipeline sử dụng mô hình trong thực tế sau khi quá trình huấn luyện đã hoàn tất. Ở giai đoạn suy luận, người dùng cung cấp một ảnh y khoa và một câu nhắc văn bản mô tả vùng cần phân đoạn. Hai nguồn đặc trưng này được kết hợp trong mô hình để sinh ra bản đồ xác suất phân đoạn. Sau đó, bản đồ xác suất được xử lý bằng một ngưỡng quyết định để tạo ra mặt nạ nhị phân cuối cùng. Mặt nạ này biểu diễn vùng tổn thương hoặc cơ quan phù hợp với nội dung câu nhắc đầu vào.

Điểm quan trọng của pipeline online là mô hình có tính linh hoạt theo câu nhắc. Cùng một ảnh đầu vào có thể tạo ra các mặt nạ khác nhau nếu người dùng thay đổi mô tả văn bản.

Phương pháp: Pipeline huấn luyện và sử dụng



Hình 8: Pipeline tính toán hàm mất mát và xây dựng nhãn giả chi tiết

Phương pháp: Pipeline huấn luyện và sử dụng

Hình 8 mô tả chi tiết quá trình xây dựng nhãn giả và tính toán hàm mất mát cho ảnh không nhãn. Trước hết, mô hình nhận ảnh không nhãn cùng câu nhắc văn bản tương ứng để sinh ra bản đồ xác suất hiện tại $P_{current}$. Mỗi phần tử trong $P_{current}$ biểu diễn xác suất pixel tương ứng thuộc về vùng cần phân đoạn, thay vì chỉ đưa ra quyết định nhị phân là nền hoặc tổn thương. Do đó, $P_{current}$ không chỉ cho biết vị trí vùng dự đoán mà còn thể hiện mức độ tự tin của mô hình tại từng điểm ảnh.

Điểm quan trọng là các hàm mất mát trong bước này được áp dụng theo hướng *soft*. Điều này có nghĩa là mục tiêu huấn luyện không bắt buộc phải là mặt nạ nhị phân chỉ gồm các giá trị 0 và 1, mà có thể là một bản đồ xác suất với các giá trị thực nằm trong khoảng từ 0 đến 1. Ví dụ, một pixel có giá trị 0.8 trong nhãn giả thể hiện rằng pixel đó có khả năng cao thuộc vùng tổn thương, trong khi giá trị 0.4 thể hiện mức độ không chắc chắn lớn hơn. Cách biểu diễn này giữ lại nhiều thông tin hơn so với việc gán cứng pixel đó thành 0 hoặc 1.

Mục lục

1. Giới thiệu
   - Bối cảnh
   - Động lực nghiên cứu
     - Ý nghĩa khoa học
     - Ý nghĩa thực tiễn
   - Phát biểu bài toán
2. Phương pháp
   - Dữ liệu
   - Quy trình xây dựng chú thích văn bản
   - Cấu trúc chú thích
   - Kiến trúc mô hình
   - Hàm mất mát
   - Cơ chế sinh nhãn giả
   - Pipeline huấn luyện và sử dụng
3. Cài đặt và thử nghiệm
   - Môi trường thử nghiệm
   - Cài đặt thực tế
   - Kết quả thử nghiệm

Cài đặt và thử nghiệm: Môi trường thử nghiệm

Thử nghiệm được thực hiện trên nền tảng Kaggle với cấu hình GPU T4 x2.

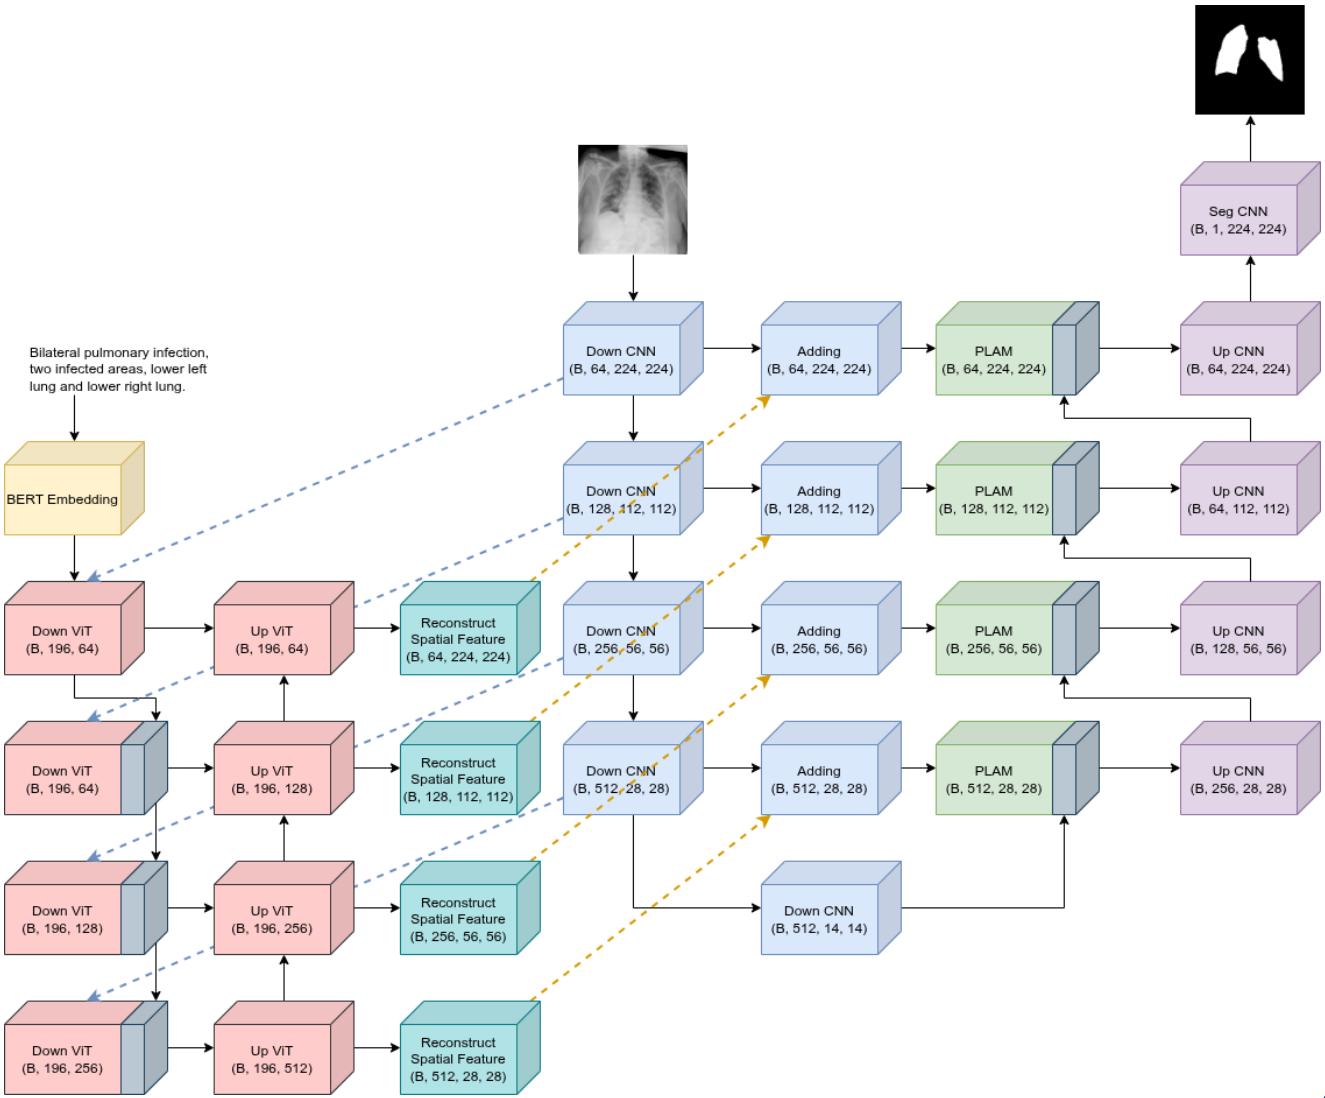
Mô hình được huấn luyện riêng biệt trên hai tập dữ liệu QaTa-COV19-v2 và MosMedData+. Hai tập dữ liệu này đều có mặt nạ phân đoạn và ghi chú y khoa đi kèm, do đó phù hợp với mục tiêu đánh giá mô hình phân đoạn đa phương thức dựa trên cả thông tin ảnh và văn bản.

Trước khi đưa vào mô hình, tất cả ảnh đầu vào được thay đổi kích thước về 224×224. Đây là kích thước đầu vào phổ biến của Vision Transformer, đặc biệt trong các mô hình tiền huấn luyện trên ImageNet.

Cài đặt và thử nghiệm: Môi trường thử nghiệm

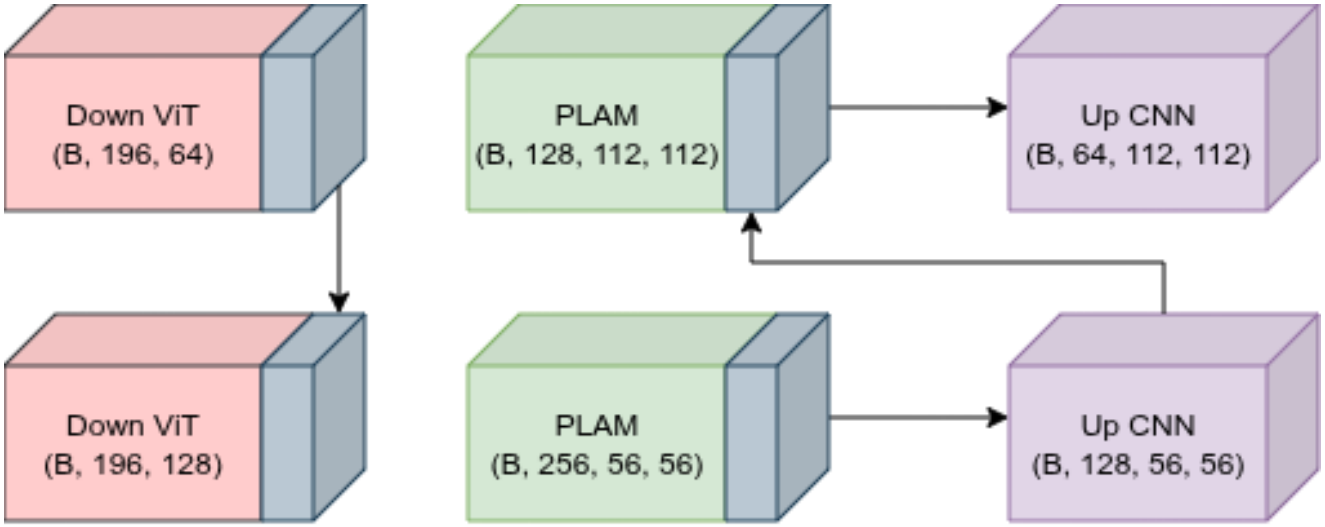
	QaTa-COV19-v2		**MosMedData+**	
	Supervised	Semi-supervised	Supervised	Semi-supervised
Optimizer	Adam			
Tỉ lệ nhãn	100%	25%	100%	25%
Batch size	24	16	24	16
LR	0.0003		0.001	
Scheduler	Cosine Annealing Restarts			
Epochs	100			

Cài đặt và thử nghiệm: Cài đặt thực tế



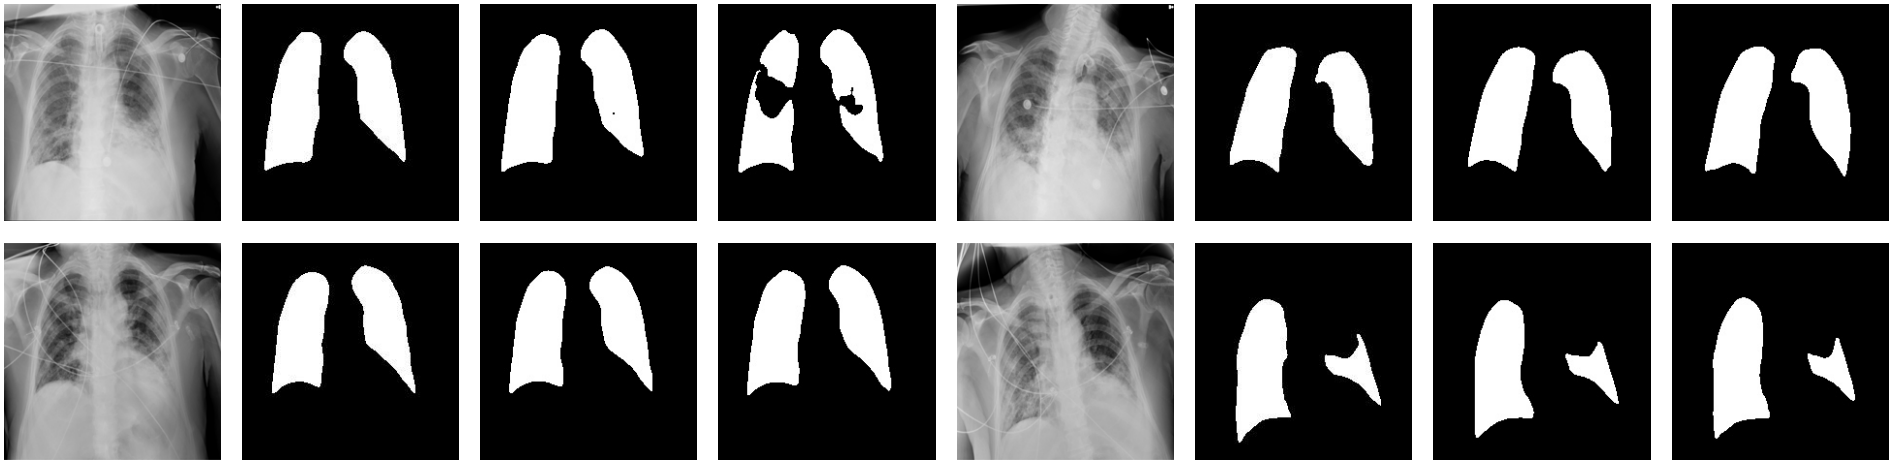
Hình 9: Minh họa kiến trúc LViT trong cài đặt.

Cài đặt và thử nghiệm: Cài đặt thực tế



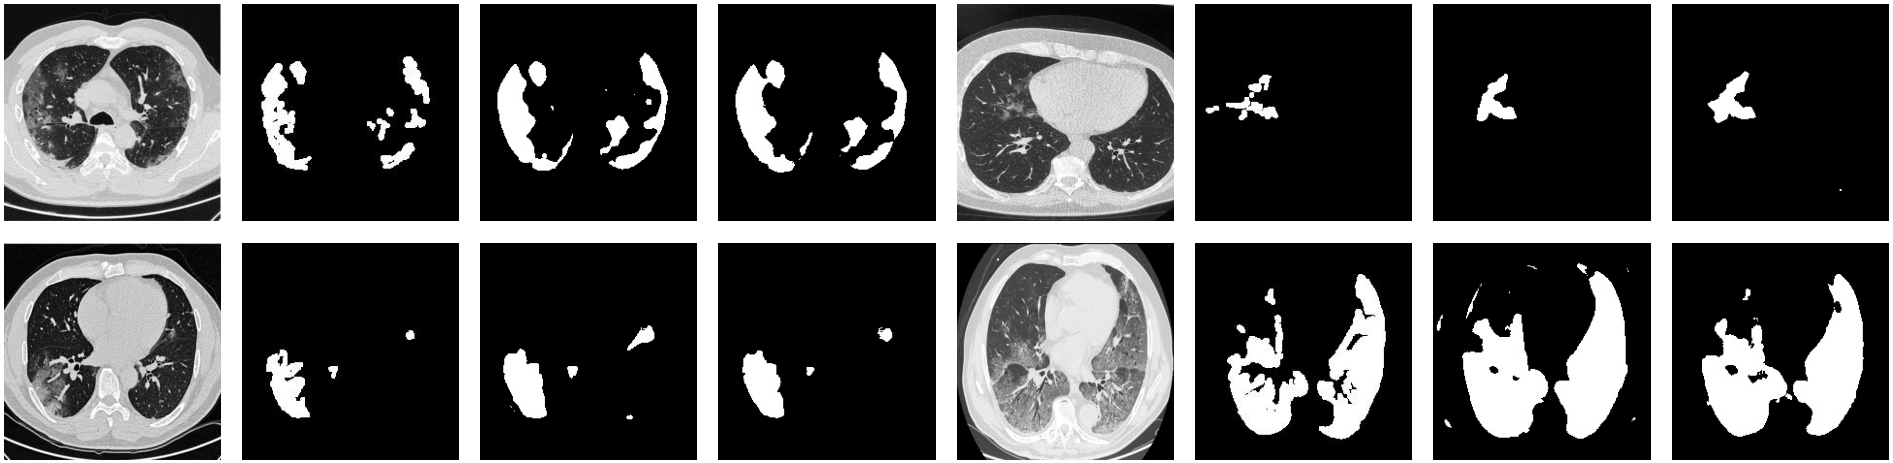
Hình 10: Phép nối dữ liệu theo chiều kênh.

Cài đặt và thử nghiệm: Kết quả thử nghiệm



Hình 11: So sánh trực quan dự đoán trên QaTa-COV19, thứ tự từ trái sang phải là ảnh gốc, ground truth, mask supervised và mask semi-supervised.

Cài đặt và thử nghiệm: Kết quả thử nghiệm



Hình 12: So sánh trực quan dự đoán trên MosMedData+, thứ tự trong mỗi nhóm là ảnh gốc, ground truth, mask supervised và mask semi-supervised.

Cài đặt và thử nghiệm: Kết quả thử nghiệm

Bảng 2: Kết quả huấn luyện, kiểm định và kiểm thử của LViT trên các cấu hình thực nghiệm

Dữ liệu	**Cấu hình**	**Train Dice**	**Val Dice**	**Test Dice**	**Test IoU**
Covid19	Supervised	86.32	79.44	81.27	72.46
Covid19	Semi-supervised	85.91	75.28	76.72	66.93
MosMedData+	Supervised	79.73	67.20	13.39	11.00
MosMedData+	Semi-supervised	78.79	63.86	12.92	10.44

Cài đặt và thử nghiệm: Kết quả thử nghiệm

Trên tập Covid19, mô hình đạt kết quả tương đối ổn định, cho thấy khoảng cách giữa huấn luyện, kiểm định và kiểm thử không quá lớn. Khi chuyển sang cấu hình semi-supervised, Test Dice và Test IoU đều giảm. Mức giảm này là hợp lý vì mô hình không còn được sử dụng đầy đủ nhãn thật trong quá trình huấn luyện, trong khi phần sinh nhãn giả trong mã nguồn tái lập không hoàn toàn tương đương với một quy trình bán giám sát hoàn chỉnh trong công trình gốc.

Trên tập MosMedData+, kết quả có sự khác biệt rõ rệt giữa train/validation và test. Cả supervised và semi-supervised đều có sự giảm mạnh. Điều này cho thấy mô hình có học được đặc trưng trên tập huấn luyện, nhưng khả năng tổng quát hóa sang tập kiểm thử của MosMedData+ chưa tốt.

Cài đặt và thử nghiệm: Kết quả thử nghiệm

Nguyên nhân kết quả trên MosMedData+ thấp có thể đến từ ba yếu tố chính:

- MosMedData+ là dữ liệu CT, khác biệt rõ với ảnh X-ray của Covid19 về cấu trúc lát cắt, độ tương phản và phân bố cường độ.
- Dữ liệu tái lập có thể khác công trình gốc về cách tổ chức, định dạng, ánh xạ mặt nạ và chia tập dữ liệu.
- Thời gian huấn luyện trên Kaggle bị giới hạn, mô hình dùng số epoch cố định nên có thể chưa hội tụ tốt trên MosMedData+.

Cài đặt và thử nghiệm: Kết quả thử nghiệm

Bảng 3: Kết quả so sánh LViT thử nghiệm với LViT công bố và các phương pháp SOTA

Phương pháp	**Văn bản**	**Tỉ lệ nhãn**	**QaTa-COV19**		**MosMedData+**	
			Dice (%)	mIoU (%)	Dice (%)	mIoU (%)
LViT-T-Exp (1/4)	✓	25%	76.72	66.93	12.92	10.44
LViT-T-Exp	✓	100%	81.27	72.46	13.39	11.00
LViT-TW (1/4)	×	25%	79.08	69.42	70.65	58.07
LViT-TW (1/2)	×	50%	80.35	70.74	71.89	59.63
LViT-TW	×	100%	81.12	71.37	72.58	60.40
LViT-T (1/4)	✓	25%	80.95	71.31	72.48	60.31
LViT-T (1/2)	✓	50%	82.73	73.99	73.56	61.05
LViT-T	✓	100%	83.66	75.11	74.57	61.33
U-Net	×	100%	79.02	69.46	64.60	50.73
UNet++	×	100%	79.62	70.25	71.75	58.39
nnUNet	×	100%	80.42	70.81	72.59	60.36
GLoRIA	×	100%	79.94	70.68	72.42	60.18
LAVT	×	100%	79.28	69.89	73.29	60.41

Cài đặt và thử nghiệm: Kết quả thử nghiệm

Phân tích trên Covid19

- Với 100% nhãn, mô hình tái lập đạt 81.27% Dice và 72.46% mIoU, chỉ thấp hơn LViT-T công bố 2.39 điểm Dice.
- Khoảng cách này tương đối nhỏ, cho thấy pipeline tái lập trên Covid19 vẫn giữ được phần lớn hiệu quả của LViT.
- Với 25% nhãn, kết quả giảm mạnh hơn, cho thấy thiết lập bán giám sát chưa tái hiện đầy đủ cơ chế của công trình gốc.

Cài đặt và thử nghiệm: Kết quả thử nghiệm

Phân tích trên MosMedData+

- Kết quả tái lập trên MosMedData+ thấp hơn rất nhiều so với kết quả công bố ở cả 100% và 25% nhãn.
- Train Dice và Val Dice vẫn khá cao, nhưng Test Dice thấp, cho thấy mô hình chưa tổng quát tốt sang tập kiểm thử.
- Nguyên nhân có thể liên quan đến khác biệt dữ liệu CT, tiền xử lý, cách chia tập và giới hạn thời gian huấn luyện.

Cài đặt và thử nghiệm: Kết quả thử nghiệm

Vai trò của thông tin văn bản

- Trong kết quả công bố, LViT-T có dùng văn bản đều tốt hơn LViT-TW chỉ dùng ảnh.
- Với 100% nhãn, Dice tăng từ 81.12% lên 83.66% trên QaTa-COV19.
- Trên MosMedData+, Dice tăng từ 72.58% lên 74.57%, cho thấy văn bản giúp định hướng vùng cần phân đoạn.

Cài đặt và thử nghiệm: Kết quả thử nghiệm

Nhận xét về bán giám sát

- Kết quả công bố cho thấy 25% nhãn vẫn đạt hiệu quả ổn định nhờ cơ chế sinh nhãn giả EPI.
- Trong tái lập, hiệu quả 25% nhãn phụ thuộc mạnh vào mức độ hoàn chỉnh của quy trình bán giám sát.
- EPI có tiềm năng giảm chi phí chú thích y khoa, nhưng cần bước sinh, lọc và cập nhật nhãn giả chặt chẽ hơn.

Mục lục

1. Giới thiệu
   - Bối cảnh
   - Động lực nghiên cứu
     - Ý nghĩa khoa học
     - Ý nghĩa thực tiễn
   - Phát biểu bài toán
2. Phương pháp
   - Dữ liệu
   - Quy trình xây dựng chú thích văn bản
   - Cấu trúc chú thích
   - Kiến trúc mô hình
   - Hàm mất mát
   - Cơ chế sinh nhãn giả
   - Pipeline huấn luyện và sử dụng
3. Cài đặt và thử nghiệm
   - Môi trường thử nghiệm
   - Cài đặt thực tế
   - Kết quả thử nghiệm

Tổng kết: Tổng kết

- Báo cáo đã tìm hiểu, phân tích và cài đặt LViT cho bài toán phân đoạn ảnh y khoa theo câu nhắc văn bản.
- LViT kết hợp đặc trưng ảnh và ngôn ngữ, giúp mô hình định hướng vùng tổn thương theo mô tả lâm sàng.
- Cách tiếp cận này phù hợp với dữ liệu y khoa, nơi ảnh thường đi kèm ghi chú vị trí, mức độ hoặc đặc điểm bệnh lý.

Tổng kết: Tổng kết

- Báo cáo đã phân tích các thành phần chính: CNN U-shape, ViT U-shape, BERT embedding, Patch Embedding, Reconstruct và PLAM.
- Nhánh CNN giữ chi tiết cục bộ, trong khi nhánh ViT học quan hệ toàn cục giữa các vùng ảnh.
- Văn bản được dùng như tín hiệu điều kiện, giúp quá trình phân đoạn không chỉ phụ thuộc vào ảnh đầu vào.

Tổng kết: Tổng kết

- Báo cáo đã trình bày pipeline huấn luyện, suy luận và tính loss kết hợp với sinh nhãn giả.
- Language-Vision Loss và EPI cho thấy tiềm năng khai thác dữ liệu ít nhãn hoặc không nhãn.
- Phần cài đặt đã được điều chỉnh để tương thích với môi trường Kaggle, dữ liệu thực nghiệm và tài nguyên giới hạn.

Mục lục

1. Giới thiệu
   - Bối cảnh
   - Động lực nghiên cứu
     - Ý nghĩa khoa học
     - Ý nghĩa thực tiễn
   - Phát biểu bài toán
2. Phương pháp
   - Dữ liệu
   - Quy trình xây dựng chú thích văn bản
   - Cấu trúc chú thích
   - Kiến trúc mô hình
   - Hàm mất mát
   - Cơ chế sinh nhãn giả
   - Pipeline huấn luyện và sử dụng
3. Cài đặt và thử nghiệm
   - Môi trường thử nghiệm
   - Cài đặt thực tế
   - Kết quả thử nghiệm

Hạn chế: Hạn chế

- Thực nghiệm chủ yếu tập trung trên QaTa-COV19-v2 và MosMedData+, chưa đánh giá đầy đủ trên nhiều miền dữ liệu khác.
- Cơ chế bán giám sát và sinh nhãn giả EPI mới được tái hiện ở mức hạn chế, chưa tương đương hoàn toàn với công trình gốc.
- Tập ESO-CT không được sử dụng do chưa được công bố công khai, làm giảm phạm vi đánh giá.

Hạn chế: Hạn chế

- Kết quả tái lập chịu ảnh hưởng bởi khác biệt môi trường phần mềm, cấu trúc dữ liệu và cách chia tập.
- Giới hạn tài nguyên trên Kaggle khiến quá trình huấn luyện khó tái hiện đầy đủ điều kiện của công trình gốc.
- Một số siêu tham số và bước tiền xử lý phải điều chỉnh, nên kết quả có thể khác so với kết quả công bố.

Mục lục

1. Giới thiệu
   - Bối cảnh
   - Động lực nghiên cứu
     - Ý nghĩa khoa học
     - Ý nghĩa thực tiễn
   - Phát biểu bài toán
2. Phương pháp
   - Dữ liệu
   - Quy trình xây dựng chú thích văn bản
   - Cấu trúc chú thích
   - Kiến trúc mô hình
   - Hàm mất mát
   - Cơ chế sinh nhãn giả
   - Pipeline huấn luyện và sử dụng
3. Cài đặt và thử nghiệm
   - Môi trường thử nghiệm
   - Cài đặt thực tế
   - Kết quả thử nghiệm

Hướng phát triển: Hướng phát triển

- Hoàn thiện thực nghiệm bán giám sát bằng cách triển khai đầy đủ cơ chế sinh và cập nhật nhãn giả EPI.
- Mở rộng đánh giá trên nhiều loại ảnh y khoa hơn như CT, MRI, X-ray và ảnh mô bệnh học.
- Kiểm tra khả năng tổng quát hóa của LViT trên nhiều bệnh lý, nhiều cách chia dữ liệu và nhiều dạng chú thích văn bản.

Hướng phát triển: Hướng phát triển

- Nghiên cứu các bộ mã hóa văn bản mạnh hơn để khai thác tốt hơn ngữ cảnh trong mô tả y khoa.
- Tích hợp các mô hình nền tảng y khoa nhằm cải thiện căn chỉnh giữa đặc trưng ảnh và đặc trưng ngôn ngữ.
- Tối ưu quy trình sinh, lọc và cập nhật nhãn giả để giảm chi phí chú thích dữ liệu y khoa.

Hướng phát triển: Kết luận chung

- LViT là hướng tiếp cận tiềm năng cho phân đoạn ảnh y khoa đa phương thức.
- Việc kết hợp thị giác và ngôn ngữ giúp tận dụng tri thức mô tả từ chuyên gia.
- Dù còn hạn chế trong tái lập, báo cáo đã làm rõ kiến trúc, cơ sở phương pháp và các vấn đề kỹ thuật khi triển khai LViT.

Tài liệu tham khảo I



Zihan Li **andothers**. *LViT: Language meets Vision Transformer in Medical Image Segmentation*. en. arXiv:2206.14718 [cs]. **june** 2023. DOI: 10.48550/arXiv.2206.14718. URL: http://arxiv.org/abs/2206.14718 (**urlseen** 23/03/2026).